

Détection d'anomalie multi-domaines

Contents

3.1	Objectifs et cadre de détection	2
3.2	Etat de l'art de la détection d'anomalies	3
3.2.1	Approche historique dans les réseaux traditionnels	3
3.2.2	Apprentissage non supervisé appliquée aux réseaux 5G	3
3.3	Méthodologie de formalisation	5
3.3.1	Extraction des payload applicatives	5
3.3.2	Tri et sélection des features	5
3.3.3	Transformation en graph	5
3.3.4	Utilisation de Linegraph	5
3.4	Détection d'anomalies dans des graphs	5
3.4.1	Fonctionnement des GNN	5
3.4.2	Prise en compte des arcs	5
3.4.3	GNN Dynamiques Discrets et Continus	5
3.4.4	Littérature des GNN pour la détection d'anomalies	5
3.5	NLP et traitement de features en dimension non-fini	5
3.6	Conclusion	5

Le passage aux réseaux 5G s'accompagne d'un changement de paradigme majeur, caractérisé par une architecture distribuée et une complexification des interactions entre entités. Par ailleurs, l'émergence d'anomalies sémantique, séquentielle et topologique impose de nouvelles exigences en matière d'analyse. Dans ce contexte, il devient nécessaire non seulement d'adopter une analyse fine au niveau des paquets, mais également de prendre en compte le contexte dans lequel s'inscrivent les échanges. Or, cette problématique reste relativement récente dans le domaine des télécommunications, et les méthodes actuelles de détection d'anomalies apparaissent inadaptées à ce nouveau paradigme.

Dans ce contexte, nous proposons de représenter les échanges au sein des réseaux 5G sous la forme d'un graphe dynamique, permettant de capturer à la fois les interactions entre les différentes entités du réseau ainsi que l'évolution de ces interactions dans le temps. Cette formalisation nous permet d'exploiter des techniques issues du domaine des GNN intrinsèquement adaptées à l'analyse des

interactions complexes. Nous nous intéressons plus particulièrement aux GNN dynamiques, qui intègrent nativement la dimension temporelle.

3.1 Objectifs et cadre de détection

Dans ces travaux, nous nous plaçons du point de vue de l'opérateur d'un réseau 5G et nous nous intéressons à la détection d'anomalies en nous concentrant exclusivement sur le trafic de contrôle échangé entre les entités du réseau, qu'il s'agisse du cœur de réseau ou du RAN. Le trafic utilisateur n'est pas pris en compte, car il ne présente pas de spécificités propres à l'architecture 5G et ne relève pas de la responsabilité directe du fournisseur d'accès réseau. En se plaçant du point de vue de l'opérateur, nous supposons que celui-ci possède l'ensemble des NF et dispose d'un accès complet au trafic de contrôle. Dans l'architecture 5G, la fonction Service Communication Proxy (SCP) agit comme un intermédiaire dans les échanges entre les différentes NF, notamment pour le routage des requêtes et la vérification des autorisations d'accès. Dans ce contexte, il est raisonnable de considérer que l'opérateur peut observer l'intégralité du trafic de contrôle en déployant des sondes au niveau des SCP, qui constituent des points d'observation privilégiés des interactions entre NF. Ce trafic est généralement chiffré, par exemple via TLS sur le SBI ou via IPsec pour certains canaux, tels que N3 ou N4, reposant sur des protocoles spécifiques à la 5G. Cependant, en adoptant le point de vue de l'opérateur, nous supposons disposer des clés de chiffrement nécessaires pour accéder au contenu de ces échanges en clair. L'objectif serait de pouvoir exécuter nos modèles de détection en temps réel. Malgré les débits élevés offerts par la 5G, le volume de données est majoritairement porté par le trafic utilisateur, qui n'entre pas dans le périmètre de cette étude. À l'inverse, le trafic de contrôle est principalement composé de messages liés aux changements d'état des entités du réseau, qu'il s'agisse d'UE ou de NF, et ont une fréquence d'occurrence plus modérée. Par conséquent, bien que le surcoût induit par nos modèles puisse avoir un impact sur les performances, il est raisonnable de supposer que les ressources disponibles sont suffisantes pour permettre un traitement en temps réel, notamment grâce à l'exploitation de techniques d'optimisation et de parallélisation. La remédiation des anomalies détectées ne relève pas du périmètre de ce travail et est considérée comme une brique fonctionnelle distincte. Nous nous concentrons exclusivement sur la détection et les alertes générées par notre système ont vocation à être exploitées de manière similaire à celles produites par un système de détection d'intrusion (IDS) classique. Elles peuvent ainsi conduire, par exemple, à des ajustements des règles de firewall ou à des modifications de l'architecture réseau. L'objectif de ces travaux n'est pas de concevoir un système de détection absolu et entièrement autonome. En effet, une anomalie ne constitue pas nécessairement le signe d'une activité malveillante et peut résulter d'une mise à jour, d'une erreur de configuration ou encore d'une interconnexion avec un système tiers, comme dans le cas du roaming. Dans ce contexte, la distinction entre une anomalie bénigne et une attaque de

type zero-day requiert in fine une expertise humaine. Par conséquent, l'un des aspects essentiels de nos travaux est de proposer un système interprétable, venant compléter une expertise humaine plutôt que de la remplacer.

3.2 Etat de l'art de la détection d'anomalies

3.2.1 Approche historique dans les réseaux traditionnels

La détection d'attaques au sein des réseaux est historiquement assurée par des systèmes de détection d'intrusion (IDS). Ces systèmes reposent généralement sur une analyse du trafic agrégé sous forme de flux, plutôt qu'au niveau des paquets individuels. Cette approche permet d'extraire des métriques globales et d'effectuer des analyses de volumétrie, par exemple afin de détecter des variations significatives du volume de trafic ou repérer des signatures d'attaques connues.

Parmi les IDS les plus connus on retrouve Snort [?], Zeek [?] et Suricata [?], qui reposent sur des règles prédéfinies pour identifier des motifs (aussi appelés signatures) d'attaques spécifiques dans le flux réseau. Ce sont la plupart du temps des outils open source qui bénéficient d'une large communauté qui contribue à l'enrichissement de leur base de signatures.

Par ailleurs, des approches fondées sur l'apprentissage automatique supervisé ont également été proposées pour la détection d'intrusion, notamment à l'aide de réseaux bayésiens [?], de machines à vecteurs de support (SVM) [?] ou encore d'arbres de décision [?]. Ces méthodes présentent l'avantage d'être relativement transparentes, interprétables et efficaces pour détecter des attaques déjà connues.

Néanmoins, les modèles de détection supervisé et rule based restent ultimement limités à la détection d'attaques déjà connues et ne permettent pas de considérer des comportements anormaux au niveau paquet ou des attaques zero-day. Or, il existe une grande variété de formes de cyberattaques et de nouvelles menaces émergent régulièrement. Cette diversité est amplifiée dans un système complexe tel que la 5G et il devient inenvisageable de dresser une liste exhaustive des menaces courantes et à venir. De fait, les approches non supervisées paraissent plus adaptées car elles permettent d'identifier des comportements anormaux, même inconnus, en se fondant sur des déviations par rapport aux comportements normaux présentés lors de l'entraînement.

Parmi les approches non supervisées, Münz et al. [?] proposent, par exemple, de découvrir des motifs anormaux en adaptant l'algorithme K-Means au trafic réseau, permettant ainsi de regrouper les données en fonction de leur similarité sans nécessiter d'étiquettes. Néanmoins, les caractéristiques utilisées en entrée restent relativement limitées et se restreignent notamment au nombre de paquets, au volume d'octets ainsi qu'aux adresses source et destination. Une telle approche permet d'identifier des motifs liés à la volumétrie et, par conséquent, de détecter certains types d'attaques par déni de service (DoS). Toutefois, comme elle ne prend en compte ni le contenu sémantique des paquets ni le contexte des échanges, elle demeure insuffisante pour détecter des attaques plus subtiles.

Ariu et al. [?] proposent quant à eux d'utiliser des modèles de Markov cachés afin de modéliser le trafic réseau sous forme de séquences d'octets. Ces modèles apprennent des probabilités de transition à partir de trafic bénin, puis évaluent dans quelle mesure un trafic observé s'en écarte. Cependant, les séquences considérées sont limitées à des fenêtres de taille relativement réduite, ce qui empêche la capture de dépendances temporelles à long terme. De plus, cette approche ne permet pas de modéliser explicitement les interactions entre paquets.

3.2.2 Apprentissage non supervisé appliquée aux réseaux 5G

Parmi les travaux de détection spécifiques à la 5G, Kale et al. [?] proposent d'utiliser des réseaux de neurones convolutionnels (CNN) en considérant les octets d'un paquet comme une image sur laquelle sont ensuite étudiées des variations structurelles. Les modèles CNN obtiennent de très bonnes performances dans de nombreux domaines, y compris dans des tâches qui ne relèvent pas intrinsèquement de la vision par ordinateur. Toutefois, comme ils n'interprètent pas le contenu sémantique des données, leur capacité de détection se limite à un sous-ensemble d'attaques sémantiques dans lesquelles les valeurs s'écartent fortement du trafic normal. Ils ne permettent donc pas de détecter des variations légères de valeurs d'identifiants comme les adresses IP ou les IMSI. De plus, le travail présenté par Kale et al. se concentre uniquement sur la détection sémantique et ne prend pas en compte le contexte des échanges.

Lam et al. [?] ajoutent un contexte temporel à leur CNN en alimentant ses sorties dans un réseau de neurones récurrent RNN. Cependant, en plus de ne pas être satisfaisant sur le domaine sémantique, leur modèle ne prend pas en compte l'identité des acteurs impliqués dans les échanges et n'est donc pas capable de détecter des attaques relationnelles.

AutoGuard [?] et ADSeq-5GCN [?] utilisent également des RNN afin de capturer les dépendances temporelles au sein de séquences de messages. De plus, leurs approches intègrent l'identité des entités communicantes, ce qui leur permet aussi de détecter des anomalies topologiques. Cependant, elles ne prennent pas en compte le contenu des paquets et passent donc à côté des anomalies sémantiques.

5GCGuard [?] repose également sur une modélisation séquentielle incluant les identités des NF. Les auteurs enrichissent également leur formalisation en intégrant des informations relatives au contenu des paquets, notamment via l'URL associée à chaque message. Bien que cette information soit pertinente, elle reste limitée aux paquets HTTP et ne représente qu'une fraction du contenu global des paquets, lequel peut encore présenter des comportements anormaux.

À notre connaissance, GSAD [?] est la seule approche de détection d'anomalies 5G basée sur l'apprentissage profond qui considère simultanément le contenu, la séquence et les interactions topologiques. Dans leur travaux ils proposent cette fois de formaliser leurs données sous forme de graph sur lesquels ils appliquent des réseaux de neurones adaptés (GNN) afin de modéliser le contexte relationnel des échanges entre les différentes entités. La sortie générée par leur GNN est transmise

à un RNN pour le contexte temporel. Mais, les auteurs utilisent ici aussi un CNN pour capturer le contexte sémantique ce qui rend l'analyse du contenu des paquets relativement superficielle.

L'état de l'art montre que peu d'approches considèrent simultanément les dimensions sémantique, temporelle et topologique. Les approches basées sur les GNN apparaissent particulièrement adaptées pour modéliser les interactions entre entités. À l'inverse, aucune des modélisations proposées ne semble réellement adaptée au traitement du contenu sémantique des paquets, celui-ci étant le plus souvent considéré comme un bloc monolithique. Dans ce contexte, nous proposons de représenter le contenu des paquets de manière plus fine en décomposant leurs paramètres en nœuds indépendants.

3.3 Méthodologie de formalisation

3.3.1 Extraction des payload applicatives

3.3.2 Tri et sélection des features

3.3.3 Transformation en graph

3.3.4 Utilisation de Linegraph

3.4 Détection d'anomalies dans des graphs

3.4.1 Fonctionnement des GNN

3.4.2 Prise en compte des arcs

3.4.3 GNN Dynamiques Discrets et Continus

3.4.4 Littérature des GNN pour la détection d'anomalies

3.5 NLP et traitement de features en dimension non-fini

3.6 Conclusion

Bibliography

- [1] ARIU, D., TRONCI, R., AND GIACINTO, G. *HMMPayl*: An intrusion detection system based on Hidden Markov Models. *Computers & Security* 30, 4 (June 2011), 221–241. 4
- [2] KOC, L., MAZZUCHI, T. A., AND SARKANI, S. A network intrusion detection system based on a Hidden Naïve Bayes multiclass classifier. *Expert Systems with Applications* 39, 18 (Dec. 2012), 13492–13500. 3
- [3] MOON, D., IM, H., KIM, I., AND PARK, J. DTB-IDS: an intrusion detection system based on decision tree using behavior analysis for preventing APT attacks. *The Journal of Supercomputing* 73 (July 2017). 3
- [4] MÜNZ, G., LI, S., AND CARLE, G. Traffic Anomaly Detection Using K-Means Clustering. 3
- [5] VIJAYANAND, R., DEVARAJ, D., AND KANNAPIRAN, B. Intrusion detection system for wireless mesh network using multiple support vector machine classifiers with genetic-algorithm-based feature selection. *Computers & Security* 77 (Aug. 2018), 304–314. 3