

Evaluation empirique des modèles

Contents

1.1	Etat de l'art des datasets	1
1.1.1	Analyse des datasets 5G	2
1.1.2	Limites dans l'évaluation de la qualité des données	3
1.2	Génération d'un dataset	5
1.2.1	Trafic bénin	6
1.2.2	Trafic anormal	8
1.2.3	Méthodologie de génération	12
1.2.4	Environnement et implémentation	15
1.3	Evaluation des caractéristiques du dataset	15
1.3.1	Caractérisation sémantique	16
1.3.2	Caractérisation séquentielle	17
1.3.3	Caractérisation topologique	18
1.3.4	Synthèse	19
1.4	Evaluation des modèles de détection	19
1.4.1	Métriques de classification	20
1.4.2	Courbe ROC	21
1.4.3	Approche supervisée	21
1.4.4	Approche non supervisée	24
1.5	Représentation interprétable de la détection	28
1.6	Conclusion	31

Les données constituent un élément central des approches d'apprentissage automatique. Pourtant, dans l'état de l'art appliqué à la 5G, aucun dataset ne semble aujourd'hui s'imposer comme référence commune. La majorité des travaux reposent sur des datasets construits localement par des équipes de recherche, souvent avec des méthodologies différentes et insuffisamment documentées. Cette absence de standardisation rend difficile la comparaison objective des modèles proposés dans la littérature. Dans ce contexte, la création d'un dataset de référence apparaît comme une opportunité importante pour la communauté scientifique. Toutefois, cette démarche soulève plusieurs questions fondamentales autour de la

définition de la qualité d'un dataset, un sujet qui demeure aujourd'hui au cœur des discussions de la communauté plus large de l'intelligence artificielle. Nous proposons donc, dans cette thèse, la conception d'un dataset dédié, en portant une attention particulière à la reproductibilité de son processus de génération ainsi qu'à l'évaluation des données produites.

Au moment de l'écriture de cette thèse, la recherche en apprentissage automatique fait face à une problématique croissante de reproductibilité des résultats. Dans de nombreux travaux, l'obtention de performances élevées sur des métriques de détection ou de classification constitue un critère déterminant pour la publication scientifique. En pratique, l'absence de scores compétitifs tend à éclipser les contributions méthodologiques pourtant pertinentes. Cette pression conduit à la multiplication de travaux présentant des résultats difficilement reproductibles ou insuffisamment documentés. Il devient alors complexe de déterminer si les performances observées traduisent réellement une bonne capacité de généralisation du modèle ou si elles résultent d'un surapprentissage sur des sous-ensembles de données peu représentatifs. Dans cette thèse, une attention particulière sera donc portée à la limitation des biais expérimentaux.

1.1 Etat de l'art des datasets

Dans cette section, nous commencerons par étudier les datasets existants ainsi que leurs limites, avant de présenter les principales recommandations et considérations méthodologiques relatives à la génération de datasets dans le domaine de l'apprentissage automatique.

1.1.1 Analyse des datasets 5G

Pour des raisons de confidentialité et de protection des données, les grands opérateurs de télécommunication partagent rarement les données issues de leurs réseaux opérationnels. À notre connaissance, il n'existe donc pas de dataset public contenant des données provenant d'un réseau commercial. Les travaux disponibles reposent ainsi principalement sur des données synthétiques.

À notre connaissance, seuls trois travaux se positionnent à l'heure actuelle officiellement comme des datasets 5G publics dédiés à la détection d'anomalies. 5G-NIDD [?] considère principalement des attaques génériques au niveau réseau, sans prendre en compte les spécificités des réseaux 5G. PFCP Intrusion Detection Dataset [?] propose un large éventail d'attaques ciblant le plan de gestion de session, mais ne détaille pas la génération du trafic légitime. Enfin, 5GAD [?] introduit plusieurs attaques visant les interfaces orientées services du CN, mais son trafic normal repose essentiellement sur des activités utilisateur telles que le streaming vidéo ou le téléchargement de fichiers. Ce trafic étant chiffré, il diffère fortement du trafic de contrôle utilisé pour les attaques.

En l'absence de dataset public satisfaisant, les travaux sur la détection d'anomalies doivent généralement produire leurs propres données d'entraînement,

souvent privées ou insuffisamment documentées. GSAD [?] et ADSeq-5GCN [?] proposent plusieurs procédures normales, telles que l’enregistrement d’UE ou l’établissement de session des UE mais ne couvrent cependant qu’un nombre limité d’attaques. PROV5GC [?] enrichit la diversité de trafic légitime avec les changements d’état des UE. Néanmoins, parmi les attaques qu’ils proposent, certaines concernent le slicing et le signalement SMS, pour lesquels il n’introduisent pas d’équivalents légitimes avec lesquels faire contraster leurs attaques. Enfin, 5GCGuard [?] est le seul travail à notre connaissance fournissant des outils permettant de reproduire la génération des données. Cependant, seule une version prétraitée de leur dataset généré est publiée, sans accès aux captures brutes originales.

Dataset	PCAP	Code	Procédures bénignes				
			Enregistrement d’UE	Gestion de Session	Changement d’Etat	Gestion de NF	Transmission par UPF
5GAD [?]	✓	✓					
PFCP IDD [?]	✓						
GSAD [?]			✓				
AdSeq [?]			✓	✓			
PROV5GC [?]			✓	✓	✓		
5GCGuard [?]		✓	✓	✓			
Notre solution	✓	✓	✓	✓	✓	✓	✓

Table 1.1: Comparaison de différents datasets 5G et de leurs caractéristiques.

Ainsi, le principal problème des travaux récents réside dans le manque important de ressources publiques ainsi que dans l’absence de cohérence entre les attaques à détecter et le trafic normal utilisé pour les contraster. Le tableau ?? présente une synthèse comparative des travaux de l’état de l’art proposant des datasets 5G ou générant leurs propres données pour la détection d’anomalies.

1.1.2 Limites dans l’évaluation de la qualité des données

Afin d’évaluer correctement les performances des modèles de détection, il est nécessaire de s’assurer en amont que les données utilisées sont fiables et représentatives. Le machine learning est utilisé depuis longtemps pour les NIDS, ce qui a conduit à la constitution de nombreux datasets. Cependant, plusieurs travaux ont déjà mis en évidence des lacunes importantes dans des datasets pourtant considérés comme étant des références. L’exemple le plus connu est CIC-IDS-2017 [?], qui fait souvent consensus pour des tâches de détection d’anomalies réseau. Néanmoins, des travaux ont mis en lumière des problèmes critiques dans son contenu, notamment des erreurs d’étiquetage ainsi que la duplication de paquets [?]. Cela montre que la problématique est loin d’être triviale et qu’elle constitue encore un sujet d’actualité.

Dans leur travaux, Gharib et al. [?] ont proposé un ensemble de lignes directrices permettant d’évaluer les méthodologies de génération de datasets. Ces recommandations soulignent l’importance de la diversité des types de trafic, de l’anonymisation, ainsi que d’une documentation rigoureuse garantissant

la reproductibilité. De leur côté, Flood et al. [?] apportent des éléments complémentaires en mettant en évidence des biais concrets présents dans des datasets populaires. Ils montrent que ces biais permettent la détection d'anomalies même à l'aide de modèles extrêmement simples, ce qui remet en question la validité des résultats d'évaluation obtenus sur de telles données. Bien que ces travaux fournissent des recommandations utiles, ils s'appliquent principalement à des systèmes NIDS basés sur l'analyse de flux, plutôt que sur des paquets individuels.

Par conséquent, certaines de ces lignes directrices ne sont pas directement transposables et doivent être réinterprétées dans notre contexte. En compilant les recommandations issues de l'état de l'art et en les adaptant à notre problématique, nous identifions les objectifs suivants comme essentiels à la constitution d'un dataset 5G de qualité.

1.1.2.1 Exhaustivité des surfaces d'attaques

Comme le montre le tableau ??, la majorité des travaux se concentrent sur un nombre limité de procédures de fonctionnement du réseau 5G. Les scénarios bénins se limitent généralement aux procédures d'enregistrement de l'UE et de transition d'état, qui génèrent principalement de la signalisation entre l'AN et le CN. Certains travaux incluent également des procédures de gestion de session, permettant de couvrir les échanges de signalisation PFCP entre les fonctions de gestion de session et le plan utilisateur.

En revanche, deux aspects pourtant essentiels au fonctionnement d'un réseau 5G sont largement absents de la littérature. D'une part, aucun des datasets étudiés ne propose de scénario bénin mettant en œuvre l'encapsulation du trafic utilisateur. D'autre part, les mécanismes de gestion dynamique des NF, pourtant au cœur de la flexibilité introduite par la 5G, ne sont que très rarement représentés.

Notre approche vise ainsi à proposer un dataset couvrant non seulement les surfaces les plus couramment utilisées dans les travaux existants, mais également ces deux nouvelles surfaces, que nous considérons indispensables pour obtenir une représentation plus complète du fonctionnement d'un réseau 5G.

1.1.2.2 Définition du périmètre d'utilisation

Les biais peuvent apparaître très facilement dans un dataset et introduire des corrélations artificielles facilitant excessivement la détection. Par exemple, la prise en compte des adresses MAC par un utilisateur pourrait permettre de discriminer très facilement un attaquant. Afin de limiter ces biais autant que possible, il est important de distinguer clairement les surfaces constituant le véritable objectif du dataset de celles qui ne doivent pas être prises en compte lors de l'analyse.

Notre dataset est donc conçu pour être utilisé au niveau paquet sur les protocoles correspondant aux surfaces considérées, à savoir GTP, PFCP et HTTP/2. Tout autre protocole doit être exclu des analyses afin d'éviter l'introduction de biais

non souhaités. La seule exception concerne la couche IP, pour laquelle les adresses source et destination doivent être conservées et utilisées comme identifiants des NF afin de permettre la détection des attaques basées sur les interactions.

Un autre point important de notre dataset est l'absence de contrainte de temps réel, qui n'est pas pertinent dans notre cas d'utilisation. En effet seul l'ordre des paquets dans les séquence importe pour détecter les attaques que l'on considère. Ainsi, l'utilisation de notre dataset suppose de prendre uniquement en compte de l'ordre d'arrivée des paquets, et d'ignorer leurs horodatages exacts.

1.1.2.3 Réalisme des données synthétiques

En l'absence d'accès à du trafic 5G réel, la principale solution pour les travaux de recherche consiste à s'appuyer sur des données synthétiques, générées à partir d'implémentations open-source de réseaux 5G. Bien qu'elles soient synthétiques, les données générées sur ces implémentations ne sont pas pour autant irréalistes. En effet, la 5G est en partie conçue pour des Réseaux Privés Mobiles (MPN) et destinée aux entreprises souhaitant déployer leur propre infrastructures, notamment pour garantir une faible latence ou protéger des données sensibles. Dans ces situations, il est souvent excessif de redévelopper entièrement un cœur 5G, ce qui favorise l'adoption d'implémentations open-source telles que OAI [?], free5GC [?] et Open5GS [?]. On observe également des cas d'acteurs industriels tels que Firecell [?], qui proposent des solutions prêtes à l'emploi intégrant des implémentations basées sur OAI [?]. Ainsi, même si notre dataset a été généré à partir d'une implémentation différente de celles des grands opérateurs de réseaux mobiles, il constitue une représentation réaliste d'un scénario possible de déploiement 5G privé et apparaît donc comme une solution légitime.

1.1.2.4 Trafic légitime de nature adaptée

La détection d'anomalies nécessite de disposer d'exemples représentatifs de trafic légitime servant de référence face aux attaques. Pourtant, peu de travaux proposent un trafic bénin réellement comparable aux attaques qu'ils cherchent à détecter. Pour chaque attaque incluse dans le datasets, il est donc essentiel d'identifier les messages légitimes pouvant servir de référence lors de la détection. Dans notre approche, chaque attaque intégrée au datasets est associée à au moins un type de message bénin auquel elle peut être comparée. Les résultats sont présentés dans le Tableau ??.

1.1.2.5 Caractérisation des attaques proposées

Lorsqu'un datasets intègre des attaques, il est essentiel d'identifier précisément les caractéristiques qui les distinguent du trafic bénin. Dans les sections précédentes, nous avons montré que les attaques pouvaient être catégorisées selon trois dimensions : sémantique, temporelle et topologique. Afin d'éviter l'introduction de biais, il est nécessaire de classifier chaque attaque selon ces dimensions et de

vérifier qu'elle ne puisse être détectée qu'à travers l'analyse de la ou des dimensions qui la caractérisent. Ainsi, pour chaque attaque incluse dans notre dataset, nous définissons explicitement les dimensions sur lesquelles elle doit être détectée. Ces correspondances sont détaillées dans le Tableau ??.

1.1.2.6 Caractéristiques fortement dépendantes

Une caractéristique fortement dépendante correspond à une propriété inattendue sur laquelle un modèle peut surapprendre durant l'entraînement. La définition du périmètre d'utilisation réduit déjà significativement le nombre de caractéristiques fortement dépendantes susceptibles d'apparaître. Toutefois, de telles caractéristiques peuvent encore émerger au sein des couches retenues. Nous définissons donc plusieurs critères visant à limiter leur apparition.

Pour toute attaque ne reposant pas sur une dimension sémantique, la payload doit être strictement identique à celle d'un paquet bénin. Dans le cas des attaques basées sur la répétition, il est nécessaire de randomiser l'ordre d'exécution des procédures et d'insérer du trafic bénin comme bruit de fond durant les attaques. Enfin, pour les attaques basées sur les interactions, l'adresse IP de l'attaquant doit rester cohérente au sein d'une même instance d'attaque sans pour autant demeurer constante à l'échelle de l'ensemble du datasets.

1.2 Génération d'un dataset

Cette section décrit le dataset généré dans le cadre de nos travaux. Nous présentons dans un premier temps les différents types de messages bénins et malveillants retenus. Nous détaillons ensuite les choix méthodologiques mis en œuvre afin de garantir que les données produites respectent les critères de qualité précédemment définis. Enfin, nous décrivons le processus technique de génération du dataset, de manière à en assurer la reproductibilité.

1.2.1 Trafic bénin

Parmi le trafic de contrôle 5G, les échanges entre entités s'organisent sous forme de séquences de messages appelées procédures. Certaines procédures se limitent à quelques messages échangés entre deux acteurs, tandis que d'autres peuvent impliquer de nombreuses interactions entre plusieurs NF. En effet, lorsqu'une NF doit exécuter une action nécessitant des informations ou des ressources externes, elle peut être amenée à solliciter d'autres NFs, conduisant à des procédures complexes comportant parfois plusieurs dizaines de messages. La plupart sont déclenchées à la suite d'une action initiée par un utilisateur. Toutefois, certaines peuvent également être lancées soit par une fonction réseau du CN, soit en réaction à un événement particulier, soit de manière périodique.

Le standard 5G définit un très grand nombre de procédures, souvent décliné en plusieurs variantes et sont décrites dans la spécification 3GPP TS 23.502

[?]. En pratique, il est difficile de reproduire exhaustivement l'ensemble de ces comportements, d'autant plus que les implémentations open-source disponibles ne couvrent qu'une partie des fonctionnalités prévues par les spécifications. Nous nous concentrons donc sur un sous-ensemble de procédures sélectionnées en fonction de leur importance opérationnelle et de leur pertinence vis-à-vis des scénarios d'attaque considérés. L'objectif est de disposer d'un trafic légitime suffisamment diversifié tout en garantissant la présence de procédures pouvant être directement mises en contraste avec les attaques incluses dans le dataset.

1.2.1.1 Enregistrement des UEs

Les procédures d'enregistrement des UEs sont celles les plus couramment utilisés dans l'état de l'art pour générer du trafic légitime. Elles produisent une vingtaine de requêtes réparties entre le RAN et le CN. Ces procédures font intervenir plusieurs protocoles, notamment NGAP, NAS et HTTP/2, ainsi que différentes NF telles que l'AMF, le PCF, le SMF, l'AUSF et l'UDM. Dans le cadre de notre étude, leur principal intérêt réside dans la diversité des messages et des interactions qu'elles génèrent. La Figure ??, extraite de la spécification 3GPP, illustre une procédure complète d'enregistrement incluant l'ensemble des étapes optionnelles.

1.2.1.2 Changements d'état des UE

Dans la même logique que les procédures d'enregistrement, PROV5GC [?] propose un trafic légitime fondé sur les transitions d'état des UEs. Lorsqu'un UE demeure inactif pendant une certaine durée, une procédure de *Libération de contexte* est automatiquement déclenchée. Celle-ci génère une séquence de messages entre le RAN et le CN visant à modifier l'état de l'UE du point de vue du CN et ainsi économiser des ressources précédemment allouées. Dans notre cas, ces procédures sont déclenchées manuellement, en envoyant nous-mêmes le message de libération de contexte. Lorsqu'un UE inactif redevient actif, une procédure de *requête de service* est initiée afin de rétablir son état actif. Elle peut être déclenchée soit par la réception d'un message à destination d'un UE inactif, soit, à l'inverse, par l'envoi d'un message depuis ce dernier. Qu'il s'agisse de la libération de contexte ou de la reprise d'activité, ces procédures correspondent à des comportements courants dans les réseaux opérationnels et contribuent à accroître la diversité des messages présents dans le dataset.

1.2.1.3 Création et libération de session

Plusieurs attaques décrites dans l'état de l'art ciblent l'interface N4 reliant le SMF et l'UPF, responsable de la gestion des sessions. Sur cette interface, les échanges reposent sur le protocole PFCP qui sont notamment utilisés par des messages de création, de modification et de libération de session qui sont incluses dans la procédure d'enregistrement de l'UE et de redémarrage des sessions actives d'UE.




Figure 1.1: Procédure générale d'enregistrement tel que proposé dans la TS 23.502 de 3GPP [?].

Certaines attaques [?] ciblant spécifiquement les messages PFCP associés à la création ou à la suppression de sessions, il est indispensable d'inclure des exemples légitimes de ces mêmes procédures dans le dataset afin de garantir une couverture réaliste des comportements du réseau.

1.2.1.4 Gestion des NF

L'architecture du cœur 5G étant conçue pour s'adapter dynamiquement aux variations de charge, il est nécessaire d'avoir à disposition des procédures légitimes d'ajout et de suppression de NF, pourtant absentes de l'état de l'art. Ces opérations se limitent généralement à une unique requête d'API et surviennent naturellement lors du démarrage ou de l'arrêt du réseau. Comme redémarrer le cœur empièterait sur la disponibilité du réseau, nous simulons ces procédures au cours de l'exécution, tout en garantissant la continuité du service. La manipulation de l'architecture du CN étant exploitée par certaines attaques [?], la présence de trafic légitime associé à ces opérations constitue une référence nécessaire à leur détection.

1.2.1.5 Transfert de données par l'UPF

Enfin, nous introduisons une seconde procédure absente des travaux de l'état de l'art en générant du trafic utilisateur entre l'UE et le RAN. Le contenu transporté dans le plan utilisateur n'est pas spécifique à la 5G et se situe donc en dehors du périmètre de cette étude. En revanche, son acheminement nécessite l'encapsulation des paquets entre le gNB et l'UPF. Cette encapsulation repose sur le protocole GTP, qui constitue une cible fréquente des attaques décrites dans la littérature [?, ?]. L'inclusion de trafic utilisateur permet ainsi de générer des exemples légitimes d'utilisation de GTP, indispensables à la détection et à l'évaluation des attaques ciblant ce protocole.

Attaque	Source	Surface	Bénins comparables	Dimensions
Scan applicatif des NFs	5GAD [?]	CN	Découverte de NF	Sequentiel / Topologique
Fuzzing d'API	Originale	CN	Tout appel d'API	Sequentiel / Sémantique
Man-in-the-Middle dans le CN	Originale	CN	Gestion de NF	Sequentiel / Topologique
Inondation d'établissement de session	Amponis et al.[?]	SM	Création de session	Sequentiel
Inondation de libération de session	Amponis et al.[?]	SM	Libération de session	Sequentiel
DoS des sessions par modification	Amponis et al.[?]	SM	Modification de session	Sequentiel / Sémantique
Fuzzing du SEID	Originale	SM	Modification de session	Sequentiel
PFCP dans GTP-U	Park et al.[?]	UP	Tout message GTP-U	Sémantique
Usurpation de trafic montant	Trend Micro [?]	UP	Tout message GTP-U	Topologique

Note : CN = cœur de réseau; SM = gestion de session ; UP = plan utilisateur

Table 1.2: Liste des attaques présentes dans le dataset ainsi que leurs caractéristiques.

1.2.2 Trafic anormal

La littérature recense un large éventail d'attaques ciblant les réseaux mobiles et les infrastructures 5G. Comme évoqué dans le chapitre précédent, certaines de ces attaques exploitent des vulnérabilités spécifiques à des implémentations particulières et ne sont pas nécessairement réalistes dans le cas d'une entreprise disposant d'une implémentation robuste et conforme aux spécifications. Néanmoins,

le réel enjeu ici est plutôt que les attaques restent distinguables du trafic normal selon des critères bien définis. Ainsi, en apprenant à détecter des anomalies sur une ou plusieurs des trois dimensions définies précédemment, un modèle peut ensuite être rendu utilisable dans un cadre opérationnel plus réaliste en s'entraînant sur des données réelles. Par ailleurs, étant donné que certaines implémentations open-source sont utilisées dans des réseaux 5G privés, il est également possible que des attaques aussi triviales existent tout de même en pratique. Pour chaque attaque, nous avons identifié de manière explicite dans le Tableau ?? ses dimensions de détection, ainsi que les surfaces d'attaque concernées et les procédures bénignes permettant une comparaison pertinente.

1.2.2.1 Scan applicatif des NFs

Dans les réseaux 5G, les NFs peuvent être instanciées et supprimées dynamiquement. Le NRF maintient un registre des instances actives ainsi que des métadonnées décrivant leurs capacités. Lorsqu'une NF nécessite un service particulier, elle interroge le NRF afin d'identifier les fournisseurs disponibles. 5GAD [?] souligne que, en l'absence de mécanismes d'authentification adéquats, ces requêtes de découverte peuvent être détournées par un attaquant afin de cartographier l'ensemble du CN. Nous implémentons ce scénario en générant une séquence de requêtes de découverte, chacune ciblant aléatoirement un type de NF différent. Ces messages, pris individuellement, sont entièrement bénins. Toutefois, c'est leur enchaînement ainsi que leur origine commune qui peuvent constituer un comportement anormal.

1.2.2.2 Fuzzing d'API

Les réseaux 5G étant conformes aux spécifications 3GPP, les schémas d'API sont publiquement accessibles. Un attaquant peut ainsi disposer d'une connaissance complète des requêtes possibles ainsi que des formats de paramètres d'entrée attendus. Cette accessibilité est renforcée par des travaux récents [?] ayant automatisé l'extraction de ces spécifications et leur mise à disposition dans des formats facilement exploitables. Dans ce contexte, un attaquant peut automatiquement générer des requêtes syntaxiquement valides mais contenant des paramètres falsifiés, susceptibles de provoquer des comportements anormaux selon l'implémentation du parser d'API. Dans notre code, nous sélectionnons aléatoirement des services au sein de plusieurs NFs et faisons varier systématiquement les paramètres associés. Ces messages peuvent être détectés soit individuellement via l'analyse de valeurs incohérentes, soit de manière séquentielle via l'identification de séquences anormales.

1.2.2.3 Man-in-the-Middle dans le CN

En l'absence de mécanismes d'authentification suffisants, un attaquant ayant accès au cœur de réseau peut enregistrer des NFs malveillantes de tout type. Lorsqu'une

fonction malveillante se déclare comme fournisseur d'un service donné, elle apparaît alors dans les résultats de découverte au même titre que les instances légitimes. Dans le cas de free5GC, lorsqu'une fonction réseau doit sélectionner un fournisseur parmi plusieurs candidats, elle privilégie généralement celui ayant été enregistré le plus anciennement. Un attaquant peut exploiter ce comportement en supprimant puis en ré-enregistrant les NFs légitimes, de manière à faire apparaître sa fonction malveillante comme la plus ancienne. Cette manipulation lui permet de s'interposer dans les échanges et de rediriger le trafic sans interruption de service. On distingue alors deux phases dans ce scénario. La première correspond à la phase d'établissement, qui se caractérise par des séries de procédures anormales. La seconde phase correspond à la redirection du trafic légitime, dans laquelle l'anomalie réside dans les interactions topologiques observées au sein du réseau.

1.2.2.4 Inondation d'établissement de session

Comme proposé par Amponis et al. [?], une attaque possible est de cibler l'UPF et de lui envoyer un grand nombre de requêtes de création de session. L'objectif est de saturer ses ressources de calcul et de mémoire, entraînant un ralentissement des autres requêtes légitimes. Dans notre implémentation, nous générons des séquences de requêtes de création de session avec des valeurs de Identifiant de Session (SEID) et de Identifiant de Tunnel (TEID) aléatoires. Dans ce contexte, les messages produits sont sémantiquement identiques aux messages légitimes et seule leur séquence permet de les distinguer du trafic normal.

1.2.2.5 Inondation de libération de session

Dans cette attaque, Amponis et al. [?] proposent de rompre les sessions établies entre l'UE et le réseau de données en envoyant des requêtes de libération. L'attaquant peut cibler un UE spécifique s'il connaît son SEID, ou bien effectuer une attaque par saturation en variant les identifiants afin de déconnecter un grand nombre d'UE. Dans notre implémentation, nous adoptons une stratégie similaire à celle de l'inondation d'établissement de session, en variant systématiquement les SEIDs. Cette attaque présente de fortes similarités avec la précédente et est donc également détectable principalement sur la dimension séquentielle.

1.2.2.6 DoS des sessions par modification

Amponis et al. [?] décrivent également des attaques reposant sur la modification des Forwarding Action Rule (FAR) afin de perturber discrètement l'accès au plan de données. Une première variante consiste à remplacer l'action de transfert (*forward*) par une action de suppression (*drop*), conduisant l'UPF à éliminer silencieusement les paquets associés à une session ciblée, sans qu'aucune notification ne soit transmise à l'UE. Une seconde variante repose sur la modification de la FAR afin de dupliquer les paquets au lieu de simplement les transférer. Cette duplication peut être utilisée à des fins d'écoute passive ou pour amplifier du DoS. Ces attaques

peuvent être détectées à la fois par leur fréquence anormale et par leur contenu, qui comporte des champs ou des configurations inhabituels, absents des requêtes légitimes de modification de session.

1.2.2.7 Fuzzing de SEID

Les attaques de libération et de DoS de sessions supposent l'existence d'une session valide dont le SEID est connu. En l'absence de connaissance d'un SEID valide, un attaquant peut tenter d'exécuter son attaque en testant successivement différents SEID jusqu'à obtenir un résultat concluant. Toutefois, dans le cas des DoS par modification, cette approche peut être détectée à la fois sur les dimensions sémantique et séquentielle. Dans le cas d'attaques par libération de session, dès qu'un SEID valide est identifié, la session associée est supprimée, ce qui empêche toute réutilisation ultérieure de cet identifiant. Afin de discrètement identifier des SEID actifs, un attaquant peut exploiter le comportement des requêtes de modification de session, qui produisent une réponse positive lorsque le SEID existe et une réponse négative dans le cas contraire, même lorsque la requête n'entraîne aucune modification effective de l'état de la session (par exemple lorsque les paramètres demandés correspondent déjà à l'état courant). L'attaquant peut ainsi envoyer un grand nombre de requêtes de modification bénignes, sémantiquement correctes et sans effet, et observer les réponses obtenues. De cette manière, il est possible d'extraire une liste de SEID actifs tout en restant détectable uniquement via la dimension séquentielle.

1.2.2.8 PFCP dans GTP-U

Park et al. [?] présentent une vulnérabilité liée au processus de décapsulation de l'UPF. Lorsqu'un utilisateur envoie des données vers le réseau de données, celles-ci sont encapsulées dans un paquet GTP-U traversant l'UPF. Celui-ci décapsule le paquet et le redirige vers sa destination. Toutefois, certaines implémentations, telles que free5GC, ne vérifient pas la nature du protocole encapsulé et le traitent de manière transparente. Il devient alors possible d'injecter des messages PFCP dans un tunnel GTP-U. Dans notre cas, nous encapsulons un unique message de suppression de session PFCP dans un paquet GTP-U. Ce type d'encapsulation n'est pas prévu par les spécifications, ce qui rend l'anomalie détectable sur la dimension sémantique.

1.2.2.9 Usurpation d'utilisateur

TrendMicro [?] met en évidence une vulnérabilité de type réflexion de paquets dans le protocole GTP-U. En l'absence de validation appropriée, un attaquant ayant accès à l'UPF peut envoyer depuis ce dernier un paquet GTP-U encapsulant un paquet IP falsifié contenant l'adresse d'un UE légitime. Une fois désencapsulé, ce paquet est relayé vers l'Internet, permettant à l'attaquant d'usurper l'identité de l'UE. Celui-ci peut alors émettre des requêtes en se faisant passer pour l'utilisateur

légitime et réaliser des actions en son nom. Par exemple, un comportement malveillant répété pourrait conduire certains services à bloquer l'adresse IP associée à cet utilisateur, sans que celui-ci en soit responsable. Son identification repose principalement sur l'analyse de la dimension topologique, en mettant en évidence des incohérences dans les interactions observées entre les différentes entités du réseau.

1.2.3 Méthodologie de génération

Afin de limiter les biais, nous présentons dans cette section les choix méthodologiques ainsi que les mesures mises en œuvre afin de garantir la qualité, la représentativité et la cohérence du dataset généré.

1.2.3.1 Longueur des attaques par répétition

Dans le trafic anormal, certaines attaques reposent sur l'émission d'un unique message malveillant, tandis que d'autres nécessitent la transmission d'un grand nombre de paquets successifs. Pour ces dernières, le nombre de répétitions a été fixé à 100 messages. En pratique, un attaquant pourrait facilement transmettre un nombre bien plus important de paquets lors d'une attaque par inondation. Toutefois, limiter chaque instance d'attaque à 100 messages permet d'éviter que les scénarios d'inondation ne dominent de manière disproportionnée le dataset, tout en conservant les caractéristiques essentielles de ce type d'attaque.

Cette valeur est considérée comme suffisamment élevée, car dans des conditions normales d'utilisation d'un réseau 5G, des séquences de plus de trois ou quatre messages quasi identiques consécutifs sont très rares. Ainsi, un modèle capable de détecter le comportement anormal généré par 100 messages malveillants consécutifs devrait naturellement être en mesure de se généraliser à des attaques par inondation de plus grande ampleur. Enfin, puisque ces traces d'attaque sont utilisées exclusivement pour l'évaluation, le fait de fixer ce nombre de répétitions ne peut pas introduire de biais dans l'apprentissage.

1.2.3.2 Préservation du contexte temporel

La plupart des datasets 5G existants séparent le trafic bénin et le trafic malveillant en les plaçant dans des intervalles temporels distincts. Cette approche est explicitement critiquée par Flood et al. [?], car elle empêche la conservation d'un contexte séquentiel pertinent et favorise l'apparition d'un sur-apprentissage basé sur les périodes plutôt que sur le contenu des échanges. Afin de reproduire des séquences plus réalistes, nous adoptons une approche similaire à celle proposée par 5GCCGuard [?], consistant à entrelacer le trafic malveillant avec une activité bénigne de fond pendant l'exécution des attaques. Pour ce faire, nous exécutons en parallèle un script générant des procédures bénignes et un autre dédié aux procédures malveillantes. Dans chaque cas, les procédures sont sélectionnées aléatoirement parmi l'ensemble de celles que nous avons implémentées.

1.2.3.3 Préservation du contexte d'identité

Une autre approche couramment utilisée pour distinguer le trafic bénin du trafic malveillant consiste à s'appuyer sur des identités, telles que l'adresse IP. Cette pratique est fréquente dans les datasets d'IDS, les adresses étant généralement anonymisées a posteriori afin de préserver la confidentialité des utilisateurs. Dans notre cas, le dataset étant entièrement synthétique, il n'est pas soumis à ces contraintes. Nous conservons donc les adresses IP, qui sont essentielles pour la détection des anomalies de nature topologique.

Toutefois, l'utilisation d'une adresse IP fixe pour l'attaquant peut conduire un modèle à sur-apprendre cette caractéristique et à identifier un attaquant uniquement à partir de son adresse. Afin d'éviter ce biais, nous faisons en sorte que l'adresse source associée aux messages d'attaque corresponde à celle d'une NF légitime choisie aléatoirement au sein du CN. Cette configuration peut par exemple simuler la compromission d'une fonction réseau légitime. Afin de conserver un contexte topologique cohérent, nous garantissons toutefois que l'ensemble des messages appartenant à une même procédure d'attaque partagent la même adresse de fonction réseau d'origine.




Figure 1.2: Processus de labellisation préservant les contextes temporels et topologiques grâce à l'utilisation de marqueurs.

1.2.3.4 Labelisation du dataset

Afin d'attribuer une adresse IP cohérente à l'ensemble des paquets appartenant à une même procédure, il est nécessaire d'identifier, pour chaque paquet, à quelle procédure il appartient. Dans cette optique, les attaques sont initialement générées à partir d'une même machine source. Au lancement de chaque procédure, qu'elle soit bénigne ou malveillante, des marqueurs sont injectés sous la forme de paquets UDP temporaires contenant le nom de la procédure.

Ces marqueurs permettent de délimiter automatiquement les frontières temporelles de chaque procédure et de restreindre la modification des adresses source aux seuls paquets situés entre ces bornes. Il est ainsi possible de modifier a posteriori l'ensemble des adresses IP comprises entre deux marqueurs de manière cohérente. Par ailleurs, cette approche permet de générer, en parallèle, une table

de correspondance reliant les identifiants des paquets aux noms des procédures associées. Ce processus est illustré sur la figure ??.

Bénin			Attaque		
Nom	Procédures	Paquets	Nom	Procédures	Paquets
Enregistrement d'UE	591	467,638	Fuzzing d'API	107	33,308
Redémarrage de session	562	379,181	MITM dans le CN	123	22,587
Trafic utilisateur	317	159,228	Fuzzing de SEID	116	23,858
Libération de contexte	288	67,124	Inondation d'établissement	113	23,949
Réveil par envoi	137	55,599	Inondation de libération	98	20,446
Deregister UE	276	50,279	Scan applicatif	81	4,997
Réveil par reception	279	21,884	Modification : Duplication	119	345
Ajout de NF	261	18,232	Modification : Suppression	100	292
Suppression de NF	253	16,336	Usurpation d'utilisateur	102	102
			PFCP dans GTP-U	101	101
Total	2 265	1 235 501	Total	1 060	129 985

Table 1.3: Nombre de procédures et de paquets pour les scénarios bénins et d'attaque, classés par volume de paquets.

1.2.4 Environnement et implémentation

Les implémentations commerciales de la 5G n'étant pas librement accessibles, nous nous appuyons sur des projets open-source afin de simuler des déploiements réalistes. Plus précisément, nous utilisons *free5GC* [?] pour émuler le CN, ainsi que *UERANSIM* [?] pour simuler les UEs et les gNBs du réseau d'accès. Ces outils ont été retenus en raison de leur large adoption au sein de la communauté scientifique et de leur utilisation fréquente dans les travaux de génération de données 5G.

Bien que *free5GC* et *UERANSIM* puissent être exécutés directement sous forme de binaires, nous avons choisi de les déployer via Docker, au moyen du projet *free5gc-compose* [?]. L'utilisation de la conteneurisation permet de disposer d'environnements préconfigurés pour l'ensemble des composants, ce qui simplifie le déploiement et améliore la reproductibilité des expériences.

Nous avons également apporté plusieurs modifications à cette architecture basée sur Docker. Tout d'abord, les adresses IP des fonctions réseau ont été fixées, la configuration par défaut reposant sur une attribution dynamique à chaque déploiement. De plus, un nouveau conteneur nommé *NF_EVIL* a été ajouté afin d'exécuter les scénarios d'attaque. Par ailleurs, nous avons modifié le Dockerfile de *UERANSIM* afin d'utiliser notre propre fork, la version originale présentant une défaillance affectant le mécanisme de libération du contexte UE, la rendant inutilisable pour nos expérimentations. La version corrigée est disponible dans notre dépôt GitHub [?].

Le dataset d'apprentissage est constitué exclusivement de trafic bénin, généré sur

une période de 15 heures, correspondant à environ 10 000 procédures individuelles. Le dataset d'évaluation, quant à lui, a été produit en exécutant simultanément du trafic bénin et des scénarios d'attaque pendant 4 heures. Les volumes de trafic générés sont indiqués dans le tableau ??.

Les volumes de trafic associés aux attaques présentent une forte hétérogénéité. Celle-ci reflète la distinction entre les attaques fondées sur la répétition de messages, qui génèrent un trafic conséquent, et les attaques sémantiques, dont l'exécution repose généralement sur un nombre restreint de requêtes, voire sur une seule interaction.

1.3 Evaluation des caractéristiques du dataset

Nous avons présenté dans les sections précédentes les différents objectifs de qualité retenus pour la conception de notre dataset, ainsi que la méthodologie mise en œuvre pour les satisfaire. Les procédures bénignes associées à chaque attaque ont été présentées dans le Tableau ??. L'objectif de cette section est de vérifier que les attaques incluses dans le dataset ne peuvent être distinguées du trafic légitime associé qu'à travers les dimensions pour lesquelles elles ont été conçues.




Figure 1.3: Proportion de messages bénins sémantiquement identiques à des messages d'attaque de même nature.

1.3.1 Caractérisation sémantique

Afin d'évaluer si les attaques sémantiques sont les seules susceptibles d'être détectées sur cette dimension, nous utilisons la distance de Jaccard. La distance de Jaccard est une métrique permettant de mesurer la similarité entre deux ensembles de caractéristiques. Elle est notamment utilisée dans l'analyse de similarité de contenus textuels, par exemple pour comparer des courriels de phishing [?]. Dans notre cas, nous l'utilisons afin d'évaluer si les attaques sémantiques sont les seules susceptibles

d'être détectées sur cette dimension. Les champs protocolaires présents dans chaque paquet d'attaque sont représentés sous forme d'un ensemble de caractéristiques, puis comparés aux ensembles extraits des paquets bénins de nature comparable. Une distance nulle indique que les deux messages partagent exactement les mêmes champs protocolaires et sont donc considérés comme sémantiquement équivalents.

Néanmoins, un même type de message bénin peut présenter plusieurs variations sémantiques. Par exemple, une requête légitime de découverte peut contenir plus ou moins d'informations selon le contexte dans lequel elle est émise. Ainsi, une attaque n'a pas nécessairement besoin d'être identique à l'ensemble du trafic bénin pour être considérée comme potentiellement connue par le modèle. Il suffit en effet qu'au moins un message bénin équivalent présente une distance de Jaccard nulle avec le message d'attaque pour que celui-ci ait pu être observé lors de l'apprentissage. Dans ce cas, il ne devrait pas être détecté sur la seule dimension sémantique.

Nous mesurons donc, pour chaque message généré par une procédure d'attaque, la proportion de messages bénins présentant une distance de Jaccard nulle avec celui-ci. La Figure ?? présente les résultats obtenus. Nous observons que seules les attaques considérées comme sémantiques, à savoir l'injection de messages PFCP dans GTP-U et la modification de session, ne disposent d'aucun équivalent bénin strictement identique.

L'attaque par fuzzing d'API constitue un cas particulier et n'est pas incluse dans cette analyse globale. En effet, elle génère des messages sémantiquement différents selon les endpoints sollicités, ce qui nécessite une étude spécifique de leurs caractéristiques. En calculant la distance de Jaccard pour chaque type d'appel d'API indépendamment, nous constatons que 93% des messages générés par cette attaque ne possèdent aucun équivalent sémantiquement identique dans le trafic bénin. Les 7% restants correspondent à des requêtes plausibles, dont la détection repose alors davantage sur leur contexte temporel ou comportemental que sur leur seule structure sémantique.




Figure 1.4: Distribution des messages issues de procédures d'attaques et bénignes en fonction du temps.

1.3.2 Caractérisation séquentielle

Nous avons vu dans les sections précédentes que nous cherchions à limiter les biais temporels en introduisant du bruit de fond durant les phases d'attaque et en randomisant l'ordre d'exécution des événements. La Figure ?? met en évidence que, lors de l'exécution d'une attaque, du trafic bénin est systématiquement présent en parallèle, ce qui empêche toute isolation temporelle simple de l'attaque. Cette figure illustre également les différences de longueurs de séquences selon les types d'attaques. Les attaques non fondées sur la répétition apparaissent en très faible quantité, car elles reposent généralement sur un nombre réduit de paquets.

Il existe néanmoins quelques cas particuliers qu'il convient de détailler ici. Bien que les attaques de type scan applicatif soient généralement détectables sur la dimension temporelle, elles génèrent un volume relativement faible sur les graphiques observés. Cela s'explique par le fait que, bien qu'elles reposent sur un principe de répétition, elles n'ont pas besoin de produire un grand nombre de requêtes pour être efficaces.

À l'inverse, l'attaque de type MITM génère un nombre important de paquets bien qu'elle ne soit pas fondée sur la répétition. En effet, si sa phase d'initialisation nécessite un faible nombre de messages, l'ensemble des paquets relayés par la suite est systématiquement annoté comme anomalie. Le fait de considérer les paquets redirigés comme appartenant à la procédure MITM conduit ainsi à une augmentation artificielle du volume de messages associés à cette attaque. Toutefois, comme il s'agit essentiellement d'une redirection de trafic légitime, les séquences restent structurellement similaires à du trafic bénin et ne peuvent être discriminées qu'en analysant les identités et la topologie des échanges. La longueur des séquences associées au MITM est par ailleurs fortement variable, car elle dépend à la fois de la fonction usurpée et de l'intensité avec laquelle celle-ci est sollicitée par le trafic bénin durant la prise de contrôle.

Le dernier cas particulier concerne le fuzzing applicatif. Celui-ci constitue une attaque reposant sur la répétition, générant typiquement de l'ordre d'une centaine de messages par exécution. Cependant, la figure montre que ces messages présentent moins de pics temporels marqués que les autres attaques séquentielles et sont, au contraire, davantage dispersés dans le temps. Ce comportement s'explique par le fait que certaines exécutions de fuzzing peuvent être relativement longues et s'étendre sur plusieurs minutes, en fonction du temps de réponse des NF.

1.3.3 Caractérisation topologique

La dernière dimension d'attaques que l'on veut vérifier est la dimension topologique. L'objectif ici est de vérifier que les motifs théoriques caractérisant ces attaques apparaissent effectivement dans le dataset. Ces motifs sont illustrés sur la Figure ?? et ne peuvent pas se produire dans un trafic normal d'un réseau respectant la spécification 3GPP. Afin de dénombrer ces occurrences, nous avons transformé les paquets du dataset en graphes, puis recherché dans ces graphes les motifs suivants.




Figure 1.5: Schéma d'interactions : (a) MITM dans le CN (b) Usurpation d'utilisateur.

Dans le cas du MITM, nous avons identifié un motif de redirection durant sa phase opérationnelle, dans lequel le récepteur d'une requête API redirige la même requête vers un autre NF. Le nombre d'occurrences de ce motif dépend directement du volume de trafic bénin sollicitant le MITM. Étant donné que ce trafic est généralement important, nous observons ainsi de l'ordre de 4500 occurrences de ce motif, ce qui dépasse largement le nombre d'exécutions distinctes de la procédure MITM.

Pour l'attaque d'usurpation d'utilisateur, nous avons recherché une requête GTP-U dont l'adresse IP source dans l'en-tête IP externe diffère de l'adresse IP de destination de la réponse correspondante. Afin de garantir qu'il s'agit bien d'une réponse, nous vérifions également la cohérence des adresses IP internes. La recherche de ce motif ne permet d'identifier que 72 occurrences, soit 20 de moins que le nombre d'exécutions de la procédure de spoofing. Cet écart est attendu, dans la mesure où des pertes de paquets peuvent être observées lors des requêtes adressées au service web sollicité.

1.3.4 Synthèse

Nous avons vérifié dans cette section que, pour chacune des attaques de notre dataset, la discriminabilité n'est possible qu'au regard des dimensions que nous avons définies. Nous obtenons ainsi un dataset dans lequel le risque de biais a été réduit autant que possible et que nous pourrions utiliser pendant l'entraînement et l'évaluation de nos modèles, dont les expérimentations sont détaillées dans la section suivante.

1.4 Evaluation des modèles de détection

La contribution principale de cette thèse est de proposer un formalisme permettant de représenter de manière explicite les interactions au sein d'un réseau 5G et de détecter les nouvelles anomalies liées à sa nature fortement logicielisée. La conception de nouveaux modèles de GNN constitue un domaine de recherche à part

entière et ne relève pas de l’objectif de cette thèse. Nous nous appuyons donc sur des modèles existants de l’état de l’art afin d’évaluer la pertinence du formalisme proposé et de vérifier qu’il permet d’obtenir des résultats encourageants.

Afin de comparer ces modèles de manière rigoureuse, il est nécessaire de les évaluer dans un cadre expérimental unifié, de manière à éviter les biais pouvant être introduits par des différences d’implémentation ou de protocole expérimental. Pour cette raison, nous nous appuyons sur DyGLib, la bibliothèque proposée par Yu et al. [?], qui fournit un environnement unifié et bien établi regroupant plusieurs des modèles de l’état de l’art présenté dans la section 3.4.2.2. Parmi ceux retenus figurent CAWN, DyGFormer, TCL et GraphMixer, qui couvrent différentes approches légères d’encodage temporel, ainsi que les modèles DyRep, JODIE et TGN qui représentent les approches plus complexes de voisinage temporel avec un module de mémoire.

Comme présenté dans la section 3.4.5, notre problématique se distingue des scénarios classiquement considérés dans la littérature. Afin de mieux répondre à nos besoins, plusieurs adaptations ont été apportées à la bibliothèque. Ces modifications concernent notamment la prise en compte des informations temporelles associées aux événements ainsi que la gestion des parcours multi-sauts. Ces changements ont été implémentés sous la forme d’un fork de DyGLib, disponible à l’adresse indiquée dans [?].

L’utilisation de DyGLib nous permet ainsi non seulement de comparer la performance de notre formalisme dans différents modèles dans un cadre homogène, mais également d’évaluer leurs performances des méthodes supervisées et non supervisées. Nous étudierons également l’impact des différentes variantes de NLP présentées précédemment. Les résultats de ces expérimentations sont présentés dans les sections suivantes.

1.4.1 Métriques de classification

Afin d’évaluer les performances des modèles de détection, nous utilisons des métriques standards de classification permettant de quantifier leur capacité à distinguer les comportements normaux des comportements anormaux.

Dans notre cas, une distinction doit être faite entre les deux types de modèles considérés. Les modèles de prédiction de liens produisent directement un score de probabilité compris entre 0 et 1. Les autoencodeurs produisent quant à eux un score d’anomalie non borné, que l’on transforme dans l’intervalle $[0, 1]$ à l’aide d’une fonction sigmoïde. Dans les deux cas, une valeur proche de 0 correspond à un comportement bénin, tandis qu’une valeur proche de 1 correspond à un comportement anormal.

Les scores obtenus sont ensuite comparés au label de vérité afin de déterminer, pour un seuil de classification donné, les cas où le modèle effectue une prédiction correcte ou incorrecte. Ces résultats permettent de calculer différentes métriques de classification.

Le **taux de vrais positifs** (TVP) mesure la proportion d’anomalies

correctement détectées parmi l'ensemble des instances d'attaques :

$$\text{TVP} = \frac{VraisPositifs}{VraisPositifs + FauxNégatifs}$$

Le **taux de faux positifs** (TFP) quantifie la proportion de bénins incorrectement classés comme anormaux :

$$\text{TFP} = \frac{FauxPositifs}{FauxPositifs + VraisNégatifs}$$

Ces métriques sont directement liées à leurs contreparties, le **taux de faux négatifs** (TFN) qui correspond aux attaques non détectées et le **taux de vrais négatifs** (TVN) qui mesure la proportion de bénins correctement classées. On observe ainsi les relations complémentaires suivantes :

$$\text{TVP} = 1 - \text{TFN} \quad \text{et} \quad \text{TVN} = 1 - \text{TFP}$$

Dans notre cas, l'objectif est de maximiser le TVP et de minimiser le TFP. Les autres métriques (TFN et TVN) étant complémentaires, elles ne sont pas utilisées directement dans l'analyse, puisque leurs valeurs peuvent être déduites respectivement à partir du TVP et du TFP.

1.4.2 Courbe ROC

Les taux présentés précédemment dépendent du seuil de classification choisi. Or, le choix d'un seuil arbitraire peut influencer directement les performances mesurées. Afin d'évaluer les capacités de discrimination d'un modèle indépendamment d'un seuil particulier, il est courant d'utiliser une courbe Receiver Operating Characteristic (ROC). Cette courbe représente le TVP en fonction du TFP pour l'ensemble des seuils de classification possibles. Chaque point de la courbe correspond ainsi à un seuil donné et représente le compromis entre la capacité du modèle à détecter les anomalies et sa tendance à générer de fausses alertes.

Une courbe ROC idéale monte rapidement vers le coin supérieur gauche du graphique. Cela signifie que le modèle est capable de détecter une grande proportion des anomalies (TVP élevé) tout en générant peu de fausses alertes (TFP faible). À l'inverse, une courbe proche de la diagonale reliant le coin inférieur gauche au coin supérieur droit indique que le modèle ne discrimine pas mieux les classes qu'un tirage aléatoire.

Afin de résumer les performances d'un modèle par une seule valeur, on calcule généralement l'aire sous la courbe ROC, Area Under the Curve (AUC). Une AUC égale à 0,5 correspond à un classifieur aléatoire, tandis qu'une AUC de 1 indique une séparation parfaite entre les observations normales et les anomalies. En pratique, plus l'AUC est élevée, meilleures sont les capacités de discrimination du modèle.




Figure 1.6: Exemple de courbe ROC.

1.4.3 Approche supervisée




Figure 1.7: Représentation du processus d'apprentissage supervisé.

Parmi les différentes familles d'apprentissage considérées dans cette étude figurent l'apprentissage supervisé et l'apprentissage non supervisé. La première approche étudiée est l'apprentissage supervisé, dont l'objectif est d'entraîner un modèle à partir d'un ensemble de données d'apprentissage contenant des exemples annotés, c'est-à-dire associés à une classe connue. Le modèle apprend ainsi à estimer la probabilité d'existence des arcs dans le graphe à partir des caractéristiques des nœuds et des interactions observées durant la phase d'apprentissage. Une représentation du processus d'apprentissage supervisé est présentée sur la figure ??.

Comme présenté dans la section 3.5.1, la principale limite de cette approche est qu'elle permet principalement de détecter des attaques déjà observées ou des variantes proches de celles présentes dans les données d'entraînement. Cependant, dans notre cas, la connaissance préalable des paramètres à analyser permet de sélectionner un sous-ensemble pertinent de caractéristiques et de les encoder à l'aide d'un one-hot encoder. Cette réduction de l'espace de représentation permet de diminuer la complexité du problème et d'obtenir de meilleures performances.

Par ailleurs, la détection d'attaques connues reste une tâche pertinente dans un contexte opérationnel. Grâce au formalisme proposé, les décisions du modèle restent interprétables, ce qui facilite l'analyse des alertes générées. De plus, ce

type de modèle peut être réentraîné régulièrement afin d'intégrer de nouveaux comportements malveillants ou des évolutions de l'infrastructure.




Figure 1.8: Courbes ROC pour les différents modèles de prédiction de lien supervisés.

La figure ?? présente les résultats obtenus par les différents modèles. Parmi les approches évaluées, TGN obtient les meilleures performances avec une AUC de 0.95. Ces métriques sont relativement bonnes mais doivent être interprétées avec précaution dans un contexte de détection d'attaques. En effet, sur un volume important de données, un faible taux de faux positifs peut tout de même générer un nombre conséquent d'alertes nécessitant une analyse humaine. De la même manière, le fait de ne pas détecter tous les vrais positifs représente un risque important puisqu'ils correspondent à des attaques non détectées pouvant avoir un impact sur l'infrastructure. Néanmoins, même si les performances actuelles ne sont pas encore suffisantes pour une utilisation opérationnelle directe, ces résultats montrent que le formalisme proposé et son exploitation par des modèles d'apprentissage supervisé sont pertinents.

Le tableau ?? compare les performances des différents modèles ainsi que leur temps d'exécution. On observe que TGN, qui présente les meilleures performances de détection, est également le modèle ayant le débit d'exécution le plus faible, avec

Métrique	JODIE	DyRep	CAWN	DyGFormer	TCL	GraphMixer	TGN
AUC	0.5321	0.5299	0.6187	0.6741	0.5788	0.7411	<u>0.9517</u>
Paquets/s	90.63	41.20	138.43	<u>855.73</u>	151.64	76.23	22.79

Table 1.4: Temps d'exécution par paquet et AUC pour les différents modèles étudiés.

environ 23 paquets par seconde, soit près de 38 fois moins que DyGFormer, le modèle le plus rapide. Cependant, sur notre jeu de données de test, composé de 523 000 paquets générés en 5 heures, le flux moyen est d'environ 29 paquets par seconde. Dans ce contexte, TGN n'est donc pas encore capable de traiter le flux en temps réel, mais l'écart reste relativement faible. De plus, la principale cause de cette lenteur semble liée à l'implémentation de la librairie DyGLib, qui n'est pas prévue pour être optimisée et réalise des allocations mémoire inefficaces. Il serait donc possible d'améliorer significativement le temps d'exécution, soit en optimisant le code, soit en simplifiant le modèle.

Pour résumer, les résultats de TGN sont très encourageants et pourront être améliorés dans le futur, tant au niveau de la vitesse d'exécution que des performances, par exemple via l'ajustement des hyperparamètres, des modifications d'architecture ou des optimisations d'implémentation.

1.4.4 Approche non supervisée




Figure 1.9: Représentation du processus d'apprentissage non supervisé. La première ligne correspond à une tâche de prédiction de lien avec des arcs négatifs artificiels, tandis que la seconde ligne correspond à une tâche de reconstruction.

Cette section s'intéresse aux approches non supervisées, dont l'objectif est de permettre au modèle d'exploiter des informations issues de l'ensemble des paramètres des paquets en entrée, sans recourir à des étiquettes préalablement définies.

Comme présenté en section 3.4.2.3, deux principales familles de méthodes non supervisées sont considérées dans la littérature. La première repose sur la prédiction de liens, analogue à certaines approches supervisées, dans laquelle le modèle est

exposé à un ensemble d'arcs considérés comme valides ainsi qu'à des arcs négatifs, qu'il doit apprendre à distinguer. Néanmoins, en l'absence d'exemples d'attaques dans les datasets d'entraînement, des liens artificiellement négatifs sont générés. Ceux-ci sont construits en reliant des attributs initialement non connectés, tout en respectant la structure bipartite du graphe. La seconde approche repose sur des méthodes de reconstruction, dans lesquelles un graphe est fourni en entrée et le modèle est entraîné à en reconstruire la structure ou les attributs associés. Ces deux différentes approches sont représentées sur la figure ??.

1.4.4.1 Comparaison des méthodes d'encodage

Quelque soit l'approche, une étape d'encodage est nécessaire afin de transformer les différents paramètres disponibles en représentations vectorielles de dimension finie, en s'appuyant sur des techniques issues du NLP. Parmi les architectures étudiées dans la section 3.5.1, nous retenons les méthodes FastText et BERT qui permettent de capturer des informations contextuelles au sein des séquences textuelles. FastText offre une solution plus légère et rapide, tandis que BERT est généralement plus expressif et performant, au prix d'une complexité computationnelle plus élevée.

Cependant, l'un des objectifs de cette étude est de proposer une méthode de détection utilisable dans des temps compatibles avec un contexte opérationnel. Il est donc nécessaire d'évaluer le surcoût induit par les différentes méthodes d'encodage.

Pour cela, nous avons réalisé une étude expérimentale consistant à mesurer le temps nécessaire à l'encodage d'un paquet de notre dataset. L'attention est principalement portée sur les modèles de la famille BERT, dont le coût d'inférence est susceptible d'être le plus élevé. Plusieurs variantes légères de cette architecture sont ainsi comparées afin de déterminer si certaines offrent un compromis satisfaisant entre qualité de représentation et temps d'encodage. Les performances de ces modèles sont ensuite comparées à celles de FastText, qui constitue la solution de référence en termes de rapidité. Les résultats sont présentés sur le tableau ??.

Méthode d'encodage	Temps d'encodage (s/paquet)
One-hot	4.5×10^{-4}
FastText	5.1×10^{-4}
DistilBERT	1.2
ALBERT	2.4
BERT	4.2

Table 1.5: Comparaison des surcoûts temporels induits par les différentes méthodes d'encodage considérées.

On observe que les temps d'exécution associés aux méthodes basées sur BERT sont de l'ordre de plusieurs secondes par paquet, tandis que les approches FastText et *one-hot* restent inférieures à la milliseconde. Les performances mesurées pour BERT sont en partie liées à l'implémentation utilisée et pourraient potentiellement

être optimisés. Néanmoins, le coût computationnel reste significativement plus élevé que celui des autres méthodes évaluées.

Compte tenu de ce surcoût temporel important, les approches basées sur BERT ont été écartées pour la suite de cette étude. Nous avons ainsi choisi de nous concentrer sur FastText, qui offre un compromis plus adapté entre richesse des représentations et temps d'exécution.

1.4.4.2 Prédiction de lien

Pour la prédiction de lien, l'approche suivie est similaire à celle utilisée dans le cadre non supervisé. Cependant, contrairement à l'apprentissage supervisé où le modèle est entraîné sur des données bénignes et des attaques explicitement labélisées, l'apprentissage repose uniquement sur des données bénignes ainsi que sur des arcs négatifs artificiellement générés. Lors de la phase d'évaluation, le modèle est ensuite confronté à la fois à des interactions bénignes et à des interactions issues d'attaques afin d'évaluer sa capacité à identifier des comportements malveillants à partir des écarts par rapport aux interactions normales apprises.




Figure 1.10: Courbes ROC pour les différents modèles de prédiction de lien non supervisés.

La figure ?? présente les résultats obtenus par les différents modèles. On

constate que, quel que soit le modèle considéré, les valeurs du TVP et du TFP sont généralement proches de 0,5, ce qui correspond à des performances comparables à celles d'un classifieur aléatoire. Ces résultats suggèrent que les modèles n'ont pas appris de représentation permettant de distinguer efficacement les comportements normaux des comportements anormaux.

Contrairement à l'apprentissage supervisé, les modèles de prédiction de liens disposent ici de beaucoup moins d'informations lors de la phase d'entraînement. Ils sont ainsi davantage susceptibles d'être influencés par les biais introduits lors de la construction des arcs négatifs, dont la stratégie de sélection peut avoir un impact important sur les performances. De plus, l'utilisation d'un encodage fondé sur des techniques issues du NLP constitue une source d'incertitude supplémentaire, notamment lorsque les représentations obtenues ne capturent pas correctement la sémantique des interactions étudiées.

1.4.4.3 Reconstruction

Pour l'approche par reconstruction, on compare directement le vecteur reconstruit au vecteur original afin de calculer une erreur de reconstruction. Cette erreur est ensuite utilisée comme score d'anomalie et les observations présentant une erreur élevée sont considérées comme potentiellement anormales.

Dans notre cas, nous utilisons l'erreur quadratique moyenne Mean Squared Error (MSE) comme métrique de reconstruction. Elle correspond à la moyenne des écarts quadratiques entre chaque dimension du vecteur d'entrée et sa reconstruction :

$$MSE(x, x') = \frac{1}{n} \sum_{i=1}^n (x_i - x'_i)^2$$

où (x) représente le vecteur d'entrée, (x') sa reconstruction par l'autoencodeur et (n) la dimension du vecteur. Cette métrique pénalise fortement les grandes erreurs de reconstruction, ce qui la rend adaptée pour identifier des observations dont la représentation diffère significativement de celles utilisées lors de l'apprentissage.

Les performances obtenues pour les différents modèles sont présentées sous forme de courbes ROC sur la figure ??.

Les résultats obtenus sont meilleurs que ceux observés pour la prédiction de liens, mais restent néanmoins perfectibles, avec des valeurs d'AUC généralement proches, voire inférieures, à 0,7. Ces résultats montrent que les modèles commencent à distinguer les observations normales des anomalies, mais que leur capacité de discrimination reste insuffisante pour une détection fiable. Cette performance est toutefois à mettre en perspective avec le caractère non supervisé de l'approche, qui dispose de moins d'informations lors de l'apprentissage que les modèles supervisés.

Plusieurs pistes pourraient être explorées afin d'améliorer ces résultats. Tout d'abord, l'encodage des données constitue un axe d'amélioration important. L'approche actuelle repose sur FastText, dont les représentations restent relativement simples. L'autoencodeur peut ainsi apprendre une représentation trop générale ou peu discriminante des données, lui permettant de reconstruire




Figure 1.11: Courbes ROC pour les différents modèles d'autoencodeurs non supervisés.

correctement aussi bien les observations normales que les anomalies. Une représentation plus riche pourrait donc permettre de mieux caractériser les comportements normaux et, par conséquent, d'augmenter l'erreur de reconstruction associée aux anomalies. Il serait cependant nécessaire de trouver un compromis entre la qualité des représentations produites et leur coût computationnel. Des modèles de NLP plus complexes, tels que BERT, ont notamment été écartés en raison de leur temps d'exécution trop important pour notre configuration.

Par ailleurs, les modèles proposés par DyGLib n'étant pas initialement conçus pour être utilisés comme autoencodeurs, le choix de l'architecture et des paramètres d'apprentissage pourrait également limiter leurs performances. Le choix de la fonction de coût ainsi que la définition de la tâche de reconstruction pourraient notamment être étudiés afin de favoriser l'apprentissage d'une représentation davantage spécifique aux comportements normaux.

Néanmoins, l'approche fondée sur la reconstruction semble plus prometteuse que la prédiction de liens dans le cadre d'une détection non supervisée. Elle constitue ainsi une piste intéressante à approfondir, notamment en améliorant les représentations utilisées et en adaptant davantage l'architecture et l'apprentissage

des modèles à la tâche de détection d'anomalies.

1.5 Représentation interprétable de la détection

L'un des principaux avantages du formalisme proposé réside dans son caractère visuel ainsi que dans son niveau élevé de granularité, qui en font une représentation particulièrement interprétable. Qu'il soit utilisé dans un cadre d'apprentissage supervisé ou non supervisé, le modèle associe à chaque arc du graphe une probabilité reflétant son degré de légitimité. Ces probabilités peuvent ensuite être directement projetées sur la structure du graphe afin de mettre en évidence les éléments ayant contribué à la décision du modèle.




Figure 1.12: Représentation des coefficients d'anomalies pour les dimensions (a) sémantique, (b) séquentielle, et (c) topologique. Les nœuds rouges représentent des paquets d'attaque tandis que les verts représentent des paquets bénins.

La figure ?? présente différents exemples d'anomalies sémantiques, temporelles et topologiques, ainsi que les probabilités d'existence associées prédites par le modèle. Dans le cas d'une anomalie sémantique, le modèle identifie l'arc associé à l'attribut *nf_type*, qui présente un comportement inhabituel, comme étant fortement anormal. Cependant, en raison de l'utilisation de convolutions sur

les graphes, les représentations des arcs intègrent une partie de l'information issue de leur voisinage. Ainsi, l'arc associé à l'attribut *path*, bien qu'il ne soit pas directement à l'origine de l'anomalie, peut également être considéré comme partiellement anormal par le modèle.

Pour l'anomalie temporelle, trois paquets successifs sont observés. Leur ordre d'apparition introduit progressivement un comportement atypique, ce qui conduit le modèle à attribuer des scores d'anomalie croissants au fur et à mesure de la séquence. Enfin, dans le cas d'une anomalie topologique, le problème provient d'une redirection inhabituelle. Le modèle doit identifier que l'anomalie est liée au fait que l'adresse IP source et l'attribut *path* du second paquet correspondent à ceux observés dans le premier paquet. Comme précédemment, les arcs adjacents peuvent également hériter d'une partie du caractère anormal en raison de la propagation de l'information au sein du voisinage du graphe.

Cette représentation visuelle peut ainsi compléter un mécanisme de détection automatisée fondé sur un seuil d'anomalie. Dans un contexte opérationnel, les opérateurs pourraient définir un niveau de sensibilité à partir duquel une alerte est déclenchée. Lorsqu'un paquet ou une interaction dépasse ce seuil, le modèle fournit alors non seulement une indication de l'anomalie détectée, mais également une représentation visuelle détaillée de son contexte, permettant d'identifier les caractéristiques ayant influencé cette décision. La Figure ?? présente un exemple réel, plus complet, et donc plus représentatif des scénarios susceptibles d'être observés dans un environnement opérationnel.

Sur cette figure, des paquets légitimes issus de procédures de redémarrage de session (nœuds bleus) ainsi que des paquets associés à des attaques de type DoS de sessions et Fuzzing de SEID (nœuds rouges) sont représentés simultanément au sein d'un même graphe. On observe notamment que les arcs liés aux attaques ne sont pas tous directement classés comme fortement anormaux. Dans le cas des attaques Fuzzing de SEID, les premiers paquets sont représentés en orange, traduisant une sémantique initiale peu suspicieuse. Les paquets d'attaques suivants constituent de surcroît une anomalie temporelle et renforcent la confiance du modèle quant à la présence d'une anomalie. À l'inverse, les paquets issus des attaques de DoS de session sont immédiatement identifiés comme fortement anormaux. Cette distinction s'explique par le fait que ces paquets en particuliers doivent présenter des caractéristiques structurelles et sémantiques directement anormales.

La principale limitation de cette représentation réside dans le fait qu'elle ne capture pas explicitement la dimension temporelle des échanges. Néanmoins, dans un contexte opérationnel, ce formalisme pourrait être étendu sous la forme d'une visualisation dynamique dans laquelle les paquets et les interactions apparaîtraient progressivement au cours du temps. Une telle approche permettrait de combiner l'interprétabilité structurelle du graphe avec une analyse temporelle plus fine des comportements observés.




Figure 1.13: Représentation de la prédiction d'anomalie sur un graph représentant un ensemble de paquets observés. Les arcs rouges signalent des anomalies très probables tandis que les arcs verts signalent une faible probabilité d'anomalie. Les paquets bénins sont représentés comme des nœuds de couleur bleu et les paquets d'attaques comme des nœuds de couleur rouge.

1.6 Conclusion

Dans ce chapitre, nous avons mis en évidence le manque de datasets publics adaptés à l'évaluation et à la comparaison des approches proposées. Les quelques ensembles de données existants présentent soit une couverture insuffisante des cas d'usage considérés, soit des lacunes en termes de reproductibilité, notamment en raison de l'absence de procédures, d'outils ou de ressources permettant leur réutilisation.

Face à ce constat, un effort conséquent a été consacré à la conception et à la génération d'un nouveau dataset. Cette tâche s'est révélée particulièrement complexe, la définition même de la qualité d'un dataset demeurant un sujet de recherche actif pour lequel aucun consensus définitif n'a encore émergé. Dans ce contexte, une attention particulière a été portée à la réduction des biais potentiels, à la diversité des scénarios représentés ainsi qu'à la couverture des différentes

dimensions et surfaces d'attaque considérées. La qualité du dataset a par ailleurs été évaluée a posteriori à l'aide des critères définis au cours de cette étude.

Ce dataset a ensuite servi de base à l'entraînement et à l'évaluation de plusieurs modèles reposant sur différentes architectures et paradigmes d'apprentissage. Bien que les résultats obtenus avec l'apprentissage non supervisé soient limités, ceux obtenus avec les approches supervisées montrent qu'il est possible d'atteindre des performances satisfaisantes pour la détection des comportements anormaux étudiés dans notre formalisme. Au-delà des métriques de performance, l'utilisation d'une représentation graphique fondée sur les graphes permet également de fournir une interprétation fine des décisions prises par les modèles. Cette capacité d'explicabilité constitue un atout majeur dans un contexte opérationnel, où les systèmes de détection doivent non seulement identifier les anomalies, mais également fournir aux opérateurs humains les éléments nécessaires à leur compréhension et à leur analyse.

Bibliography

- [Amponis 2022] George Amponis, Panagiotis Radoglou-Grammatikis, Thomas Lagkas, Wissam Mallouli, Ana Cavalli, Dimitris Klonidis, Evangelos Markakis Panagiotis Sarigiannidis. *Threatening the 5G core via PFCP DoS attacks: the case of blocking UAV communications*. EURASIP Journal on Wireless Communications and Networking, no. 1, page 124, 2022. (Cité en page 8.)
- [Amponis 2023] George Amponis, Panagiotis Radoglou-Grammatikis, George Nakas, Sotirios Goudos, Vasileios Argyriou, Thomas Lagkas Panagiotis Sarigiannidis. *5G core PFCP intrusion detection dataset*. 2023 12th International Conference on Modern Circuits and Systems Technologies (MOCASST), pages 1–4. IEEE, 2023. (Cité en pages 2, 3, 9 et 11.)
- [Betts 2024] Lucas Betts, Robert Biddle, Danielle Lottridge Giovanni Russello. *Exploring Content Concealment in Email*. 2024 APWG Symposium on Electronic Crime Research (eCrime), pages 58–75, September 2024. ISSN: 2159-1245. (Cité en page 16.)
- [Coldwell 2022] Cooper Coldwell, Denver Conger, Edward Goodell, Brendan Jacobson, Bryton Petersen, Damon Spencer, Matthew Anderson Matthew Sgambati. *Machine Learning 5G Attack Detection in Programmable Logic*. 2022 IEEE Globecom Workshops (GC Wkshps), pages 1365–1370, December 2022. (Cité en pages 2, 3, 9 et 10.)
- [ESTI 2021] ESTI. *TS 123 502 - V16.7.0 - 5G; Procedures for the 5G System (5GS) (3GPP TS 23.502 version 16.7.0 Release 16)*, 2021. (Cité en pages 7 et 8.)
- [firecell 2026] firecell. *Firecell <https://firecell.io/fr/>*, 2026. (Cité en page 5.)
- [Flood 2024] Robert Flood, Gints Engelen, David Aspinall Lieven Desmet. *Bad Design Smells in Benchmark NIDS Datasets*. 2024 IEEE 9th European Symposium on Security and Privacy (EuroS&P), pages 658–675, July 2024. (Cité en pages 4 et 13.)
- [free5GC compose 2025] free5GC compose. *free5gc/free5gc-compose*, 2025. (Cité en page 15.)
- [free5GC Project 2026] free5GC Project. *free5GC: 5G Core Network*, 2026. Accessed: 2026-03-31. (Cité en pages 5 et 15.)
- [Gregorio 2025] Jesus de Gregorio. *jdegre/5GC_APIs*, 2025. (Cité en page 10.)
- [Hoger 2025] Thomas Hoger. *thomas-hoger/free5gc-compose*, 2025. (Cité en page 15.)

- [Hoger 2026] Thomas Hoger. *thomas-hoger/DyGLib*, May 2026. original-date: 2026-02-24T15:15:48Z. (Cité en page 20.)
- [Lanvin 2022] Maxime Lanvin, Pierre-François Gimenez, Yufei Han, Frédéric Majorczyk, Ludovic Mé Éric Totel. *Errors in the CICIDS2017 Dataset and the Significant Differences in Detection Performances It Makes*. Risks and Security of Internet and Systems: 17th International Conference, CRiSIS 2022, Sousse, Tunisia, December 7-9, 2022, Revised Selected Papers, pages 18–33, Berlin, Heidelberg, December 2022. Springer-Verlag. (Cité en page 3.)
- [oai 2026] oai. *OpenAirInterface* <https://openairinterface.org/>, 2026. (Cité en page 5.)
- [open5gs 2026] open5gs. *Open5GS*, 2026. (Cité en page 5.)
- [Pacherkar 2024] Harsh Sanjay Pacherkar Guanhua Yan. *PROV5GC: Hardening 5G Core Network Security with Attack Detection and Attribution Based on Provenance Graphs*. Proceedings of the 17th ACM Conference on Security and Privacy in Wireless and Mobile Networks, WiSec '24, pages 254–264, New York, NY, USA, May 2024. Association for Computing Machinery. (Cité en pages 3 et 7.)
- [Park 2022] Seongmin Park, Sungmoon Kwon, Youngkwon Park, Dowon Kim Ilsun You. *Session Management for Security Systems in 5G Standalone Network*. IEEE Access, vol. 10, pages 73421–73436, 2022. (Cité en pages 9 et 12.)
- [Samarakoon 2022] Sehan Samarakoon Samarakoon, Yushan Siriwardhana Siriwardhana, Pawani Porambage Porambage, Madhusanka Liyanage Liyanage, Sang-Yoon Chang Chang, Jinoh Kim Kim, Jonghyun Kim Kim Mika Ylianttila Ylianttila. *5G-NIDD: A Comprehensive Network Intrusion Detection Dataset Generated over 5G Wireless Network*, 2022. (Cité en page 2.)
- [Sarhan 2022] Mohanad Sarhan, Siamak Layeghy Marius Portmann. *Evaluating Standard Feature Sets Towards Increased Generalisability and Explainability of ML-Based Network Intrusion Detection*. Big Data Research, vol. 30, page 100359, November 2022. (Cité en page 3.)
- [Sharafaldin 2017] Sharafaldin. *Network Intrusion dataset(CIC-IDS- 2017)*, 2017. (Cité en page 3.)
- [Tan 2025] Yawen Tan, Jiajia Liu, Yuanhao Li Jiadai Wang. *Deep Learning Based Proactive Anomaly Detection for 5G Core Control Plane Network Function Interactions*. IEEE Transactions on Cognitive Communications and Networking, pages 1–1, 2025. (Cité en pages 3 et 13.)

- [Tian 2023] Zixu Tian, Rajendra Patil, Mohan Gurusamy Joshua McCloud. *ADSeq-5GCN: Anomaly Detection from Network Traffic Sequences in 5G Core Network Control Plane*. 2023 IEEE 24th International Conference on High Performance Switching and Routing (HPSR), pages 75–82, June 2023. (Cité en page 3.)
- [TrendMicro 2023] TrendMicro. *A Deep Dive into the Packet Reflection Vulnerability Allowing Attackers to Plague Private 5G Networks | Trend Micro (US)*, 2023. (Cité en pages 9 et 12.)
- [ueransim 2026] ueransim. *UERANSIM*, 2026. (Cité en page 15.)
- [Wang 2023] Min Wang, Peng Li, Zhang Cheng, Wenmao Liu, Lei Nie, Haizhou Bao, Qin Liu Kai Zhang. *Unsupervised Graph-Sequence Anomaly Detection for 5G Core Network Control Plane Traffic*. 2023 IEEE 29th International Conference on Parallel and Distributed Systems (ICPADS), pages 1645–1652, December 2023. (Cité en page 3.)
- [Yu 2023] Le Yu, Leilei Sun, Bowen Du Weifeng Lv. *Towards Better Dynamic Graph Learning: New Architecture and Unified Library*, March 2023. (Cité en page 20.)