



THÈSE

En vue de l'obtention du

DOCTORAT DE L'UNIVERSITÉ FÉDÉRALE TOULOUSE MIDI-PYRÉNÉES

Délivré par :

l'Institut National des Sciences Appliquées de Toulouse (INSA de Toulouse)

Présentée et soutenue le *jj/mm/aaaa* par :

Thomas Hoyer

**Détection d'anomalies multi-dimensionnelles dans un réseau 5G par
Graphes Continus Dynamiques**

JURY

VINCENT NICOMETTE

Professeur

Président du Jury

XAVIER LAGRANGE

Professeur

Rapporteur

MICHAËL HAUSPIE

Maître de conférences

Rapporteur

ERIC TOTEL

Professeur

Membre du Jury

YASSINE HADJADJ-AOUL

Professeur

Membre du Jury

NATHALIE MITTON

Directrice de recherche

Membre du Jury

École doctorale et spécialité :

MITT : Domaine STIC : Réseaux, Télécoms, Systèmes et Architecture

Unité de Recherche :

Laboratoire d'analyse et d'architecture des systèmes

Directeur(s) de Thèse :

Philippe Owezarski

Rapporteurs :

Xavier LAGRANGE et Michaël HAUSPIE

Remerciements

A faire en dernier :-)

Abstract

Pour répondre à de nouvelles exigences de qualité de service et à l'émergence de nouveaux usages, le paradigme de la 5G marque une rupture majeure avec les architectures réseau traditionnelles. Le cœur de réseau évolue d'un système monolithique, dans lequel chaque fonction réseau est statiquement associée à un équipement matériel dédié, vers une architecture logicielle virtualisée, flexible et dynamique. À l'image des architectures à microservices, les fonctions réseau peuvent désormais être déployées, modifiées ou supprimées à la demande, rapprochant ainsi la 5G des systèmes distribués modernes.

Cette transformation apporte toutefois de nouveaux défis en matière de sécurité. La virtualisation et la distribution des fonctions réseau élargissent la surface d'attaque et favorisent l'émergence de menaces inédites, difficilement détectables à l'aide des approches traditionnelles de volumétrie ou de signature. Dans ce contexte, il devient nécessaire de dépasser les méthodes classiques employées par les systèmes de détection d'intrusion et d'adopter des approches centrées sur le paquet, capables d'analyser simultanément son contenu, son contexte temporel ainsi que son rôle au sein des interactions réseau.

Afin de capturer ces dimensions sémantiques, séquentielles et topologiques, cette thèse propose un nouveau formalisme fondé sur les graphes continus dynamiques. Cette représentation permet de modéliser finement l'évolution des communications réseau et d'exploiter les capacités des Réseaux de Neurones sur Graphes (GNN). Les travaux présentés démontrent que cette approche permet de détecter efficacement des anomalies subtiles tout en offrant un niveau élevé d'interprétabilité, indispensable à leur analyse et à leur compréhension.

Keywords : Cybersecurité, 5G, Détection d'Anomalie, GNN Dynamique, NLP, Dataset

Table des matières

Introduction	1
1 Identification des surfaces d'attaques de la 5G	5
1.1 Nouveautés apportées par la 5G	5
1.1.1 Changement de paradigme	6
1.1.2 Simplification des interfaces et piles protocolaires	6
1.1.3 Développement des réseaux privés	7
1.1.4 Ecosystème élargi et nouveaux vecteurs d'intrusions	7
1.2 Architecture, composants et protocoles	8
1.2.1 Composants physique du réseau	9
1.2.2 Canaux de communication et protocoles associés	10
1.2.3 Trafics utilisateur et de contrôle	11
1.3 Définition du cadre d'étude de la thèse	11
1.4 Conclusion	12
2 Etat de l'art des attaques 5G	13
2.1 Les plateformes open-source comme une approximation du réel	14
2.1.1 IPSec	14
2.1.2 Session Report	15
2.1.3 Allocation aléatoire des Identifiants de Session (SEID)	15
2.1.4 NF Heartbeat	16
2.1.5 Transport Layer Security (TLS)	16
2.1.6 Autorisation des NF avec OAuth 2.0	16
2.1.7 Présence du Service Communication Proxy (SCP)	16
2.2 Distinction entre attaques réalistes et hypothèses irréalistes	17
2.2.1 Attaques spécifiques aux implémentations	17
2.2.2 Attaques spécifiques aux standards	18
2.3 Limites du cadre FiGHT™ en tant que framework de catégorisation	20
2.4 Nouvelle classification propre aux enjeux de détections	21
2.4.1 Dimension sémantique	21
2.4.2 Dimension topologique	21
2.4.3 Dimension temporelle	22
2.5 Conclusion	23
3 Vers une formalisation adaptée à la détection d'anomalie multi-dimensionnelles	25
3.1 Objectifs et cadre de détection	26
3.2 Etat de l'art de la détection d'anomalies	27
3.2.1 Approche historique dans les réseaux traditionnels	27
3.2.2 Apprentissage profond appliqué aux réseaux 5G	28

3.2.3	Comparaison aux techniques des systèmes distribués	31
3.2.4	Synthèse	32
3.3	Méthodologie de formalisation	33
3.3.1	Extraction des features depuis la payload applicative	33
3.3.2	Transformation en graph	33
3.3.3	Encodage des arcs et nœuds	36
3.4	Détection d'anomalies dans des graphes	37
3.4.1	Introduction aux GNN	37
3.4.2	Etat de l'art des GNN	38
3.4.3	Formalisation adapté à l'utilisation de GNN dynamiques . .	43
3.4.4	Fonctionnement détaillé des GNN dynamique	44
3.4.5	Adaptation à notre cas d'utilisation	46
3.5	Encodage des paramètres contenus dans les arcs	48
3.5.1	Apprentissage supervisé et non supervisé	49
3.5.2	Tour d'horizon des techniques de NLP	50
3.5.3	Mise en place de l'encodage sémantique	53
3.5.4	Avantages et limites	54
3.6	Conclusion	55
4	Evaluation empirique des modèles	57
4.1	Etat de l'art des datasets	58
4.1.1	Analyse des datasets 5G	58
4.1.2	Limites dans l'évaluation de la qualité des données	59
4.2	Génération d'un dataset	62
4.2.1	Trafic bénin	62
4.2.2	Trafic anormal	65
4.2.3	Méthodologie de génération	69
4.2.4	Environnement et implémentation	71
4.3	Evaluation des caractéristiques du dataset	72
4.3.1	Caractérisation sémantique	72
4.3.2	Caractérisation séquentielle	74
4.3.3	Caractérisation topologique	74
4.3.4	Synthèse	75
4.4	Evaluation des modèles de détection	75
4.4.1	Métriques d'évaluation	76
4.4.2	Approche supervisée	78
4.4.3	Approche non supervisée	79
4.5	Représentation interprétable de la détection	83
4.6	Conclusion	86
5	Conclusion	87
5.1	Contributions	88
5.2	Limites et perspectives	88
5.2.1	Optimisation de l'implémentation et utilisation de BERT . .	88

Table des matières	v
5.2.2 Mise en place d'un modèle spécialisé	89
5.2.3 Extension du dataset CTD5G	89
5.2.4 Intégration d'informations système	89
5.3 Synthèse	90
Bibliographie	91

Acronymes

3GPP 3rd Generation Partnership Project.
AMF Access and Mobility Management Function.
AUC Area Under the Curve.
AUSF Authentication Server Function.
CBOW Continuous Bag of Words.
CN Cœur de Réseau.
CNN Réseaux de Neurones Convolutionnels.
DDoS Déni de Service Distribué.
DTGN Réseaux de Graphes à Temps Discret.
FAR Forwarding Action Rule.
FL Federated Learning.
GAT Graph Attention Networks.
GCN Graph Convolutional Networks.
GIN Graph Isomorphism Networks.
GloVe Global Vectors for Word Representation.
gNB Next Generation NodeB.
GNN Réseaux de Neurones sur Graphes.
GRU Gated Recurrent Unit.
GTP GPRS Tunneling Protocol - User Data.
HTTP/2 Hypertext Transfer Protocol/2.
IMSI Identifiants Utilisateurs.
LSTM Long Short-Term Memory.
MITM Man-in-the-middle.
MPN Réseaux Privés Mobiles.
MPNN Message Passing Neural Networks.
MSE Mean Squared Error.
NAS Non-Access Stratum.
NGAP Next Generation Application Protocol.
NLP Traitement Automatique du Langage Naturel.
NRF Network Repository Function.
OAI Open Air Interface.
PCA Analyse en Composantes Principales.

PEPR Programmes et Equipements Priotaires de Recherche.

PFCP Packet Forwarding Control Protocol.

RAN Réseau d'Accès Radio.

RNN Réseau de Neurones Récurent.

ROC Receiver Operating Characteristic.

SBI Service-Based Interfaces.

SCP Service Communication Proxy.

SDR Radio Définie par Logiciel.

SEID Identifiant de Session.

SMF Session Management Function.

SUCI Subscriber Concealed Identifier.

SVM Machines à Vecteurs de Support.

TEID Identifiant de Tunnel.

UDM Unified Data Management.

UE Equipment utilisateurs.

UPF User Plane Function.

Introduction

Contexte

La cinquième génération de réseaux mobiles (5G) constitue une évolution majeure des infrastructures de télécommunication. Au-delà de l'augmentation des débits et de la réduction de la latence, elle introduit une transformation profonde de l'architecture des réseaux mobiles. Le cœur de réseau, historiquement fondé sur des équipements spécialisés, est désormais largement softwarisé et repose sur une architecture orientée services dans laquelle des fonctions réseau indépendantes interagissent au travers d'interfaces applicatives standardisées. Cette évolution facilite le déploiement de nouveaux services, favorise l'automatisation et permet l'émergence de réseaux privés mobiles adaptés aux besoins spécifiques des entreprises.

Parallèlement, ces améliorations contribuent à accroître considérablement la surface d'attaque du cœur de réseau. De ce fait, un nombre croissant de travaux de recherche en cybersécurité s'intéressent aux enjeux de sécurisation des architectures 5G. De nombreuses vulnérabilités ainsi que divers scénarios d'attaque ont été identifiés dans la littérature récente, aussi bien au niveau des protocoles de communication qu'au niveau des interactions entre les différentes fonctions du réseau.

Problématique

Cette évolution architecturale remet en question les approches traditionnelles de détection d'intrusion. Les mécanismes développés pour les réseaux IP classiques reposent généralement sur l'analyse de flux ou sur des signatures connues, alors que les attaques de la littérature visant les réseaux 5G exploitent souvent des propriétés plus complexes liées à la logique des protocoles, aux séquences de messages ou aux interactions entre entités du cœur de réseau.

L'étude de ces problématiques est également freinée par le manque de données publiques. Pour des raisons de confidentialité, les opérateurs partagent rarement les traces issues de leurs infrastructures. Les travaux de recherche doivent donc s'appuyer sur des datasets synthétiques générés à partir d'implémentations open-source. Cette situation a conduit à l'émergence de nombreux datasets construits indépendamment les uns des autres, avec des méthodologies parfois peu documentées et des biais susceptibles de fausser l'évaluation des modèles. Il devient alors difficile de comparer objectivement les approches proposées dans la littérature ou d'évaluer leur capacité réelle de généralisation.

Approche Scientifique

Pour répondre à ces problématiques, ce manuscrit propose une approche fondée sur une représentation explicite des échanges observés dans le cœur de réseau 5G.

Cette approche vise à capturer simultanément les dimensions sémantiques, séquentielles et topologiques des communications et des scénarios d'attaque. À cette fin, nous introduisons un nouveau formalisme permettant de modéliser ces échanges sous la forme de graphes interprétables.

Afin de permettre une évaluation rigoureuse, nous proposons également une méthodologie de génération de dataset couvrant plusieurs surfaces d'attaque du cœur de réseau 5G. Une attention particulière est portée à la qualité des données produites, à la limitation des biais de génération et à l'association systématique d'un trafic légitime comparable à chaque scénario d'attaque.

Enfin, les différentes représentations et modèles étudiés sont comparés expérimentalement afin d'identifier les approches les plus adaptées à la détection d'anomalies dans les réseaux 5G.

Contributions

Les travaux réalisés dans le cadre de cette thèse ont conduit à trois contributions principales :

- **Analyse critique des attaques 5G et des cadres de catégorisation existants.** Soumise à *IEEE Communications Magazine*, actuellement en cours d'évaluation.
- **Conception d'un dataset de trafic de contrôle 5G.** Soumise au workshop *ANUBIS* de la conférence *ESORICS 2026*, actuellement en cours d'évaluation.
- **Proposition d'un formalisme de graphes dynamiques continus et évaluation comparative de modèles de détection d'anomalies.** Article en cours de rédaction et prévu pour soumission avant la soutenance.

Ces travaux ont également donné lieu aux présentations suivantes :

- **Conférence RESSI 2025** — Présentation du formalisme de graphes dynamiques continus.
- **Workshop « Supervision des Infrastructures Critiques », Journées TransNumériques 2026** — Présentation de l'analyse critique de la littérature sur les attaques 5G.
- **Workshop « Supervision des Infrastructures Critiques », Journées TransNumériques 2026** — Présentation des travaux relatifs à la conception du dataset.
- **Conférence THCon 2026** — Présentation du formalisme proposé et des modèles de détection étudiés.
- **Conseil Scientifique et Technologique du PEPR Réseaux du Futur** — Présentation du formalisme proposé et des modèles de détection étudiés.



FIGURE 1 – Logo du PEPR Réseaux du Futur.

Contexte au sein du PEPR Réseaux du futur

Dans le cadre de son programme de recherche scientifique France 2030, le gouvernement français a lancé plusieurs programmes Programmes et Equipements Prioritaires de Recherche (PEPR) thématiques dans différents domaines scientifiques. L'un d'entre eux est consacré à la 5G et aux réseaux du futur. Au sein de ce programme, le projet NF-HiSec vise à traiter les questions de sécurité des réseaux du futur, en particulier la 5G. Le projet NF-HiSec cherche à relever les principaux défis en matière de sécurité en se concentrant sur cinq objectifs principaux :

- **Détection et atténuation des attaques dans des environnements complexes** : Développer des techniques avancées pour identifier et atténuer les cyberattaques dans des réseaux dynamiques et en constante évolution.
- **Protection des données personnelles, avec un accent sur l'interception légale** : Sécuriser les données personnelles même lors d'interceptions légales, tout en garantissant le respect des lois sur la vie privée.
- **Modélisation des mécanismes de sécurité pour répondre aux besoins des applications** : Adapter les mesures de sécurité aux exigences spécifiques des différentes applications utilisant ces réseaux.
- **Intégration de la sécurité à travers les frontières matériel et logiciel** : Formaliser la connexion entre les composants matériels et logiciels afin d'assurer la mise en œuvre de mesures de sécurité complètes à tous les niveaux.

Dans le cadre de cette large initiative, le projet NF-HiSec joue donc un rôle central dans le développement de méthodes et d'outils innovants visant à sécuriser de manière exhaustive les réseaux du futur. Cette thèse s'inscrit ainsi comme une contribution à un effort commun, cherchant à sécuriser une partie de l'écosystème divers et complet qu'est la 5G.

Plan

Cette thèse est organisée en quatre chapitres, chacun abordant un aspect spécifique de la problématique étudiée et de l'approche proposée.

- **Chapitre 1 : Identification des surfaces d’attaque de la 5G.** Ce premier chapitre présente le contexte général des réseaux 5G, en détaillant leur architecture ainsi que les principales technologies qui les composent. Nous identifions ensuite les différentes surfaces d’attaque susceptibles d’être exploitées par un adversaire et les surfaces à protéger. Cette analyse permet de délimiter précisément le périmètre d’étude retenu dans le cadre de cette thèse.
- **Chapitre 2 : État de l’art des attaques 5G.** Une fois le cadre d’étude établi, nous analysons les travaux existants consacrés aux attaques sur les réseaux 5G. Nous montrons que la notion même d’attaque n’est pas toujours définie de manière uniforme dans la littérature, de nombreux travaux se concentrant principalement sur l’absence ou l’insuffisance de certains mécanismes de sécurité. Ce constat nous conduit à proposer une nouvelle classification des attaques, qui servira de fondement à l’approche de détection développée dans la suite de la thèse.
- **Chapitre 3 : Vers une formalisation adaptée à la détection d’anomalies multi-dimensionnelles.** Ce chapitre présente un état de l’art des méthodes de détection d’anomalies, aussi bien dans les réseaux 5G que dans les réseaux traditionnels. À partir de cette analyse, nous identifions les GNN dynamiques comme une approche particulièrement adaptée à notre problématique. Nous proposons alors une formalisation permettant de représenter finement les interactions observées dans un environnement 5G. Enfin, nous discutons plusieurs extensions permettant de prendre en compte l’encodage de paramètres de dimension non-finie.
- **Chapitre 4 : Évaluation empirique des modèles.** Le dernier chapitre est consacré à l’évaluation expérimentale du formalisme et des modèles développés. Nous présentons tout d’abord la conception d’un dataset visant à combler une lacune importante de la littérature actuelle. Nous comparons ensuite différentes architectures de modèles ainsi que plusieurs stratégies d’apprentissage afin d’évaluer leur capacité à détecter les anomalies dans les environnements 5G étudiés.

Identification des surfaces d'attaques de la 5G

Sommaire

1.1	Nouveautés apportées par la 5G	5
1.1.1	Changement de paradigme	6
1.1.2	Simplification des interfaces et piles protocolaires	6
1.1.3	Développement des réseaux privés	7
1.1.4	Ecosystème élargi et nouveaux vecteurs d'intrusions	7
1.2	Architecture, composants et protocoles	8
1.2.1	Composants physique du réseau	9
1.2.2	Canaux de communication et protocoles associés	10
1.2.3	Trafics utilisateur et de contrôle	11
1.3	Définition du cadre d'étude de la thèse	11
1.4	Conclusion	12

Les réseaux 5G sont conçus pour répondre à des exigences strictes en terme de haut débit, de faible latence et de communications massives entre appareils connectés, permettant l'émergence de nombreux services innovants [Gupta 2015, Zaame 2020]. Pour assurer le fonctionnement efficace de ces différents cas d'usage, la 5G change profondément de paradigme et intègre plusieurs nouveaux concepts aux réseaux mobiles, de nouveaux composants dans son architecture et de nouvelles méthodes de communications entre les entités qui la composent.

Ces évolutions rendent les réseaux mobiles plus flexibles et plus dynamiques mais au prix d'une complexification du système et d'une augmentation de la surface d'attaque. Dans ce contexte, les besoins en matière de détection d'anomalies évoluent également et il devient alors nécessaire de concevoir de nouveaux mécanismes de détection capables de s'adapter aux spécificités et à la complexité des architectures 5G.

1.1 Nouveautés apportées par la 5G

Cette section présente les principales évolutions introduites par la 5G par rapport aux générations précédentes de réseaux mobiles. Ces changements concernent à la fois l'architecture du réseau, les protocoles de communication, ainsi que l'écosystème global dans lequel s'inscrivent ces systèmes. Ils ont un impact direct sur la

surface d’attaque du réseau et constituent donc un élément central pour l’analyse des menaces et des vulnérabilités.

1.1.1 Changement de paradigme

La virtualisation constitue un changement majeur qui permet de déployer des services à la demande sur tout type de matériel. Grâce à cette nouveauté, les réseaux 5G s’éloignent de la conception traditionnelle des systèmes mobiles, historiquement construits sous forme d’architectures monolithiques où chaque fonction s’exécutait sur un matériel dédié et communiquait via des canaux fixes et des piles de protocoles rigides. À la place, l’architecture 5G adopte une approche plus proche de celle des microservices du cloud, où les fonctions réseau sont softwarisées, découplées et conteneurisées.

Cependant, malgré les avantages significatifs de la virtualisation, celle-ci hérite également d’un nombre important de nouvelles vulnérabilités propres à cette technologie. En effet, qu’elle repose sur des technologies de machines virtuelles ou sur la conteneurisation, la virtualisation représente une couche supplémentaire qui peut elle-même être vulnérable à des attaques spécifiques tel que l’empoisonnement d’image [Yasrab 2023] ou l’évasion de VM/Docker [TrendMicro 2019].

1.1.2 Simplification des interfaces et piles protocolaires

Les interfaces étaient initialement conçues pour des entités fixes et présentaient donc une certaine rigidité. Elles reposaient souvent sur des protocoles très spécifiques, répondant à des problématiques bien définies. Le changement de paradigme de la 5G vers celui des systèmes distribués, ainsi que la volonté de rendre les réseaux plus flexible, entraînent donc une simplification de ces interfaces et protocoles.

Certains protocoles et interfaces de la 4G sont tout de même conservés en 5G, ce qui implique que cette dernière hérite aussi d’une partie de la surface d’attaque et des vulnérabilités des générations précédentes. On retrouve par exemple des attaques d’injection de messages de contrôle dans le flux utilisateur géré par le protocole GTP-U [Park 2022, TrendMicro 2023], des attaques par inondation ciblant la gestion des ressources radio via le protocole RRC [Ettiane 2021], ainsi que des attaques par rejeu affectant les messages de signalisation du protocole NAS [Salazar 2023].

Mais la transition vers une architecture inspirée des microservices introduit aussi de nouvelles interfaces et de nouveaux protocoles, élargissant par conséquent la surface d’attaque. L’adoption des Service-Based Interfaces (SBI), basées sur des API REST, expose notamment le cœur de réseau à des attaques de type fuzzing [Hoger 2026b]. De nouveaux protocoles comme NGAP peuvent être ciblés par des injections de messages malformés [Salazar 2023], tandis que PFCP introduit de nouvelles surfaces d’attaque liées à la gestion des sessions et des flux [Amponis 2023].

1.1.3 Développement des réseaux privés

La simplification de l'architecture 5G facilite aussi le déploiement et l'exploitation de réseaux mobiles privés. Cette approche offre à certaines organisations, telles que les universités, les hôpitaux ou encore les bases militaires, la possibilité de gérer leurs propres infrastructure. Elles peuvent ainsi, entre autre, bénéficier d'un contrôle complet de leur couverture réseau, ainsi que de la gestion de sa sécurité [Wen 2022].

Cette dynamique est facilitée par la disponibilité croissante d'implémentations open-source permettant de construire des réseaux 5G de manière autonome. Toutefois, ces solutions présentent encore des limites importantes. Leur niveau de maturité reste relativement faible et certains mécanismes de sécurité fondamentaux peuvent être encore absents. Malgré ces lacunes, ces technologies open-source sont déjà utilisées dans des contextes réels, parfois après adaptation par des acteurs industriels. C'est par exemple le cas de Firecell [firecell 2026] qui réutilise une version consolidée de l'implémentation open-source d'Open Air Interface (OAI)[oai 2026].

À l'heure actuelle, la 5G privée demeure un marché de niche, en partie en raison du manque de maturité des solutions disponibles. Néanmoins, les perspectives de croissance sont importantes et une adoption plus large est attendue dans les années à venir. Dans ce contexte, le recours massif à des implémentations open-source ou à leurs dérivés commerciaux pourrait engendrer des risques significatifs en matière de sécurité, notamment si les insuffisances actuelles ne sont pas pleinement corrigées.

1.1.4 Ecosystème élargi et nouveaux vecteurs d'intrusions

La softwarisation et la simplification de l'architecture 5G ont pour objectif d'étendre l'usage de la 5G au secteur industriel. Les besoins des entreprises et de leurs utilisateurs étant variés, la 5G introduit de nouveaux mécanismes dans les réseaux mobiles afin d'y répondre. Cependant, l'ajout de nouvelles fonctionnalités entraîne également de nouvelles problématiques de sécurité ainsi que de nouveaux vecteurs d'intrusion. Parmi les nombreuses innovations apportées par la 5G, plusieurs exemples notables contribuent à l'élargissement de la surface d'attaque.

- **Slicing** : Afin de gérer efficacement plusieurs services et cas d'usage, la 5G introduit le concept de network slicing qui consiste à créer des réseaux virtuels indépendants, chacun assurant des exigences de qualité de service différentes. Le concept de slicing impacte l'architecture 5G à tous les niveaux, depuis la couche physique, où il implique la gestion de la grille de ressources temps/fréquence [Sexton 2019], jusqu'à la couche applicative, où il garantit la continuité et l'isolation des services. Bien que les slices soient censées être isolées logiquement, elles peuvent toutefois coexister au sein d'une même infrastructure physique partagée. Les spécifications du 3rd Generation Partnership Project (3GPP) relatives aux slices intègrent des mécanismes de sécurité robustes [TR 33.813 2020, TR 33.811 2018] pour garantir cette isolation logique. Néanmoins, ces mécanismes ne sont pas toujours mis en place par les implémentations actuelles, en particulier les implémentations open source,

encore très immatures. Cette situation soulève des préoccupations de sécurité et introduit de nouveaux vecteurs d'attaque, permettant par exemple à un attaquant de pivoter d'une slice à une autre [Kumar 2023, Enea 2021].

- **Orchestrations** : Dans un déploiement à grande échelle, il n'est pas réaliste de gérer l'entiereté de l'infrastructure des réseaux 5G manuellement. La virtualisation des fonctions réseaux permet cependant d'automatiser l'orchestration et la gestion des services [ETSI 2024] pour pouvoir moduler, en fonction des besoins, l'architecture et les capacités du réseaux. Cette gestion automatisée est généralement réalisée par des logiciels comme Kubernetes ou Openstack qui rajoutent des couches de complexité et de vulnérabilités.
- **Chaîne d'approvisionnement** : L'intégration logicielle était historiquement gérée par un acteur unique : le fournisseur d'équipements réseau. Cependant, les réseaux 5G reposent maintenant sur un bien plus grand panel de logiciels pour leur fonctionnement. Comme c'est généralement le cas dans le développement logiciel moderne, ces logiciels reposent largement sur du code tiers, dont une grande partie est open-source. Cela introduit des risques liés à la méconnaissances de l'inventaire détaillé des composants logiciels (Software Bill of Materials) ainsi qu'aux attaques de la chaîne d'approvisionnement [Williams 2025, Sammak 2023, Zimmermann 2019, Kula 2018, Doll 2025].

1.2 Architecture, composants et protocoles




FIGURE 1.1 – Illustration simplifiée des principaux composants de l'architecture 5G.

L'architecture 5G repose sur un ensemble distribué de composants interconnectés, organisés en plusieurs sous-systèmes coopérant pour assurer la connectivité et la gestion des communications. Bien que de nombreux autres éléments existent, les composants présentés ci-dessous comptent parmi ceux absoluts essentiels au fonctionnement du réseau 5G. La Figure 1.1 en propose une illustration simplifiée. Nous allons maintenant décrire les différents composants de l'architecture représentée, ainsi que les protocoles utilisés pour assurer les communications entre ces entités.

1.2.1 Composants physique du réseau

1.2.1.1 Equipement Utilisateur (UE)

Les Equipement utilisateurs (UE) désignent les dispositifs qui se connectent au réseau 5G, tels que les smartphones, les objets connectés et, plus généralement, tout équipement disposant d'une interface radio par laquelle ils peuvent communiquer avec le réseaux 5G. Ils constituent la grande majorité des entités actives du réseau et représentent, par nature, les composants les plus exposés de l'infrastructure. En raison de leur nombre, de leur vulnérabilité et de leur accessibilité, ils sont à la fois les cibles mais aussi les vecteurs les plus probables lors d'une attaque [Ettiane 2021, TrendMicro 2023, Park 2022].

Du point de vue d'un attaquant, compromettre un UE peut s'avérer relativement simple. L'accès peut être réalisé à distance, par installation de logiciels malveillants, ou physiquement, en dérobant l'appareil ou bien la carte SIM qui l'authentifie. Bien que les UE ne soient capable d'interagir directement qu'avec la station de base, ils peuvent par exemple être exploités pour mener des attaques par Déni de Service Distribué (DDoS).

1.2.1.2 Réseaux d'Accès Radio (RAN)

Les UE se connectent au cœur de réseau via le Réseau d'Accès Radio (RAN), composé d'un ensemble de stations de base radio, appelé Next Generation NodeB (gNB) et éventuellement complété par d'autres relais radio. Le gNB assure l'interface avec le cœur de réseau via l'Access and Mobility Management Function (AMF), ainsi qu'avec le réseau de données via l'User Plane Function (UPF) auquel il est connecté par liaison IP standard. Le gNB prend en charge les communications radio, la gestion de l'accès et de l'ordonnancement des ressources, et garantit la continuité de service grâce aux mécanismes de handover entre stations de base voisines.

Contrairement aux réseaux 4G, les réseaux 5G reposent sur un déploiement beaucoup plus dense de stations radio, situées plus près des utilisateurs finaux. Cette proximité accrue facilite l'accès physique pour des attaquants susceptibles de tenter de prendre le contrôle de ces équipements. De plus, les gNB sont relativement faciles à usurper pour un adversaire en raison de l'absence de mécanisme d'authentification forte vis-à-vis des UE. En effet, en émettant un signal plus puissant que celui des stations de base légitimes à proximité, un attaquant peut inciter les terminaux environnants à se connecter à leur station malhonnête en priorité [Mahyoub 2024]. Ces attaques sont d'autant plus facilitées par la disponibilité croissante d'outils de Radio Définie par Logiciel (SDR), qui nécessitent relativement peu de ressources et de compétences techniques pour être utilisés.

1.2.1.3 Cœur de Réseau (CN)

Le CN est un ensemble de fonctions réseau interconnectées via une infrastructure IP, qui interagissent entre elles ainsi qu'avec les UEs et les gNB à travers des

chaînes de procédures. Ces fonctions assurent chacune un rôle spécifique et un grand nombre d'entre elles sont définies par le standard 3GPP. Certaines sont essentielles au fonctionnement du réseau, tandis que d'autres répondent à des cas d'usage plus spécifiques et ne sont donc pas systématiquement déployées. Parmi les fonctions réseau essentielles, on retrouve notamment :

- **Access and Mobility Management Function (AMF)** : gère l'enregistrement des UEs, la mobilité et la signalisation.
- **Session Management Function (SMF)** : responsable de l'établissement, de la modification et de la libération des sessions PDU.
- **User Plane Function (UPF)** : assure le transfert des données utilisateur et le routage vers les réseaux externes.
- **Authentication Server Function (AUSF)** : réalise les procédures d'authentification des utilisateurs.
- **Unified Data Management (UDM)** : gère les données d'abonnement et les profils des utilisateurs.
- **Network Repository Function (NRF)** : permet la découverte et l'enregistrement des fonctions réseau.

Le Cœur de Réseau (CN) est significativement plus difficile d'accès que les UEs ou les gNBs, car les machines physiques qui les hébergent ne sont généralement pas exposées à un accès physique direct. Néanmoins, en raison de leur forte valeur stratégique, compromettre une fonction réseau reste un objectif réaliste pour un adversaire déterminé. Comme évoqué dans les sections précédentes concernant l'orchestration et la chaîne d'approvisionnement, il demeure possible d'atteindre le cœur de réseau pour compromettre certains de ses éléments et obtenir un accès direct au reste du CN. Cet accès pourrait notamment être utilisé pour altérer l'architecture du cœur de réseau en ciblant le NRF[Coldwell 2022], exposer des données utilisateur via l'UDM[Coldwell 2022], et perturber la gestion des sessions en interférant avec la communication entre le UPF et le SMF[Amponis 2022].

1.2.2 Canaux de communication et protocoles associés

En 5G, plusieurs canaux de communication coexistent, chacun remplissant un rôle spécifique et s'appuyant sur des protocoles dédiés. Certains de ces protocoles, tels que GTP-U et NAS, sont hérités des générations précédentes de réseaux mobiles. À l'inverse, la 5G introduit également de nouveaux protocoles, comme NGAP et PFCP, spécifiquement conçus pour répondre aux besoins des nouvelles architectures 5G. Dans notre étude, nous nous concentrons plus particulièrement sur les protocoles de niveau applicatif qui sont, de notre point de vue, les plus représentatifs du changement de paradigme introduit par la 5G vers des systèmes distribués. Parmi les protocoles de communications principaux, on retrouve notamment :

- **Packet Forwarding Control Protocol (PFCP)** est utilisé entre le SMF et l'UPF sur l'interface N4 pour la gestion des sessions utilisateur.
- **GPRS Tunneling Protocol - User Data (GTP)** encapsule les données utilisateurs émises par l'UE. Ces paquets sont ensuite acheminés via l'UPF

par le gNB sur l'interface N3.

- **Next Generation Application Protocol (NGAP)** assure la gestion des échanges de signalisation entre le gNB et l'AMF sur l'interface N2.
- **Non-Access Stratum (NAS)** est utilisé par l'UE pour communiquer avec l'AMF via l'interface N1. Bien que cette interface soit logiquement définie comme de bout en bout, elle est en pratique virtuelle, les messages NAS étant relayés de manière transparente par le gNB.
- **Hypertext Transfer Protocol/2 (HTTP/2)** est utilisé pour les communications entre fonctions réseau via le SBI.

1.2.3 Trafics utilisateur et de contrôle

Les deux principales catégories de trafic dans les réseaux 5G sont le trafic utilisateur et le trafic de contrôle. Le trafic utilisateur correspond aux données échangées entre les utilisateurs finaux et l'Internet une fois le tunnel de communication établi. Il représente généralement la majeure partie du volume de paquets circulant dans le réseau. Du point de vue de l'opérateur, ce trafic est chiffré entre l'utilisateur et l'Internet, et est simplement redirigé sans être interprété par le cœur 5G, de manière similaire à un routeur classique. Il ne présente donc pas de caractéristiques propres au fonctionnement de la 5G.

Il existe également le trafic de contrôle, qui regroupe l'ensemble des messages permettant la mise en place des tunnels de communication des utilisateurs ainsi que le bon fonctionnement général du réseau. Ces messages sont transparents du point de vue de l'utilisateur. À l'inverse du trafic utilisateur, le trafic de contrôle est constitué de messages intrinsèquement liés au fonctionnement du réseau 5G, reposant sur des protocoles et des comportements spécifiques à ce type de réseau, et présentant ainsi des vecteurs d'attaque spécifiques. Ce trafic est également chiffré, mais comme l'opérateur possède les équipements concernés par les échanges, il peut les déchiffrer et analyser leur contenu en clair. C'est donc ce type de trafic qui est le plus pertinent à analyser et vouloir sécuriser.

1.3 Définition du cadre d'étude de la thèse

Comme présenté dans les sections précédentes, l'écosystème et la surface d'attaque de la 5G se sont considérablement élargis par rapport aux générations précédentes, formant plusieurs domaines hétérogènes et attaquables à différents niveaux. Ces domaines sont vastes et présentent peu de recouvrement. Il n'est donc pas envisageable de sécuriser l'ensemble de la 5G et il est plutôt nécessaire de se focaliser sur des problématiques ciblant des parties restreintes de cet écosystème. Nous excluons ainsi de notre étude les problématiques de sécurité liées directement au network slicing, à la virtualisation ou à l'orchestration, qui nécessiteraient une analyse spécifique. Nous considérons plutôt ces mécanismes comme des vecteurs potentiels d'intrusion qui pourrait permettre à un attaquant de compromettre un ou plusieurs composants du réseau.

La softwarisation de la 5G est l'un des changements majeurs de cette génération et se reflète principalement sur les couches protocolaires hautes. C'est pourquoi nous avons choisi de concentrer le travail de cette thèse sur la partie applicative du trafic de contrôle transitant par le cœur et le RAN de la 5G. Les sections précédentes ont montré que la 5G est conçue pour être très modulaire, avec des nouvelles familles de NF pouvant être définies de manière arbitraire, notamment dans le cas des déploiements privés. Nous restreignons donc notre champ d'étude à un réseau comprenant uniquement les NF essentielles et géré par un seul opérateur.

Comme nous n'avons pas d'informations sur l'état de maturité ni sur les problématiques de déploiement rencontrées par les opérateurs publics, notre étude se base à la fois sur les deux seules sources d'information publiques à savoir la norme 3GPP et les implémentations open-source. Nous supposons que ces implémentations open-source sont bien moins matures que les déploiements réels des opérateurs commerciaux, mais nous faisons l'hypothèse que, étant donné la complexité du système, même les réseaux 5G des opérateurs doivent s'écarter du standard à certains égards. De plus, dans le cadre de déploiements privés, il est tout à fait plausible que certaines organisations utilisent une version officielle ou dérivée d'implémentations open-source.

1.4 Conclusion

Dans cette section, nous avons vu que la 5G apporte des changements profonds par rapport aux générations de réseaux mobiles précédentes. Nous avons ainsi montré comment les nouveautés introduites par la 5G contribuent à l'évolution de sa surface d'attaque et de ses vecteurs d'intrusion. En présentant les éléments principaux de l'architecture 5G, nous avons pu délimiter un cadre d'étude pour cette thèse en nous concentrant sur les éléments originaux et fondamentalement nécessaires à son fonctionnement.

Etat de l'art des attaques 5G

Sommaire

2.1	Les plateformes open-source comme une approximation du réel	14
2.1.1	IPSec	14
2.1.2	Session Report	15
2.1.3	Allocation aléatoire des Identifiants de Session (SEID)	15
2.1.4	NF Heartbeat	16
2.1.5	Transport Layer Security (TLS)	16
2.1.6	Autorisation des NF avec OAuth 2.0	16
2.1.7	Présence du Service Communication Proxy (SCP)	16
2.2	Distinction entre attaques réalistes et hypothèses irréalistes	17
2.2.1	Attaques spécifiques aux implémentations	17
2.2.2	Attaques spécifiques aux standards	18
2.3	Limites du cadre FiGHT™ en tant que framework de catégorisation	20
2.4	Nouvelle classification propre aux enjeux de détections	21
2.4.1	Dimension sémantique	21
2.4.2	Dimension topologique	21
2.4.3	Dimension temporelle	22
2.5	Conclusion	23

Les opérateurs de télécommunications divulguent très peu d'information au sujet de leurs implémentations de la 5G ainsi que sur les attaques auxquelles ils sont confrontés. Cette « sécurité par l'obscurité » limite l'émergence de menaces opportunistes et préserve des avantages concurrentiels. Toutefois, elle constitue également un frein important pour la recherche et la mise en place de solutions de sécurité systémique. En l'absence de données empiriques et de retours d'expérience concrets, de nombreux travaux proposent des scénarios d'attaque théoriques sans disposer de cadre de référence solide, rendant difficile l'estimation de leur réalisme et de leur applicabilité dans des environnements opérationnels.

Ce flou de l'état de l'art en matière de réalisme est accentué par une caractérisation parfois insuffisante des attaques dans la littérature scientifique. Certains travaux reposent sur des modèles d'attaquants incomplets, des hypothèses peu explicites ou encore des expérimentations menées sur des implémentations open-source trop peu matures. Bien qu'il existe des cadres méthodologiques dédiés à la caractérisation des attaques tels que FIGHT, ceux-ci présentent encore des limites et

demeurent, à notre connaissance, très peu adoptés dans l'état de l'art. Cette situation contribue à entretenir une certaine ambiguïté quant à la définition et à la classification des attaques réellement pertinentes dans le contexte de la 5G.

Par ailleurs, les approches traditionnelles de détection d'anomalies reposent majoritairement sur l'analyse de flux à grande échelle, fondée sur des indicateurs volumétriques. Cependant, la softwarisation des réseaux 5G rapproche ces infrastructures de systèmes distribués complexes, ce qui nécessite désormais une analyse plus fine, notamment au niveau des paquets. Afin de répondre à ce changement de paradigme, nous proposons une nouvelle catégorisation en trois dimensions d'attaques : sémantiques, séquentielles et topologiques, chacune présentant des problématiques spécifiques en matière de détection.

2.1 Les plateformes open-source comme une approximation du réel

Afin d'accélérer la recherche sur les réseaux 5G et soutenir la mise en place de réseaux privés par les acteurs industriels, plusieurs projets open-source ont été développés, proposant des implémentations fonctionnelles à la fois du RAN et du CN. Ces plateformes sont devenues des outils essentiels pour le monde académique, permettant de mener des expérimentations sans dépendre d'équipements propriétaires coûteux. Parmi les implémentations de cœur de réseau les plus populaires figurent OAI [oai 2026], free5GC [free5GC Project 2026] et Open5GS [open5gs 2026]. Ces dernières peuvent être associées à un RAN réel comme srsRAN [srsRAN 2026] ou OAI-RAN [oai 2026], connecté à du matériel radio et qui exploite vraiment la couche physique radio. Il existe aussi des alternatives simulées, telles que UERAN-SIM [ueransim 2026], qui émulent la couche radio via TCP.

Ces initiatives sont particulièrement importantes mais restent encore à un stade de développement précoce, et ne couvrent pas encore tous les aspects de la norme 3GPP de manière exhaustive. Leur priorité est avant tout de proposer un code opérationnel offrant un maximum de fonctionnalités. La sécurité, bien qu'importante dans un cadre opérationnel, constitue chez eux une contrainte parmi d'autres et n'est pas toujours prioritaire.

De ce fait, de nombreux mécanismes de sécurité définis par la norme 3GPP ne sont pas implémentés dans les différentes solutions open-source. Le tableau 2.1 illustre ce problème en mettant en évidence l'absence de certains mécanismes dans les trois implémentations de CN les plus répandues. Afin de mieux appréhender les implications de ces lacunes, chacun des mécanismes présentés dans ce tableau est décrit individuellement dans les sous-sections suivantes.

2.1.1 IPSec

Selon la norme TS 33.501 [TS 33.501 2026], les interfaces non basées sur les services, telles que N2, N3 et N4, doivent assurer des mécanismes d'intégrité, de

2.1. Les plateformes open-source comme une approximation du réel 15

Mécanisme	Open5GS	free5GC	OAI	Standards
IPSec par accès 3GPP	✗	✗	✗	Rel. 15 (2018)
PFCEP Session Report	v2.1.4 (2021)	v3.3.0 (2022)	v2.0 (2023)	Rel. 15 (2018)
SEID aléatoire	v2.6.3 (2023)	✗	✗	Rel. 15 (2018)
NF Heartbeat	v2.0.0 (2020)	✗	v1.1.0 (2021)	Rel. 15 (2018)
TLS	v2.6.1 (2022)	v3.1.0 (2022)	v2.3.0 (2025)	Rel. 15 (2018)
OAuth2	✗	v3.4.0 (2024)	✗	Rel. 15 (2018)
Fonction réseau SCP	v2.4.9 (2022)	✗	✗	Rel. 16 (2020)

TABLE 2.1 – Date d’implémentation de mécanismes de sécurité dans les implémentations CN open-source vis à vis de leur date de parution dans les standards 3GPP.

protection contre le rejeu et de confidentialité. Plus précisément, IPSec en mode tunnel est requis pour N2 et N3, et n’est obligatoire pour N4 que si la sécurité n’est pas assurée par d’autres moyens. Parmi les implémentations open-source étudiées, seule free5GC propose IPSec. Toutefois, IPSec est uniquement disponible via les fonctions réseau N3IWF et TNGF, qui sont utilisées pour des équipements non conformes 3GPP. En pratique, la majorité des attaques proposées dans l’état de l’art que nous avons examinées déploient le cœur de réseau 5G avec un simulateur de RAN, tel que UERANSIM, qui se connecte directement à l’AMF et à l’UPF sans utiliser IPSec.

2.1.2 Session Report

Les procédures de *Session Report* sont définies dans la norme TS 29.244[TS 29.244 2026] et sont initiées par le SMF afin de synchroniser sa table de sessions locale avec celle de l’UPF. Régulièrement, et pour chaque session de sa table locale, le SMF envoie une requête sur l’interface N4 afin de vérifier l’état de la session du point de vue de l’UPF. Ce mécanisme n’a sans doute pas été initialement conçu à des fins de sécurité, mais y contribue néanmoins en supprimant les sessions obsolètes de l’UPF. Ainsi, les *Session Report* peuvent atténuer les attaques de type *PFCEP Session Establishment Flood* en supprimant les sessions frauduleuses qui auraient pu être injectées dans l’UPF par un attaquant. Ce mécanisme n’est implémenté que dans free5GC et OAI.

2.1.3 Allocation aléatoire des Identifiants de Session (SEID)

Le SMF et l’UPF maintiennent chacun une liste locale de Identifiant de Session (SEID) permettant de désigner les sessions qu’ils gèrent. Pour interagir avec une session existante, une NF initiatrice de communication doit connaître le SEID correspondant. La norme TS 29.244[TS 29.244 2026] spécifie que le SEID doit être codé sur 8 octets, ce qui implique en théorie une faible probabilité de collision si les valeurs sont uniformément réparties sur l’ensemble de l’espace. Néanmoins, même dans les versions les plus récentes, le 3GPP ne précise pas de méthode d’attri-

bution des SEID. En conséquence, les implémentations varient : free5GC et OAI attribuent des SEID de manière incrémentale à partir de 0, tandis qu'Open5GS les génère de manière pseudo-aléatoire mais n'utilise que 12 bits sur 64, ce qui les rend prédictibles.

2.1.4 NF Heartbeat

La norme TS 29.510[TS 29.510 2026] stipule que chaque NF enregistrée dans le NRF doit envoyer régulièrement des *heartbeats* afin de prouver qu'elle est toujours active. Grâce à ce mécanisme, si une fonction légitime a été désenregistrée par un attaquant, elle se réenregistrera automatiquement lors de l'envoi du prochain *heartbeat*. Ce mécanisme n'est pas conçu exclusivement à des fins de sécurité, mais il permet implicitement de prévenir certaines attaques de DoS basiques qui désenregistrent simplement des NF légitimes. Parmi les implémentations que nous avons étudiées, seule free5GC n'implémente pas les *NF heartbeats*.

2.1.5 Transport Layer Security (TLS)

Selon la norme 3GPP TS 33.501[TS 33.501 2026], TLS doit être implémenté par chaque NF avec des certificats côté client et côté serveur. Ce protocole permet l'authentification, le chiffrement et la protection de l'intégrité des données, réduisant fortement le risque qu'un attaquant interagisse de manière malveillante avec les API des autres NF. Ce mécanisme est présent dans toutes les implémentations étudiées, mais il est à chaque fois désactivé par défaut.

2.1.6 Autorisation des NF avec OAuth 2.0

L'autorisation des NF est renforcée par l'utilisation d'OAuth 2.0 pour les appels aux API REST. Alors que TLS garantit que la NF est connue et légitime, OAuth permet de préciser les permissions de chaque entité et d'identifier les services accessibles par une NF. Comme décrit dans la norme 3GPP TS 33.501[TS 33.501 2026], le NRF agit en tant que serveur d'autorisation et délivre des jetons chiffrés contenant des informations détaillées sur les privilèges de la NF appelante. Parmi les implémentations étudiées, seule free5GC utilise ces jetons OAuth. Toutefois, leur version actuelle ne vérifie pas les permissions contenues dans les jetons lors des requêtes, rendant caduque l'utilisation d'OAuth.

2.1.7 Présence du Service Communication Proxy (SCP)

Dans le plan de contrôle du CN, les NF communiquent selon quatre modèles architecturaux (A, B, C et D), qui diffèrent par la manière dont la découverte, la sélection et le routage sont effectués (3GPP TS 23.501 [TS 23.501 2026]). L'approche recommandée par le standard introduit une NF dédiée, appelée Service Communication Proxy (SCP), qui agit comme intermédiaire pour les communications SBI entre NF et ajoute une couche supplémentaire de contrôle d'accès et de supervision.

Parmi les implémentations étudiées, seule Open5GS suit le modèle de communication D proposé par 3GPP.

À travers les sections précédentes et le tableau 2.1, nous avons montré que le niveau de maturité des plateformes 5G disponibles dans l'état de l'art varie significativement. Chaque plateforme présente au moins trois mécanismes absents dans son implémentation, et les mécanismes manquants diffèrent d'une plateforme à l'autre. Cette hétérogénéité rend ces plateformes inadaptées comme outils intrinsèques d'évaluation des attaques et souligne la nécessité, dans le cadre de travaux de recherche orientés sur les attaques, de se référer aux spécifications 3GPP.

2.2 Distinction entre attaques réalistes et hypothèses irréalistes

Plusieurs travaux récents ont analysé des vulnérabilités 5G à travers des attaques théoriques et pratiques. Nous les classons en deux catégories : (i) les attaques exploitant des failles spécifiques aux implémentations open-source, et (ii) les attaques exploitant des faiblesses inhérentes aux spécifications 3GPP. L'objectif de cette classification est de mettre en évidence les biais de raisonnement qui conduisent à confondre des attaques irréalistes avec des failles majeures des standards. Le tableau 2.2 présente une catégorisation détaillée de ces attaques, en précisant les versions des plateformes utilisées, les mécanismes de sécurité manquants et le type de faille exploitée.

2.2.1 Attaques spécifiques aux implémentations

Coldwell et al. [Coldwell 2022] ainsi que CTD5G [Hoger 2026b] exploitent différentes NF de free5GC via des appels API malveillants qui incluent la manipulation de la gestion des NF, le scan et l'extraction de données utilisateurs. Ces attaques réussissent sur la version par défaut de free5GC, qui ne dispose ni de TLS, ni d'OAuth, ni de SCP, et ne permet donc pas d'authentifier correctement les NF. De plus, l'absence de mécanismes de *heartbeat* rend possible la suppression de NF légitimes qui se reconnecteraient automatiquement en temps normal.

Amponis et al. [Amponis 2022] décrivent deux attaques basées sur PFCP ciblant la gestion des sessions entre le SMF et l'UPF. La première classe d'attaques tente de modifier ou supprimer des sessions, nécessitant la connaissance du SEID correspondant. Ces attaques ont été démontrées avec succès sur Open5GS, mais l'implémentation n'utilise que 12 bits sur 64 pour le SEID, rendant collisions et découvertes par force brute beaucoup plus faciles. La seconde classe d'attaques proposée par Amponis et al. [Amponis 2022] vise à épuiser les ressources de l'UPF en établissant de manière répétée un grand nombre de sessions. Cette attaque n'est plausible que sur certaines implémentations, comme Open5GS, qui ne supportent pas les *PFCP Session Report* et ne suppriment donc pas les sessions inutilisées.

ZDI-CAN-18522 [TrendMicro 2023] décrit une vulnérabilité de réflexion de paquets permettant aux attaquants d'usurper l'identité d'un UE pour une communication montante. L'attaquant peut créer des paquets avec l'IP de l'UE victime comme source et les envoyer via un tunnel utilisateur valide. L'UPF transmet alors ce trafic vers un hôte Internet arbitraire, créant un canal montant falsifié au nom du dispositif. Cette attaque n'est possible qu'en l'absence d'authentification et d'intégrité et n'est donc pas possible sur une implémentation qui intègre IPSec conformément aux standards 3GPP.

Salazar et al. [Salazar 2021] présentent deux attaques spécifiques aux implémentations. La première envoie des messages NGAP mal formés pour déclencher une vulnérabilité des parseurs de free5GC et Open5GS, provoquant un crash de l'AMF. La seconde consiste à connecter et déconnecter de manière répétée un grand nombre d'UE, surchargeant le réseau et ciblant des déploiements 5G mal dimensionnés incapables de gérer un grand nombre d'utilisateurs.

Les attaques décrites dans ces travaux dépendent de conditions très spécifiques et exploitent souvent des implémentations encore immatures. Il est important de les distinguer des failles ciblant les standards, qui ont un impact plus large. Cette distinction est rarement établie dans la littérature.

2.2.2 Attaques spécifiques aux standards

Les spécifications 3GPP sont considérées comme exhaustives et couvrent de nombreux cas d'usage. Pourtant, plusieurs études ont identifié des vulnérabilités qui peuvent survenir même dans des déploiements respectant strictement les recommandations 3GPP.

Park et al. [Park 2022] exploitent le fait que l'encapsulation de tout autre trafic que celui des utilisateurs par la couche GTP-U constitue une zone ambiguë des spécifications 3GPP (TS 29.281)[TS 29.281 2026]. De fait, la plupart des UPF n'inspectent pas les en-têtes GTP-U imbriqués et considèrent le contenu comme une charge utile opaque, sans validation supplémentaire. Park et al. montrent ainsi que l'encapsulation de protocoles tels que PFCP, NGAP, ou même d'une autre couche GTP-U permet à un attaquant de transmettre des requêtes à des NF critiques du CN sans y avoir un accès direct. Ces attaques restent efficaces même lorsque IPSec est déployé car bien que ce dernier protège les communications entre acteurs légitimes, il n'est d'aucun secours si ces derniers sont compromis.

Fan et al. [Fan 2025] identifient deux vulnérabilités liées à des ambiguïtés de la spécification 5G. Lorsque le processus échoue, l'UE réinitialise le compteur à zéro, mais la clé elle-même n'est pas nécessairement renouvelée selon la TS 33.501[TS 33.501 2026]. Par conséquent, le même flux de clé peut être réutilisé, permettant à un attaquant de déchiffrer les messages de signalisation. De plus, selon la TS 24.501, le CN 5G peut faire primer la vérification d'identité sur celle d'intégrité, ce qui permet à un attaquant de forger certains paquets et de provoquer des DoS.

Chlosta et al. [Chlosta 2021] présentent l'attaque *SUCI-Catcher*, qui permet

de découvrir des identifiants utilisateurs et de les utiliser pour de la géolocalisation. L'attaque exploite le fait que les messages d'enregistrement NAS de l'UE sont échangés en clair avant l'établissement de clés, conformément à TS 33.501[TS 33.501 2026], ce qui permet à un gNB malveillant de lire le Subscriber Concealed Identifier (SUCI) et donc d'identifier les UE présents dans une zone donnée.

Hussain et al. [Hussain 2019] introduisent 5GReasoner, un outil de vérification formelle pour les protocoles du plan de contrôle. En l'appliquant aux spécifications 3GPP, ils ont découvert plusieurs attaques qu'un gNB malveillant peut exécuter. Ils ont notamment identifié des vulnérabilités de désynchronisation des compteurs NAS dans TS 33.501[TS 33.501 2026] qui permet plusieurs formes de DoS.

Ces attaques illustrent des vulnérabilités systémiques qui ne dépendent pas d'un contexte particulier et sont donc beaucoup plus susceptibles d'être exploitées en pratique. C'est précisément ce type d'attaques qui présente le plus d'intérêt pour la recherche, car il contribue significativement au renforcement et à la maturation continue du standard 3GPP.

2.3 Limites du cadre FiGHT™ en tant que framework de catégorisation

L'ambiguïté au sujet de la portée des attaques provient d'un manque de caractérisation rigoureuse de ces dernières. Les matrices MITRE constituent justement des cadres universels pour la compréhension et la caractérisation des cyberattaques. Elles proposent généralement à la fois une couverture exhaustive des attaques ainsi qu'une catégorisation à plusieurs niveaux de granularité, allant des tactiques, elles-mêmes déclinées en techniques, lesquelles peuvent être mises en œuvre sous forme d'attaques concrètes appelées procédures. FiGHT™[FIGHT 2026] en est une adaptation spécifique à la 5G, permettant de se concentrer sur les menaces propres à cet environnement. Néanmoins, l'outil FiGHT™ présente encore certaines limites que nous avons constatées en essayant de l'utiliser pour catégoriser différentes attaques de l'état de l'art :

- **Manque de cohérence dans le niveau de granularité :** Les catégories de techniques proposées par FiGHT™ présentent un niveau de granularité très hétérogène, allant de techniques très spécifiques comme « Fraudulent AMF Registration for UE in UDM » à des techniques beaucoup plus générales comme « Rootkit ».
- **Absence de techniques et concepts identifiés :** Certaines procédures ou attaques, telles que « Session Modification » [Amponis 2022], ne correspondent à aucune catégorie existante. Bien que la matrice fasse référence à certains concepts comme les sessions, elle omet des éléments techniques importants de même niveau, tels que les tunnels GTP-U.
- **Manque de référence aux standards 3GPP :** Le cadre FiGHT™ référence les mécanismes de sécurité associés à la plupart des techniques, mais

TABLE 2.2 – Catégorisation des attaques de l'état de l'art et positionnement relatif à la matrice MITRE FiGHT™.

MITRE FiGHT™		Procédure	Version de Plateforme	Mécanismes Manquants	Type de Faille
Tactique	Technique				
Attaques HTTP					
Découverte	FGT5003	Scan du CN [Coldwell 2022] (2022)	free5GC (v3.2)	TLS, Oauth, SCP	Implem.
Impacte	FGT5041	Désenregistrement de NF [Coldwell 2022] (2022)	free5GC (v3.2)	TLS, Oauth, SCP, NFHB	Implem.
Execution	FGT5007	Enregistrement de NF [Coldwell 2022] (2022)	free5GC (v3.2)	TLS, Oauth, SCP	Implem.
Impacte	FGT1498.503	Fuzzing d'API [Hoger 2026b] (2025)	free5GC (v4.0)	TLS, SCP	Implem.
Collection	FGT1557.504	Man-in-the-middle dans le CN [Hoger 2026b] (2025)	free5GC (v4.0)	TLS, SCP, NFHB	Implem.
Attaques PFCP					
Découverte	FGT5031	Fuzzing de SEID [Hoger 2026b] (2025)	free5GC (v4.0)	IPSec, AAS	Implem.
Impacte	FGT1499	Suppression / Création de Session [Amponis 2022] (2022)	Open5GS (v2.4)	IPSec, PSR	Implem.
Impacte		Modification de Session [Amponis 2022] (2022)	Open5GS (v2.4)	IPSec, AAS	Implem.
Collection, Impacte	FGT5008	Ecoute de trafic utilisateur [Amponis 2022] (2022)	Open5GS (v2.4)	IPSec, AAS	Implem.
Attaques GTP-U					
Evasion	FGT1599.505	Usurpation de Trafic Montant [TrendMicro 2023] (2023)	Non spécifié	IPSec	Implem.
Evasion	FGT1599.505	PFCP-in-GTP [Park 2022] (2021)	Spirent Land-slide C100-M4		Standard
Attaques NGAP					
Impacte	FGT1498.503	Injection de paquets malformés [Salazar 2021] (2021)	free5GC (v3.0) Open5GS (v2.3)	IPSec	Implem.
Attaques NAS					
Evasion		Rejeu de NAS SMC [Salazar 2021] (2021)	free5GC (v3.0) Open5GS (v2.3)	RIC	Implem.
Evasion		Manipulation du flux de clé [Fan 2025] (2025)	srsRAN (v25.04)		Standard
Collection	FGT1040.501	Récupération de SUCI [Chlost 2021] (2021)	free5gc (v3.0.5) srsRAN (21.04)		Standard
Impacte		Desynchronisation du compteur NAS [Hussain 2019] (2019)	Non spécifié		Standard

Légende :

NFHB=NF HeartBeat ; PSR=Procédure de Session Report ;

AAS=Allocation Aléatoire de SEID ; RIC=Resilience Insuffisante à la Charge

ne fait pas explicitement référence aux spécifications 3GPP, rendant difficile la détermination de l'origine de ces mécanismes dans les standards.

- **Absence d'information sur les versions concernées :** Les spécifications et les implémentations évoluent continuellement. Il est donc important de mentionner explicitement les versions concernées, à l'image de ce qu'il se fait pour les CVEs, afin de pouvoir déterminer facilement si une procédure reste applicable ou non.

FiGHT™ est déjà largement reconnu, mais ses lacunes rendent la caractérisation des attaques, de leur probabilité et de leurs impacts floue. Cela expliquerait en partie pourquoi ce framework n'est jamais utilisé dans les travaux que nous avons analysés dans l'état de l'art. En comblant les limites du framework tel que nous le proposons et en mettant en évidence l'intérêt d'une caractérisation rigoureuse, FiGHT™ pourrait devenir un outil précieux pour la communauté et permettrait d'améliorer la qualité des scénarios d'attaque présentés dans l'état de l'art.

2.4 Nouvelle classification propre aux enjeux de détections

En analysant les attaques issues de l'état de l'art et en les confrontant aux besoins de détection propres aux environnements 5G, nous avons identifié une nouvelle classification structurée selon 3 dimensions : sémantiques, séquentielles et topologiques. Cette caractérisation constitue l'origine du travail de cette thèse, car elle soulève de nouvelles problématiques en matière de détection.

2.4.1 Dimension sémantique

La dimension sémantique correspond à des anomalies où un paquet apparaît intrinsèquement anormal au regard de son contenu, en raison de combinaisons de paramètres inhabituelles ou incohérentes par rapport au trafic légitime. La nouveauté à l'origine de cette problématique réside principalement dans l'adoption des communications SBI ainsi que dans l'utilisation d'API REST qui introduisent un grand nombre de paramètres et de combinaisons possibles au sein des requêtes HTTP/2. Par exemple, certaines attaques de fuzzing, telles que celle représentée sur la figure 2.1, consistent à faire varier de manière systématique les paramètres des requêtes HTTP/2 et profiter de vulnérabilités des parseurs de l'API. Un autre cas d'anomalie sémantique est lié aux interactions entre différents protocoles. Comme plusieurs couches protocolaires coexistent en 5G, on peut observer des combinaisons de protocoles qui ne sont pas censées se produire. C'est par exemple le cas de l'attaque *PFCP-in-GTP* où on trouve un schéma d'encapsulation de protocoles qui n'est pas censé apparaître avec du trafic légitime.




FIGURE 2.1 – Exemple d'anomalie sémantique : une requête HTTP/2 avec une url non spécifiée dans les standards qui pourrait être le résultat d'une attaque de fuzzing.

2.4.2 Dimension topologique

Une anomalie sur la dimension topologique correspond aux situations où un paquet avec un contenu légitime devient suspect en raison des relations qu'il entretient avec d'autres paquets ou entités du réseau. Les valeurs de certains attributs, comme les adresses IP ou les identifiants d'instance de NF, n'ont pas d'intérêt intrinsèque, mais peuvent apporter des informations importantes quant au contexte d'un paquet. En analysant les relations entre des paquets partageant les mêmes paramètres, il est possible de mettre en évidence des schémas d'attaque qui ne seraient pas détectables en analysant les paquets indépendamment. La figure 2.2 présente un exemple de redirection de paquets résultant d'une attaque Man-in-the-middle (MITM), où l'adresse de destination d'un premier paquet est réutilisée comme adresse source pour un second paquet contenant exactement le même appel d'API. Or il n'existe aucune situation dans les réseaux 5G où ce type de redirection pourrait se produire de façon légitime. Pour détecter ce type d'anomalie il est donc nécessaire de prendre en compte le contexte topologique. Cette problématique existait déjà partiellement dans les réseaux antérieurs à la 5G, mais elle est aujourd'hui largement amplifiée par le caractère dynamique des entités réseau.

2.4.3 Dimension temporelle

Le trafic du plan de contrôle 5G, tel que défini par la norme 3GPP, suit des modèles d'échanges séquentiels, et toute déviation par rapport à ces séquences représente une anomalie. Ces déviations peuvent correspondre à la répétition de plusieurs paquets identiques, tel que représenté sur la figure 2.3, ou à l'ajout de paquets au sein d'une séquence donnée. Les attaques basées sur la dimension temporelle sont rarement spécifiques à la 5G mais comme ces attaques n'appartiennent pas exclusivement à une seule famille, les anomalies temporelles 5G ont aussi souvent des dimensions topologiques ou sémantique. Un exemple est le DDoS qui est une anomalie temporelle mais se différencie des DoS classiques par son aspect dis-




FIGURE 2.2 – Exemple d’anomalie topologique : une redirection de paquets résultant d’une attaque MITM.

tribué et donc topologique. Cette complémentarité entre les différentes dimensions d’anomalies souligne la nécessité d’une approche de détection multi-dimensionnelle.




FIGURE 2.3 – Exemple d’anomalie séquentielle : l’envoi répété d’un même paquet intervient rarement en 5G et peut être le résultat d’une attaque par inondation.

2.5 Conclusion

En raison du manque de visibilité sur le fonctionnement réel des réseaux 5G déployés par les grands opérateurs nationaux et internationaux, les travaux de recherche reposent majoritairement sur des plateformes open-source, qui constituent aujourd’hui les principaux outils disponibles pour l’expérimentation. Toutefois, ces plateformes restent encore insuffisamment matures pour permettre une évaluation pleinement réaliste des attaques. Dans ce contexte, en analysant l’état de l’art des attaques 5G, on constate que de nombreux travaux de recherche négligent les standards et se basent sur des vulnérabilités propres à ces environnements expérimentaux. De ce fait, de nombreuses attaques peu réalistes sont présentées comme des menaces critiques. Cette ambiguïté s’étend donc sur la définition de surface d’attaque réelle de la 5G et freine les avancées en matière de recherche en sécurité.

Pour remédier à cela, il serait nécessaire que les travaux de recherche s’accordent

collectivement sur une meilleure caractérisation des attaques, par exemple en s'appuyant systématiquement sur un cadre commun tel que la matrice FIGHT, qui pourrait remplir efficacement ce rôle moyennant quelques ajustements. Enfin, ce besoin de caractérisation, combiné à l'analyse des attaques issues de l'état de l'art, nous a conduit à proposer une nouvelle catégorisation fondée sur les dimensions de détection, rendue nécessaire par les changements introduits par la 5G.

Vers une formalisation adaptée à la détection d'anomalie multi-dimensionnelles

Sommaire

3.1	Objectifs et cadre de détection	26
3.2	État de l'art de la détection d'anomalies	27
3.2.1	Approche historique dans les réseaux traditionnels	27
3.2.2	Apprentissage profond appliqué aux réseaux 5G	28
3.2.3	Comparaison aux techniques des systèmes distribués	31
3.2.4	Synthèse	32
3.3	Méthodologie de formalisation	33
3.3.1	Extraction des features depuis la payload applicative	33
3.3.2	Transformation en graph	33
3.3.3	Encodage des arcs et nœuds	36
3.4	Détection d'anomalies dans des graphes	37
3.4.1	Introduction aux GNN	37
3.4.2	Etat de l'art des GNN	38
3.4.3	Formalisation adapté à l'utilisation de GNN dynamiques	43
3.4.4	Fonctionnement détaillé des GNN dynamique	44
3.4.5	Adaptation à notre cas d'utilisation	46
3.5	Encodage des paramètres contenus dans les arcs	48
3.5.1	Apprentissage supervisé et non supervisé	49
3.5.2	Tour d'horizon des techniques de NLP	50
3.5.3	Mise en place de l'encodage sémantique	53
3.5.4	Avantages et limites	54
3.6	Conclusion	55

Le passage aux réseaux 5G s'accompagne d'un changement de paradigme majeur, caractérisé par une architecture distribuée et une complexification des interactions entre entités. Par ailleurs, l'émergence d'anomalies sémantique, séquentielle et topologique impose de nouvelles exigences en matière d'analyse. Dans ce contexte, il devient nécessaire non seulement d'adopter une analyse fine au niveau des paquets, mais également de prendre en compte le contexte dans lequel s'inscrivent les

échanges. Or, cette problématique reste relativement récente dans le domaine des télécommunications, et les méthodes actuelles de détection d'anomalies apparaissent inadaptées à ce nouveau paradigme.

Dans ce contexte, nous proposons de représenter les échanges au sein des réseaux 5G sous la forme d'un graphe dynamique, permettant de capturer les interactions entre les différentes entités du réseau ainsi que l'évolution de ces interactions dans le temps. Cette formalisation nous permet d'exploiter des techniques issues du domaine des GNN, intrinsèquement adaptées à l'analyse des interactions complexes. Nous nous intéressons plus particulièrement aux GNN dynamiques, qui intègrent nativement la dimension temporelle.

3.1 Objectifs et cadre de détection

Dans nos travaux, nous nous plaçons du point de vue de l'opérateur d'un réseau 5G et nous nous intéressons à la détection d'anomalies en nous concentrant exclusivement sur le trafic de contrôle échangé entre les entités du réseau, qu'il s'agisse du cœur de réseau ou du RAN. Le trafic utilisateur n'est pas pris en compte, car il ne présente pas de spécificités propres à l'architecture 5G et ne relève pas de la responsabilité directe du fournisseur d'accès réseau.

En se plaçant du point de vue de l'opérateur, nous supposons que celui-ci possède l'ensemble des NF et dispose d'un accès complet au trafic de contrôle. Dans l'architecture 5G, la fonction SCP agit comme un intermédiaire dans les échanges entre les différentes NF, notamment pour le routage des requêtes et la vérification des autorisations d'accès. Dans ce contexte, il est raisonnable de considérer que l'opérateur peut observer l'intégralité du trafic de contrôle en déployant des sondes au niveau des SCP, qui constituent des points d'observation privilégiés des interactions entre NF.

Ce trafic est généralement chiffré, par exemple via TLS sur le SBI ou via IPsec pour certains canaux, tels que N3 ou N4, reposant sur des protocoles spécifiques à la 5G. Cependant, en adoptant le point de vue de l'opérateur, nous supposons disposer des clés de chiffrement nécessaires pour accéder au contenu de ces échanges en clair.

L'objectif serait de pouvoir exécuter nos modèles de détection en temps réel. Malgré les débits élevés offerts par la 5G, le volume de données est majoritairement porté par le trafic utilisateur, qui n'entre pas dans le périmètre de cette étude. Le trafic de contrôle, lui, est principalement composé de messages liés aux changements d'état des entités du réseau, qu'il s'agisse d'UE ou de NF, et ont une fréquence d'occurrence plus modérée. Par conséquent, bien que le surcoût induit par nos modèles puisse avoir un impact sur les performances, il est raisonnable de supposer que les ressources disponibles sont suffisantes pour permettre un traitement en temps réel.

La remédiation des anomalies détectées ne relève pas du périmètre de cette thèse et est considérée comme une brique fonctionnelle distincte. Nous nous concentrons

exclusivement sur la détection des anomalies et générons des alertes qui pourront être exploitées de manière similaire à celles produites par un IDS classique.

L'objectif de ces travaux n'est pas de concevoir un système de détection absolu et entièrement autonome. En effet, une anomalie ne constitue pas nécessairement le signe d'une activité malveillante et peut résulter d'une mise à jour, d'une erreur de configuration ou encore d'une interconnexion avec un système tiers, comme dans le cas du roaming. Dans ce contexte, la distinction entre une anomalie bénigne et une réelle attaque requiert in fine une expertise humaine. Par conséquent, l'un des aspects essentiels de nos travaux est de proposer un système interprétable, venant assister une expertise humaine plutôt que de la remplacer.

3.2 État de l'art de la détection d'anomalies

Cette section propose un panorama des travaux de recherche consacrés à la détection d'anomalies. Dans un premier temps, nous présenterons les limites des approches traditionnelles appliquées à notre problématique, en montrant que les objectifs visés ainsi que les contraintes opérationnelles diffèrent sensiblement de notre contexte d'étude. Nous nous intéresserons ensuite aux méthodes développées pour la détection d'anomalies dans les réseaux 5G, afin d'évaluer l'état actuel de la recherche sur notre problématique spécifique et identifier les limites des travaux existants. Enfin, nous adopterons une perspective plus large en examinant les travaux issus du domaine des systèmes distribués qui, comme nous l'avons montré précédemment, présentent de nombreuses similarités structurelles et fonctionnelles avec les architectures 5G.

3.2.1 Approche historique dans les réseaux traditionnels

La détection d'attaques au sein des réseaux est historiquement assurée par des IDS. Ces systèmes reposent généralement sur une analyse du trafic agrégé sous forme de flux, plutôt qu'au niveau des paquets individuels. Cette approche permet d'extraire des métriques globales et d'effectuer des analyses de volumétrie, par exemple afin de détecter des variations significatives du volume de trafic ou repérer des signatures d'attaques connues.

Parmi les IDS les plus connus on retrouve Snort [Snort 2026], Zeek [Zeek 2026] et Suricata [Suricata 2026], qui reposent sur des règles prédéfinies pour identifier des motifs (aussi appelés signatures) d'attaques spécifiques dans le flux réseau. Ce sont la plupart du temps des outils open-source qui bénéficient d'une large communauté dont la contribution est essentielle au maintien de leur base de signatures.

Des approches fondées sur l'apprentissage automatique supervisé ont également été proposées pour la détection d'intrusion, notamment à l'aide de réseaux bayésiens [Koc 2012], de Machines à Vecteurs de Support (SVM) [Vijayanand 2018] ou encore d'arbres de décision [Moon 2017]. Ces méthodes présentent l'avantage d'être relativement transparentes, interprétables et efficaces pour détecter des attaques déjà connues.

Parmi les approches non-supervisées, Münz et al. [Münz 2007] proposent, par exemple, de découvrir des motifs anormaux en adaptant l'algorithme K-Means au trafic réseau, permettant ainsi de regrouper les données en fonction de leur similarité sans nécessiter d'étiquettes. Néanmoins, les caractéristiques utilisées en entrée restent relativement limitées et se restreignent notamment au nombre de paquets, au volume d'octets ainsi qu'aux adresses source et destination. Une telle approche permet d'identifier des motifs anormaux liés à la volumétrie. Toutefois, elle ne prend en compte ni le contenu sémantique des paquets ni le contexte des échanges.

Ariu et al. [Ariu 2011] proposent quant à eux d'utiliser des modèles de Markov cachés afin de modéliser le trafic réseau sous forme de séquences d'octets. Ces modèles apprennent des probabilités de transition à partir de trafic bénin, puis évaluent dans quelle mesure un trafic observé s'en écarte. Cependant, les séquences considérées sont limitées à des fenêtres de tailles relativement réduites, ce qui empêche la capture de dépendances temporelles à long terme. De plus, cette approche ne permet pas de modéliser explicitement les interactions entre paquets.

Cette étude met en évidence le décalage entre les approches historiques de détection d'intrusion et les besoins spécifiques liés aux réseaux 5G. Les méthodes traditionnelles, principalement conçues pour l'analyse agrégée de flux, se révèlent peu adaptées à un environnement distribué et logiciel. Ainsi, les IDS traditionnels restent généralement limités, soit par le manque d'expressivité des caractéristiques considérées, soit par une modélisation insuffisante des dépendances temporelles et des interactions complexes entre paquets. Ces limites justifient ainsi la nécessité de développer des méthodes plus adaptées aux spécificités des architectures 5G.

3.2.2 Apprentissage profond appliqué aux réseaux 5G

Après avoir présenté les limites des approches traditionnelles de détection d'intrusion, nous nous intéressons désormais aux méthodes spécifiquement conçues pour les réseaux 5G. L'objectif est d'analyser dans quelle mesure ces travaux prennent en compte les dimensions sémantique, séquentielle et topologique. Cette analyse permettra d'identifier les avancées récentes du domaine, mais également les limitations persistantes des approches actuelles.

Parmi les travaux de détection spécifiques à la 5G, Kale et al. [Kale 2023] proposent d'utiliser des Réseaux de Neurones Convolutionnels (CNN) en considérant les octets d'un paquet comme une image sur laquelle sont ensuite étudiées des variations structurelles. Les modèles CNN obtiennent de très bonnes performances dans de nombreux domaines, y compris dans des tâches qui ne relèvent pas intrinsèquement de la vision par ordinateur [Ganesh 2017]. Toutefois, comme ils n'interprètent pas le contenu des données, leur capacité de détection se limite à un sous-ensemble d'attaques sémantiques dans lesquelles les valeurs s'écartent fortement du trafic normal. Ils ne permettent donc pas de détecter des variations légères de valeurs d'identifiants comme les adresses IP ou les Identifiants Utilisateurs (IMSI). De plus, le travail présenté par Kale et al. se concentre uniquement sur la détection sémantique et ne prend pas en compte le contexte des échanges. Lam et al. [Lam 2020]

ajoutent un contexte temporel à leur CNN en alimentant ses sorties dans un Réseau de Neurones Récurrent (RNN). Cependant, en plus de ne pas être satisfaisant sur le domaine sémantique, leur modèle ne prend pas en compte l'identité des acteurs impliqués dans les échanges et n'est donc pas capable de détecter des attaques relationnelles.




FIGURE 3.1 – Représentation d'une séquence d'événement bénins entre différentes entités tel que présenté par ADSeq-5GCN [Tian 2023].

AutoGuard [Madi 2021] et ADSeq-5GCN [Tian 2023] modélisent les échanges réseau sous forme de séquences d'interactions entre entités du réseau tel que représenté sur figure 3.1. Ces modèles utilisent ensuite des RNN afin de capturer les dépendances temporelles et prédire les interactions futures. Leurs approches intègrent l'identité des entités communicantes, ce qui leur permet de prendre en compte, dans une certaine mesure, le contexte topologique des interactions. Cependant, elles rencontrent des difficultés à modéliser efficacement les dépendances relationnelles lorsque les interactions sont éloignées dans le temps. De plus, le principal problème est que leur formalisme n'intègre pas le contenu des paquets et ne considère donc aucunement la dimension sémantique. 5GCCGuard [Tan 2025] tente de pallier cette limitation en enrichissant leurs séquences par l'intégration de l'URL associée à chaque message. Bien qu'elle apporte une information sémantique supplémentaire, cette approche demeure très limitée car l'information propre à l'URL ne représente qu'une fraction du contenu réel des paquets et n'est applicable qu'au trafic HTTP.

Prov5GCC [Pacherkar 2024] propose de son côté de représenter le trafic sous forme de graphe de provenance. Dans cette représentation, illustrée sur la figure 3.2, les nœuds correspondent aux entités du réseau et chaque message échangé entre ces entités est modélisé par une arête, à laquelle est associé le contenu du paquet. La formalisation en graphe est particulièrement adaptée à l'analyse topologique des interactions du réseau. Cependant, elle ne modélise pas explicitement la dimension temporelle des échanges, ce qui restreint sa capacité à capturer l'évolution dynamique des interactions. De plus, le fait d'agréger le payload au niveau des arêtes




FIGURE 3.2 – Trafic de contrôle 5G formalisé par Prov5GC [Pacherkar 2024] en tant que graphe de provenance.

limite fortement l'exploitation de l'information contenue dans les paquets. Dans leur cas la payload est utilisée par un algorithme de détection heuristique spécifique à chaque attaque, ce qui rend l'approche relativement lourde et peu adaptée à des environnements complexes.




FIGURE 3.3 – Pipeline de GSAD [Wang 2023] représentant leur formalisation ainsi que les trois modules de détections traitant respectivement les dimensions sémantique, séquentielle et topologique.

GSAD [Wang 2023] propose également de modéliser les données sous forme de graphe de manière similaire à Prov5GC [Pacherkar 2024]. La principale différence réside dans la représentation du contenu des arêtes. Au lieu de l'encoder sous forme de dictionnaire monolithique, les auteurs le transforment en flux d'octets structuré comme une image. Cette représentation leur permet d'utiliser un CNN pour encoder chaque paquet et analyser sa dimension sémantique. Les représentations sémantiques sont ensuite injectées dans un GNN afin de modéliser les interactions entre

les paquets, puis dans un RNN pour capturer les dépendances temporelles. À notre connaissance, GSAD [Wang 2023] est la seule approche de détection d’anomalies 5G qui considère simultanément les trois dimensions de détection. La principale limite de leur approche réside dans le fait que, comme évoqué précédemment, les CNN ne permettent qu’une analyse relativement superficielle de la dimension sémantique des paquets. La Figure 3.3 illustre l’architecture générale du pipeline proposé par GSAD et met en évidence les trois composantes du modèle correspondant respectivement aux trois dimensions.

Référence	Sémantique	Séquentiel	Topologique
Kale et al. [Kale 2023]	Partiel	Non	Non
Lam et al. [Lam 2020]	Partiel	Oui	Non
AutoGuard [Madi 2021]	Non	Oui	Partiel
ADSeq-5GCN [Tian 2023]	Non	Oui	Partiel
5GCGuard [Tan 2025]	Non	Oui	Partiel
Prov5GC [Pacherkar 2024]	Partiel	Non	Partiel
GSAD [Wang 2023]	Partiel	Partiel	Oui

TABLE 3.1 – Comparaison des approches de l’état de l’art de détection d’anomalies 5G selon les dimensions considérées.

Le tableau 3.1 résume les différentes approches de détection d’anomalies dans les réseaux 5G, en mettant en évidence les dimensions sémantique, temporelle et topologique prises en compte par chacune d’elles. L’état de l’art montre que peu d’approches considèrent simultanément les trois dimensions. A travers les travaux tels que GSAD [Wang 2023] et Prov5GC [Pacherkar 2024], les GNN semblent particulièrement adaptés pour modéliser les interactions entre entités. À l’inverse, aucune des modélisations proposées ne semble réellement adaptée au traitement du contenu sémantique des paquets, celui-ci étant le plus souvent considéré comme un bloc monolithique.

3.2.3 Comparaison aux techniques des systèmes distribués

Enfin, nous prenons un peu de recul en nous intéressant aux travaux issus du domaine des systèmes distribués. Comme évoqué précédemment, les architectures 5G changent de paradigme et présentent maintenant de nombreuses similarités avec ces systèmes fortement distribués et dynamiques. Nous examinons donc dans cette section les principales approches de détection d’anomalies proposées dans ce domaine, afin d’identifier dans quelle mesure elles exploitent les spécificités de ces architectures et les enseignements qu’il est possible d’en tirer pour notre problématique.

Parmi les approches exploitant la nature distribuée des infrastructures, on retrouve notamment des travaux basés sur le Federated Learning (FL). DioT [Nguyen 2019] et VFL [Wei 2024], par exemple, promeuvent les avantages de la fédération dans les systèmes distribués, notamment en termes de passage à l’échelle,

de confidentialité et de décentralisation de l'apprentissage. Cependant, leur contribution se concentre principalement sur le mécanisme de fédération lui-même. Les modèles utilisés restent relativement classiques et ne couvrent généralement qu'une partie des dimensions nécessaires à une détection complète des anomalies. DioT [Nguyen 2019] s'appuie ainsi sur des RNN de type Gated Recurrent Unit (GRU) pour modéliser les dépendances temporelles, tandis que VFL [Wei 2024] exploite GraphSAGE [Hamilton 2018] afin de capturer les relations structurelles entre entités. Dans ce contexte, le FL apparaît davantage comme une extension permettant de rendre la détection scalable et réaliste d'un point de vue opérationnel que d'une méthode de détection à part entière.

Dans la littérature des systèmes distribués, on retrouve également de nombreuses approches fondées sur l'analyse de logs systèmes, telles que [Liu 2010, Tan 2023]. Toutefois, ces méthodes présentent plusieurs limitations. Bien qu'elles permettent d'observer l'activité du système à un niveau relativement élevé, les logs constituent une représentation indirecte et partielle des événements réseau. Ils dépendent fortement des implémentations logicielles et peuvent contenir du bruit, des informations manquantes ou des incohérences. Ainsi, certains comportements anormaux peuvent ne jamais être journalisés, ce qui limite intrinsèquement la capacité de détection. Une piste complémentaire consiste à combiner différentes sources d'observation, comme proposé par Bogatinovski et al. [Bogatinovski 2021], en fusionnant logs et traces afin d'enrichir la représentation des événements. Cependant, cette approche introduit également une complexité supplémentaire dans la gestion et la corrélation des données, et peut conduire à une surcharge informationnelle.

Enfin, une part importante des travaux de la littérature s'intéresse aussi aux GNN [Protogerou 2021, Pazho 2024] et plus spécifiquement sur des approches dynamiques [Liu 2023]. Cette convergence entre les domaines de la 5G et des systèmes distribués confirme que la modélisation par graphes constitue un cadre particulièrement pertinent pour capturer les interactions complexes en intégrant à la fois les dimensions structurelles et temporelles des échanges.

3.2.4 Synthèse

L'analyse de la littérature sur la détection d'anomalies réseau met en évidence que les approches traditionnelles ne sont pas adaptées à notre problématique, principalement en raison d'un niveau de granularité trop élevé qui empêche la capture de comportements subtils. En se focalisant sur des travaux spécifiquement dédiés à la 5G, on constate par ailleurs qu'aucune approche ne propose à ce jour un formalisme unifié permettant de prendre en compte simultanément les trois dimensions de détection définies dans cette thèse. Néanmoins, plusieurs éléments issus de l'état de l'art convergent vers des directions prometteuses. En particulier, des travaux tels que GSAD, ainsi que les approches issues des systèmes distribués, montrent que les représentations par graphes et les GNN font désormais l'objet d'un consensus croissant. Ces modèles apparaissent comme des outils particulièrement adaptés pour représenter la structure complexe des interactions et pourraient constituer une

base solide pour répondre à notre problématique.

3.3 Méthodologie de formalisation

Nous avons vu que le formalisme en graphe proposé par GSAD consiste à regrouper l'ensemble du contenu des paquets dans un bloc monolithique associé à une arête, ce qui limite fortement la capacité à exploiter correctement la dimension sémantique. Dans ce contexte, nous proposons une représentation plus fine du trafic, en décomposant le contenu des paquets en nœuds indépendants correspondant chacun à un paramètre différent. Nous détaillons à présent notre méthodologie de formalisation. Nous commencerons par l'extraction des caractéristiques à partir du trafic de contrôle, puis nous présenterons leur transformation en graphes.

3.3.1 Extraction des features depuis la payload applicative

Comme notre objectif est principalement d'analyser le contenu applicatif des paquets, nous extrayons la payload applicative pour chaque paquet. Les seules informations non applicatives conservées concernent la couche IP, utilisées comme identifiant afin de discriminer les différentes entités du réseau. Cette approche n'est pas idéale, car elle est sensible au *spoofing*. Toutefois, dans un cadre opérationnel, ces adresses pourraient être remplacées par des identifiants plus robustes, tels que des empreintes ou des hash, qui pourraient représenter les entités de manière unique.

Pour récupérer le contenu des payloads, nous utilisons *Scapy*, qui permet de parser les paquets réseau et de générer, pour chacun d'eux, une représentation sous forme de dictionnaire associant les noms des paramètres à leurs valeurs respectives.

Une des problématiques du trafic applicatif est la présence d'imbrication dans le contenu des données de la payload. En effet, les paquets HTTP/2 contiennent couramment des structures JSON avec des données hiérarchisées. Conserver explicitement le chemin d'imbrication dans une modélisation en graphe nécessiterait d'introduire de nouveaux types de nœuds et donc de diluer l'information produite par le contenu lui-même. Or, même si l'imbrication est utile pour différencier des paramètres, elle reste secondaire par rapport aux valeurs elles-mêmes.

Pour gérer ce problème, nous avons donc choisi d'aplatir les dictionnaires extraits des payloads en construisant le nom de chaque paramètre de feuille comme la concaténation de ses clés précédentes, séparées par des délimiteurs. On obtient ainsi des identifiants de paramètres composés, par exemple `http2.headers.content-type`, permettant de désigner le champ `content-type` d'un paquet HTTP/2. Cette approche permet de conserver l'information d'imbrication en tant que nom de paramètre tout en maintenant une structure suffisamment simple pour notre formalisation en graphe.




FIGURE 3.4 – Exemple de transformation de paquets en sous-graphes. Les nœuds mauves représentent les valeurs des paramètres, tandis que les nœuds bleus représentent les paquets eux-mêmes.

3.3.2 Transformation en graph

Au lieu de représenter un paquet comme une arête entre deux entités, nous le modélisons comme un sous-graphe, où chaque paramètre est un nœud. Chacun de ces nœuds paramètre est relié à un nœud central qui représente le paquet. Chaque nœud paramètre contient la valeur du paramètre, tandis que l'arête reliant ce nœud au nœud central contient l'information du nom du paramètre correspondant. Lors de la création d'un sous-graphe représentant un paquet, de nouveaux nœud paramètres sont créés seulement s'il n'existaient pas encore dans le graphe global. Dans le cas contraire, le nœud existant est réutilisé. Ce mécanisme permet de relier progressivement les différents sous-graphes entre eux à travers leurs paramètres partagés. La figure 3.4 illustre le processus de transformation de deux paquets en deux sous-graphes. Ces deux paquets partagent certains paramètres et leurs sous-graphes respectifs se retrouvent donc connectés.

Dans notre formalisme, la réception de nouveaux paquets ne peut entraîner que l'ajout de nouveaux nœuds et d'arêtes, sans jamais modifier ni supprimer ceux déjà présents. De plus, nous avons seulement deux types de nœuds : paramètres et centraux. Ces derniers ne peuvent jamais être reliés directement à d'autres nœuds du même type et notre formalisme est donc un graphe biparti purement additif.

Cette décomposition permet de connecter des attributs issus de paquets différents en s'appuyant sur des caractéristiques communes, plutôt que seulement sur l'identité des participants. Une telle représentation offre un niveau de granularité très fin et permet de capturer des interactions plus riches entre les caractéristiques des paquets. Enfin, cette approche permet également d'identifier précisément les paramètres à l'origine d'un comportement anormal et se révèle donc, par construction, hautement interprétable.

Nous allons maintenant analyser la représentation des anomalies de chaque dimension une fois adaptés à notre formalisme.

3.3.2.1 Anomalies sémantiques




FIGURE 3.5 – Anomalie sémantique et sa représentation sous forme de graphe.

La figure 3.5 illustre une anomalie sémantique dans laquelle un champ inhabituel apparaît. Dans le cas présent, il s'agit du paquet P3 dont la valeur du champs *nf-type* n'existe pas en 5G. Cette anomalie peut être détectée en le comparant aux autres paquets de même nature. On observe par exemple que les paquets P1 et P2, qui sont, comme P3, des requêtes vers l'endpoint *add-nf*, possèdent des valeurs identiques pour le champ *nf-type*, alors que P3 s'en écarte. Un modèle de détection ayant appris la structure usuelle de ce type de paquet pourrait ainsi identifier l'anomalie en observant uniquement le sous-graphe associé à P3.

3.3.2.2 Anomalies topologiques




FIGURE 3.6 – Anomalie topologique et sa représentation sous forme de graphe.

Sur la figure 3.6, on observe un exemple d'attaque de type MITM, où un paquet P1, initialement envoyé à une première adresse, génère l'envoi d'un nouveau paquet P2 identique (ici simplifié par le fait qu'il s'agisse du même endpoint). Ce nouveau paquet a comme source la destination du paquet précédent et comme destination une nouvelle adresse. Ce cas ne peut normalement pas survenir en 5G, car il n'existe aucun scénario légitime de redirection de trafic de ce type. Le paquet P2 est une copie de P1 et paraît donc légitime pris individuellement. Il est ici nécessaire de prendre en compte le contexte de redirection afin de détecter l'anomalie.

3.3.2.3 Anomalies séquentielles

Enfin, sur la figure 3.7, on observe un exemple d'anomalie séquentielle. Dans ce cas, le contenu et les interactions des paquets sont normaux et la caractéristique




FIGURE 3.7 – Anomalie séquentielle et sa représentation sous forme de graphe.

anormale concerne uniquement leur ordre d'arrivée. Le problème est que le formalisme actuel ne modélise pas explicitement la dimension temporelle. Il serait possible de l'intégrer en ajoutant à chaque sous-graphe un nœud représentant l'horodatage du paquet, mais avec cette approche la dimension temporelle serait confondue avec les autres paramètres alors qu'elle est particulièrement importante. Il est donc nécessaire de proposer une modélisation permettant d'intégrer le temps de manière plus explicite.

3.3.3 Encodage des arcs et nœuds

Pour être exploitables par des modèles de détection, le contenu des nœuds et des arêtes doivent être encodés sous forme de vecteurs numériques. Pour les arêtes, le vecteur est construit à partir du nom du paramètre porté par l'événement, lequel est toujours de type textuel. L'espace des noms de paramètres possibles, le vocabulaire, est considéré comme statique car il dépend de l'implémentation de l'infrastructure 5G au moment de l'entraînement du modèle. Ainsi, si le dataset d'entraînement est suffisamment exhaustif, il est possible de couvrir la majorité des noms de paramètres susceptibles d'apparaître. Cependant, lorsqu'un paramètre inconnu est rencontré, deux cas peuvent être envisagés. Il peut s'agir d'une évolution de l'implémentation, auquel cas des anomalies peuvent être observées de manière légitime tant que le modèle n'a pas été ré-entraîné. Il peut également s'agir d'une tentative d'attaque, par exemple de fuzzing, qui exploite des appels API malformés et introduisant des noms de paramètres n'existant pas dans la requête. Dans ce cas nous avons une anomalie sémantique sur le nom des paramètres. Dans le cas des noms de paramètres, leur vocabulaire est donc ici statique et avec une grande valeur sémantique.

Pour les nœuds, le vecteur est construit à partir de la valeur du paramètre au lieu de son nom. Ces valeurs peuvent correspondre aussi bien à des variables catégorielles, comme des méthodes HTTP, qu'à des identifiants uniques, comme des adresses IP. L'analyse de l'échantillon collecté dans notre dataset montre qu'environ 90% des valeurs de paramètres correspondent à des identifiants uniques. Ces identifiants sont générés au cours de l'exécution du système et ne peuvent donc pas être exhaustivement rencontrés lors de l'entraînement. Le vocabulaire des valeurs de paramètres est donc dynamique. En plus d'être indénombrables, les valeurs de

paramètres ne possèdent pas de valeur sémantique intrinsèque. Leur sémantique est plutôt liée à leur utilisation dans les échanges et peut donc être inférée à travers l'analyse de la structure du graphe, comme illustré dans la figure 3.5. Les adresses IP, par exemple, n'ont pas d'intérêt intrinsèque en elles-mêmes, mais il est possible d'inférer si elles appartiennent à un attaquant en observant les paquets qu'il envoie et reçoit.

Dans nos représentations, seule l'information portée par les arêtes sera donc conservée explicitement. L'information associée aux nœuds pourra quant à elle être reconstruite implicitement par le GNN à travers les convolutions successives et l'agrégation des informations de voisinage.

3.4 Détection d'anomalies dans des graphes

La détection d'anomalies à l'aide de GNN constitue un domaine de recherche en pleine expansion, connaissant un développement significatif ces quinze dernières années. Nous introduirons dans cette section les principes fondamentaux de ces modèles et de leurs principales variantes. Nous examinerons ensuite l'état de l'art des GNN. Enfin, nous verrons comment adapter notre formalisme à sa variante la plus adaptée à notre problème, à savoir les graphes dynamiques continus.

3.4.1 Introduction aux GNN



FIGURE 3.8 – Illustration du processus de convolution. La première figure représente le graphe à son état initial. Dans la deuxième, une première convolution est appliquée. On observe que les informations des nœuds feuilles sont agrégées et propagées à leurs voisins directs. Dans la troisième, une deuxième convolution est réalisée, et les informations précédemment propagées sont à nouveau diffusées jusqu'au nœud central du graphe. Après ces deux convolutions, le nœud central contient une représentation de son voisinage complet à distance 2.

Le fonctionnement des GNN est très proches de celui des CNN présentés précédemment. Dans les deux cas, le principe repose sur une agrégation locale de l'information, la principale différence étant le formalisme. Dans une image, cette agrégation s'effectue sur des voisinages de pixels, tandis que dans un graphe elle s'applique au voisinage des nœuds. Ces domaines sont donc très proches au point que certains travaux proposent de traiter une image comme un graphe, en considé-

rant chaque pixel comme un nœud relié à ses voisins par un arc, sur lequel appliquer des GNN. Néanmoins, cette approche reste relativement marginale [Han 2022].

Que ce soit pour les CNN ou les GNN, l'idée fondamentale de ces modèles est que chaque itération du processus de convolution, appelé *Message Passing* pour les GNN, permet de diffuser l'information d'un individu à ses voisins directs. En procédant de manière récursive, chaque couche de convolution propage cette information à une distance croissante, augmentant progressivement le champ de réception des représentations. La figure 3.8 illustre ce processus de diffusion de l'information réalisé par deux convolutions successives.

En apprentissage sur graphes, on distingue généralement les approches transductives et inductives selon les informations disponibles au moment de l'entraînement. En mode transductif, le modèle connaît déjà toutes les données du dataset, y compris les nœuds à prédire et leur voisinage, mais leurs labels restent inconnus. À l'inverse, l'apprentissage inductif suppose que les nœuds à traiter pendant le test ne sont pas visibles durant l'entraînement. Le modèle doit donc apprendre des règles générales capables de se transférer à de nouvelles structures. Le choix entre ces deux paradigmes dépend fortement de la tâche considérée. Mais, de par leur nature évolutive, l'apprentissage inductif est souvent privilégié dans les travaux sur les graphes dynamiques, car il permet de généraliser à des nœuds et interactions apparaissant au cours du temps.

Parmi les tâches courantes dans l'état de l'art des graphes, on retrouve principalement la classification, la régression et le clustering. Ces tâches peuvent être appliquées à différents niveaux de granularité, que ce soit sur des nœuds, des arêtes ou des graphes entiers. La classification consiste à attribuer un label discret à un élément du graphe, tandis que la régression vise à prédire une valeur continue associée à celui-ci. Le *clustering*, quant à lui, a pour objectif de regrouper les éléments du graphe selon leurs représentations apprises. On retrouve également la tâche de prédiction de lien, qui consiste à estimer la probabilité d'existence d'une connexion entre deux entités du graphe. Cette tâche est particulièrement importante dans les graphes dynamiques, où l'objectif est d'anticiper l'évolution des interactions au cours du temps. C'est cette dernière famille de tâches qui nous intéresse particulièrement, puisque notre objectif est d'estimer, pour chaque valeur de paramètre, la probabilité qu'elle apparaisse et qu'elle soit donc considérée comme légitime.

L'étendue des problèmes pouvant être modélisés sous forme de graphes, ainsi que la diversité des tâches applicables, expliquent la croissance rapide de la littérature sur ce sujet.

3.4.2 Etat de l'art des GNN

Nous analyserons désormais l'état de l'art concernant les GNN. Notre étude s'attachera à l'évolution historique de ces approches, en commençant par les GNN statiques. Nous examinerons ensuite les graphes dynamiques et les différentes architectures de GNN adaptées à la manipulation de ces types de graphes. Enfin, nous analyserons les approches non-supervisées, indépendamment de la dimension

temporelle, afin d'évaluer la capacité des GNN à traiter des données non étiquetées.

3.4.2.1 GNN traditionnels

Le domaine des GNN est relativement récent et s'est fortement développé au cours de la dernière décennie. Le concept de réseaux de neurones sur graphes a été formellement introduit pour la première fois en 2008 par Scarselli et al. [Scarselli 2009], qui ont proposé un framework pour l'apprentissage sur des données structurées en graphe, basé sur des mécanismes itératifs de propagation et d'agrégation d'états. Des travaux ultérieurs ont considérablement amélioré la praticabilité et la scalabilité de cette formulation initiale. En particulier, Kipf et Welling [Kipf 2017] ont introduit les Graph Convolutional Networks (GCN), qui simplifient le processus de propagation des messages en linéarisant l'agrégation de voisinage.

Dans leur formulation moderne, les GNN peuvent être vus comme réalisant des convolutions basées sur le voisinage, où l'information provenant des nœuds adjacents est agrégée afin d'enrichir la représentation de chaque nœud avec un contexte local. La plupart des architectures contemporaines de GNN suivent le paradigme de *message passing* proposé par Gilmer et al. [Gilmer 2017], composé de trois phases principales : la construction des messages à partir des embeddings des nœuds, l'agrégation des messages provenant des voisins, et la propagation (ou mise à jour) de l'information agrégée pour produire de nouvelles représentations des nœuds.

Sur la base du cadre Message Passing Neural Networks (MPNN) standard, plusieurs extensions ont été proposées. Par exemple, les Graph Attention Networks (GAT) [Veličković 2018] introduisent des mécanismes d'attention qui attribuent des poids adaptatifs aux nœuds voisins lors de l'agrégation. GraphSAGE [Hamilton 2018] permet un apprentissage inductif sur des nœuds jusqu'alors inconnus en échantillonnant un voisinage de taille fixe et en appliquant des fonctions d'agrégation apprenables telles que la moyenne, le pooling ou des agrégateurs basés sur LSTM. D'autres variantes notables incluent les Graph Isomorphism Networks (GIN) [Xu 2019] qui utilisent une agrégation par somme injective et des MLP pour mieux distinguer la structure globale du graphe.

Cependant, la plupart de ces architectures de GNN sont principalement conçues pour des graphes statiques. Or, nos données évoluent dans le temps et le graphe associé est donc dynamique. Nous nous intéressons donc aux modèles de graphes dynamiques, une classe encore plus récente de GNN. Parmi ces modèles, on distingue deux grandes catégories selon la granularité temporelle.

3.4.2.2 GNN Dynamiques

La première famille de graphes dynamiques, les Réseaux de Graphes à Temps Discret (DTGN), constitue l'approche la plus directe pour intégrer l'information temporelle. Dans ce cadre, l'évolution du graphe est modélisée comme une suite de captures de l'état du graph observés à intervalles réguliers. La dimension temporelle

est ensuite prise en compte via des RNN appliqués à posteriori en complément du GNN. C'est notamment le cas de T-GCN [Zhao 2020] et EvolveGCN [Pareja 2019]. Cette formulation permet d'adapter relativement facilement des architectures de GNN classiques à un contexte temporel. DySAT [Sankar 2019] va un cran plus loin et propose un mécanisme d'attention temporelle où chaque nœud est associé à ses représentations historiques afin de capturer l'évolution de son contexte au cours du temps. Bien que ces approches aient l'avantage d'être relativement simples à mettre en œuvre, elles présentent plusieurs limites/ Premièrement, le fait de reposer sur une représentation par capture d'état implique de conserver l'état complet du graphe à plusieurs instants, ce qui engendre un coût mémoire élevé. Ensuite, la granularité temporelle est limitée par la fréquence des captures d'état, ce qui entraîne nécessairement une perte d'information. Enfin, en raison de l'aspect externe des modules de mémoire, ces méthodes peinent généralement à capturer les longues dépendances temporelles.

La seconde catégorie correspond aux réseaux de graphes en temps continu, qui opèrent à une granularité temporelle plus fine que les approches discrètes. Plutôt que de reposer sur des captures d'état fixes, ces modèles traitent des séquences d'événements correspondant à l'ajout, la suppression ou la modification de nœuds et d'arêtes dans le graphe. Cette modélisation événementielle permet d'intégrer directement les dépendances temporelles dans le modèle, plutôt que de les traiter de manière externe.

Parmi les modèles de graphes dynamiques en temps continu, on distingue généralement deux sous-familles : les modèles d'encodage temporel (*Temporal Embedding*) et ceux de voisinage temporel (*Temporal Neighborhood*). Les modèles d'encodage temporel ne stockent pas explicitement d'état associé aux nœuds et s'appuient principalement sur des architectures récurrentes ou attentionnelles pour capturer l'évolution temporelle à partir de la séquence des événements observés. Parmi eux, TGAT [Xu 2020] adapte le mécanisme de GAT [Veličković 2018] au contexte temporel en intégrant un encodage du temps directement dans le mécanisme d'attention.

La plupart des GNN dynamiques reposent sur des stratégies d'échantillonnage multi-saut afin de récupérer un voisinage temporel étendu. Ce processus est explicite dans la majorité des approches, mais peut également être implicite dans les modèles utilisant un RNN. CAWs [Wang 2022], au lieu de faire des parcours multi-saut classiques, propose une alternative fondée sur des parcours causaux qui exploite l'hypothèse de fermeture triadique, selon laquelle deux nœuds partageant un voisin commun ont davantage de chances d'être connectés. Cette hypothèse est cependant moins adaptée à notre cas d'étude basé sur un graphe biparti.

Plus récemment, DyGFormer [Yu 2023] simplifie cette approche en se limitant à un voisinage de distance 1, tout en ajoutant des informations de co-occurrence. Celles-ci sont calculées à partir de la fréquence d'apparition des nœuds dans les événements du voisinage temporel, puis injectées dans un Transformer. Les auteurs proposent également une implémentation unifiée facilitant la comparaison des modèles de graphes dynamiques. Comme DyGFormer, GraphMixer [Cong 2023] se limite également à un voisinage de distance 1. Les auteurs critiquent l'utilisation

systématique de RNN et de mécanismes d'attention dans les graphes dynamiques, en expliquant que ces architectures ne sont nécessaires que pour agréger efficacement des dépendances multi-saut. En se limitant à un voisinage local, GraphMixer remplace ces mécanismes par des architectures de type MLP-Mixer, beaucoup plus simples et rapides à inférer.

À l'inverse des modèles d'encodage temporel, les modèles de voisinage temporel maintiennent un état latent associé à chaque nœud déjà observé, mis à jour au fil des événements. Cette approche est plus coûteuse en mémoire et en calcul, mais elle permet de conserver un historique condensé des interactions passées et de fournir davantage de contexte aux RNN lors du traitement de nouvelles interactions. Du côté des graphes dynamiques continus avec mémoire, on retrouve notamment DyRep [Trivedi 2018], qui distingue les événements de communication des événements d'association entre nœuds. Cette approche est particulièrement adaptée aux multigraphes dynamiques, mais elle est moins pertinente dans notre cas où il n'existe qu'une seule arête possible par paire de nœuds. JODIE [Kumar 2019] est quant à lui conçu pour la prédiction de liens sur graphes bipartis. Le modèle maintient pour chaque utilisateur et chaque item un embedding dynamique mis à jour par des RNN mutuellement récursifs, en complément d'une représentation statique. Enfin, TGN [Rossi 2020] propose une formalisation générale des graphes dynamiques continus avec mémoire. Le modèle introduit une architecture modulaire composée d'un mécanisme de mémoire, d'une fonction de mise à jour, d'un module de message passing et d'un encodeur temporel. De nombreux modèles existants peuvent ainsi être interprétés comme des cas particuliers de ce formalisme.

	Modèle	Attention	RNN	Mémoire	Parcours
Temporal Embedding	TGAT [Xu 2020]	Oui	Non	Non	multi-saut
	CAWs [Wang 2022]	Oui	Oui	Non	causal
	DyGFormer [Yu 2023]	Oui	Non	Non	1-hop
	GraphMixer [Cong 2023]	Non	Non	Non	1-hop
Temporal Neighborhood	DyRep [Trivedi 2018]	Non	Oui	Oui	multi-saut
	JODIE [Kumar 2019]	Non	Oui	Oui	multi-saut
	TGN [Rossi 2020]	Oui	Oui	Oui	multi-saut

TABLE 3.2 – Comparaison des principaux modèles de graphes dynamiques en temps continu.

Une vue d'ensemble de l'apprentissage sur graphes dynamiques est proposée par Feng et al. [Feng 2024], qui présentent une synthèse mettant en évidence les différences conceptuelles entre les modèles dynamiques à temps discret et à temps continu, ainsi qu'un benchmark étendu des principales méthodes de ces deux catégories. Le tableau 3.2 fournit une comparaison synthétique de ces modèles selon leurs mécanismes d'attention, leur utilisation de RNN et de mémoire, ainsi que leur stratégie d'échantillonnage de voisinage.

3.4.2.3 GNN non supervisé

L'ensemble des modèles précédemment énoncés sont conçus pour pouvoir être utilisés sur des tâches de prédiction de liens, qui relèvent de l'apprentissage auto-supervisé. Ce cadre est généralement considéré comme une sous-catégorie de l'apprentissage non supervisé, dans lequel des pseudo-labels sont construits automatiquement à partir des données brutes. Dans le cas des graphes, cela consiste à opposer des arêtes positives, correspondant aux interactions réellement observées dans le graphe, à des arêtes négatives, générées artificiellement à partir de paires de nœuds n'ayant jamais été connectées. Ces arêtes sont encodées puis passées dans une couche dense qui prédit la probabilité d'existence de l'arête. La prédiction obtenue est ensuite comparée à la vérité afin de calculer la fonction de perte. Néanmoins, la génération d'arcs négatifs pertinents constitue un défi difficile. Il est en effet, à la fois possible de produire des arcs négatifs qui pourraient en réalité être légitimes, ou au contraire de ne pas couvrir correctement la diversité des comportements anormaux lorsque ceux-ci sont échantillonnés de manière aléatoire. Ce problème est d'autant plus marqué dans des contextes tels que le nôtre, où les sous-graphes sont fortement structurés et contraints.

L'autre approche non-supervisée couramment utilisée pour la détection d'anomalies consiste à formuler le problème comme une tâche de reconstruction des données. Pour ce faire, on utilise un autoencodeur qui prend en entrée un graphe et génère une représentation latente compressée à partir duquel il va essayer de recréer l'entrée d'origine. Après avoir été entraîné sur des données ne contenant pas d'anomalies, l'autoencodeur est capable de reconstruire correctement les points considérés comme normaux, mais devrait normalement échouer davantage sur des données atypiques qu'il n'a jamais observées auparavant. L'erreur de reconstruction peut alors être utilisée comme score d'anomalie. Plus cette erreur est élevée, plus le point est susceptible d'être anormal. C'est notamment le principe utilisé par DONE [Bandyopadhyay 2020], qui repose sur deux autoencodeurs parallèles. Le premier encode la structure des liens du graphe, tandis que l'autre encode les attributs des nœuds. Les auteurs proposent également AdONE [Bandyopadhyay 2020], une extension basée sur l'apprentissage adverse permettant de construire des embeddings plus robustes aux valeurs aberrantes. GraphMAE [Hou 2022] utilise également une architecture de type autoencodeur. Leur contribution principale consiste à appliquer un double masquage. Un premier masque est appliqué sur les attributs des nœuds avant l'encodage, puis un second est appliqué dans l'espace latent après l'encodage. Dans leur cas, l'encodeur est un GNN, tandis que le décodeur est un MLP. Cette stratégie de masquage vise à renforcer la robustesse des représentations apprises en forçant le modèle à inférer des informations manquantes à différents niveaux de représentation. STGMAE [Zhang 2019] est presque identique mais enrichit l'entrée du GNN par une couche d'encodage spatio-temporel. Toutefois, ces approches restent limitées au cadre des graphes statiques et ne prennent pas directement en compte l'évolution temporelle de la structure du graphe. DyGIS [Jiao 2024] adapte justement GraphMAE aux graphes discrets dynamiques mais, à notre connaissance,

aucun travail de l'état de l'art ne propose encore d'étendre les méthodes de reconstruction au cas des graphes dynamiques en temps continu non supervisé.

Parmi les deux approches d'apprentissage non-supervisées présentées, la prédiction d'arcs via l'auto-supervision semble plus facilement équilibrable, étant donné la nature binaire de la tâche. Cependant, la création d'arcs négatifs qui est nécessaire à l'auto-supervision est sujette à l'introduction de biais. En revanche, l'approche de reconstruction est moins susceptible à ces biais mais est plus difficile à guider.

3.4.3 Formalisation adapté à l'utilisation de GNN dynamiques

Pour considérer la dimension temporelle et détecter les attaques d'inondation ou à plusieurs étapes, il faut intégrer l'information temporelle à notre détection et donc considérer les graphes dynamiques. Une solution serait d'utiliser les graphes dynamiques discrets et c'est d'ailleurs l'approche qu'emploie GSAD [Wang 2023]. Toutefois, nous avons vu que cette approche est peu adaptée, car elle est coûteuse, entraîne des pertes d'information et est peu adaptée aux périodes d'observation étendues.




FIGURE 3.9 – Différentes représentations d'une même séquence d'échanges entre un attaquant et le NRF : diagramme de séquence, graphe statique, puis graphe dynamique continu.

Nous nous intéressons donc davantage aux graphes dynamiques continus, tels qu'introduits dans le cadre de TGN [Rossi 2020]. Dans cette approche, plutôt que

de représenter le graphe comme un objet statique décrivant un état à un instant donné, celui-ci est modélisé comme une séquence d'événements qui le construit progressivement.

$$\mathcal{G} = \{e_1, e_2, \dots, e_n\}$$

où e_i désigne l'événement apparaissant à la i -ème position dans la séquence.

Ces événements correspondent généralement à des ajouts, suppressions ou modifications de nœuds et d'arêtes. Toutefois, notre cadre est plus simple car notre graphe est purement additif. Chaque arête qui serait ajoutée dans un graphe traditionnel est représentée comme un événement défini par cette arête ainsi que par les deux nœuds qu'elle relie.

$$e_i = (u, v_i, x_i),$$

où $u \in \mathcal{V}_c$ désigne un nœud central, $v_i \in \mathcal{V}_f$ un nœud de paramètre contenant la valeur de ce dernier et $\mathbf{z}_i \in \mathbb{R}^d$ le nom du paramètre contenu dans l'arête.

Cette formulation permet une représentation beaucoup plus fine, dans laquelle aucune information temporelle n'est perdue. La figure 3.9 illustre la transformation d'une forme de graphe statique à celle d'un graphe dynamique continu. On observe que, pour les trois paquets, neuf arcs sont générés dans le graphe statique, lesquels se traduisent ensuite en autant d'événements dans le graphe continu.

3.4.4 Fonctionnement détaillé des GNN dynamique

Dans leurs travaux, TGN [Rossi 2020] proposent un cadre de formalisation des GNN dynamiques, permettant de représenter les travaux de l'état de l'art comme des spécifications de leur modèle. Nous nous appuyerons sur ce cadre pour présenter et comprendre le fonctionnement d'un GNN dynamique. La figure 3.10 illustre les quatre modules principaux définis par TGN [Rossi 2020] : un module de mémoire, un module d'agrégation de messages, un module de mise à jour de la mémoire et un module d'inférence.




FIGURE 3.10 – Vue d'ensemble de l'architecture générale d'un GNN Dynamique Continu, illustrant les quatre modules principaux : mémoire, agrégation de messages, mise à jour de la mémoire et inférence.

3.4.4.1 Création des messages

La première étape d'un GNN consiste à construire un message contenant l'ensemble des informations associées à un événement du graphe dynamique.

$$m_i = msg(s(u), s(v_i), x_i, \Delta t)$$

Comme expliqué dans la section 3.3.3, la valeur des nœuds paramètres ne nous intéressent pas. Les vecteurs associés aux nœuds centraux $s(u)$ et aux nœuds paramètres $s(v_i)$ sont donc initialisés comme des vecteurs nuls. Si ces nœuds ont déjà été impliqués dans des événements précédents, leurs représentations qui a déjà subi une convolution est alors réutilisées. Le vecteur associé à l'arête x_i est quant à lui déterminé à partir du nom du paramètre porté par l'événement. Dans notre cas, ce nom de paramètre correspond à un token textuel et il est donc nécessaire de l'encoder au préalable sous forme d'un vecteur numérique. La méthode utilisée pour cet encodage est présentée dans la section suivante. Il existe diverses méthodes pour définir l'intervalle temporel Δt mais la méthode la plus fréquemment employée consiste à calculer la différence temporelle entre l'échantillon et le dernier paquet encodé. Ce dernier est représenté sous forme de vecteur de dimensions identiques aux autres composantes du système. Un paramètre ajustable permet alors de moduler la granularité de cette mesure.

3.4.4.2 Agrégation des messages

L'étape d'agrégation consiste à considérer l'ensemble des voisins du nœud source en cours de traitement, c'est-à-dire tous les événements m_i précédent un temps t dans lesquels ce nœud apparaît. On obtient ainsi une collection de messages qu'on agrège ensuite afin de produire un vecteur unique représentant le voisinage de distance 1 du nœud considéré.

$$\bar{m}_i(t) = \text{agg}(m_i(t_1), \dots, m_i(t))$$

Cette agrégation peut être réalisée de différentes manières. TGN [Rossi 2020] propose plusieurs stratégies, parmi lesquelles l'utilisation de RNN, d'un mécanisme d'attention, une moyenne des messages ou bien de simplement conserver l'événement le plus récent.

3.4.4.3 Mise à jour de la mémoire

Afin de prendre en compte la dimension temporelle, les modèles dynamiques de type *Temporal Neighborhood* disposent d'un module de mémoire, absent des modèles *Temporal Embedding*. Ce module combine le vecteur agrégé avec l'historique des représentations précédentes des éléments constitutifs du message. Cet ensemble est ensuite transmis à un RNN, qui joue le rôle de module de mémoire apprenable. Ce module produit un nouveau vecteur représentant à la fois le message et son historique.

$$s(u) = mem(x_i, s(u))$$

Cette nouvelle représentation est utilisée pour les modules futurs et remplace également l'ancienne valeur stockée en mémoire. TGN [Rossi 2020] propose notamment d'utiliser des architectures de type Long Short-Term Memory (LSTM) ou GRU pour implémenter ce module de mémoire.

3.4.4.4 Encodeur et Classifieur

L'encodeur est le module chargé de calculer la représentation des nœuds à partir de leur mémoire et des interactions temporelles. Plusieurs variantes peuvent être utilisées :

- **Identity (id)** : l'encodage correspond directement à la mémoire du nœud.
- **Time projection (time)** : la mémoire est modulée en fonction du temps écoulé depuis la dernière interaction, comme dans JODIE [Kumar 2019].
- **Temporal Graph Attention (attn)** : plusieurs couches de graph attention agrègent l'information provenant du voisinage temporel du nœud. À chaque couche, les voisins temporels sont récupérés puis combinés via un mécanisme de multi-head attention.
- **Temporal Graph Sum (sum)** : version plus simple et rapide où les informations des voisins temporels sont agrégées par somme puis projetées linéairement.

Pour les modèles *attn* et *sum*, un encodage temporel de type *Time2Vec* est utilisé afin de représenter les écarts temporels entre interactions. Ces méthodes permettent également de limiter le problème de *staleness* en mettant à jour les représentations grâce aux informations des voisins récents.

3.4.5 Adaptation à notre cas d'utilisation

Pour mieux répondre à notre problématique, nous proposons deux ajustements justifiés par notre cadre d'utilisation. Dans un premier temps, nous supprimons l'information temporelle explicite des messages. Dans un second temps, nous adaptons le mécanisme d'agrégation standard en une version spécifique, conçue pour notre structure bipartite.

Le premier ajustement consiste à supprimer l'information temporelle explicite du modèle. Concrètement, cela se traduit par le retrait du terme Δt dans la formulation des messages. Dans notre contexte, l'information temporelle est déjà implicitement capturée par les séquences d'interactions lorsqu'elle est traitée par le RNN. La mention explicite du terme Δt est principalement pertinente pour identifier d'éventuelles pauses ou délais dans le trafic. Toutefois, cette information ne constitue pas un indicateur suffisamment représentatif d'une attaque et induit souvent, au contraire, des biais de surapprentissage. Pour cette raison, nous avons choisi de retirer cette composante temporelle de la formulation des messages.




FIGURE 3.11 – Représentation du problème lié au parcours multi-saut dans notre graphe biparti. La première figure représente le graphe avec les arrivées temporelles des paquets. Les figures suivantes représentent les deux méthodes possibles de propagation de l'information du paquet P_3 . (A) La méthode classique de propagation multi-sauts utilise successivement le timestamp des nœuds intermédiaires. (B) Notre approche conserve le timestamp du nœud initial, et permet donc de récupérer correctement les voisins multi-sauts.

Le deuxième ajustement concerne la construction des voisinages multi-sauts. Dans un GNN dynamique classique, un nœud ne peut normalement agréger que des voisins apparus avant lui. Cependant, dans notre graphe biparti, les nœuds paramètres sont réutilisés et conservent leur horodatage de première apparition. Cela crée un problème lors de l'exploration multi-sauts, car l'horodatage des nœuds paramètres sera antérieur à celui de la majorité des paquets auxquels il sera lié. Ces nœuds centraux seront donc considérés à tort comme inaccessibles lors de l'agrégation du voisinage. Pour résoudre ce problème, nous conservons l'horodatage du nœud initial lors de l'exploration du voisinage, plutôt que récupérer successivement celui des nœuds intermédiaires, ce qui permet de conserver un voisinage temporel cohérent. La figure 3.11 présente un exemple d'une telle situation ainsi que les deux approches de propagation.

Ces ajustements répondent directement aux spécificités de notre cas d'usage et ont donc été intégrés à notre approche. La suppression de l'information temporelle explicite permet de limiter les risques de surapprentissage liés aux irrégularités du trafic, tandis que la modification du mécanisme de propagation garantit une exploration multi-sauts cohérente dans le contexte particulier de notre graphe biparti.

3.4.5.1 Problèmes ouverts

D'autres pistes d'ajustement ont également été envisagées au cours de cette thèse, mais n'ont finalement pas été intégrées à l'approche proposée. Elles restent néanmoins intéressantes à mentionner, car leur considération est légitime et soulève plusieurs questions pertinentes quant à notre formalisation.

Dans un réseau 5G, le déclenchement d'une procédure engendre la génération de séquences ordonnées de messages. Il peut être envisagé de représenter explicitement ces séquences ainsi que leur ordre au sein du graphe au moyen d'une formalisation dédiée. Une approche possible consiste à orienter le graphe et à introduire un type de liaison spécifique pour relier un nœud central à son successeur dans la séquence.




FIGURE 3.12 – Représentation sous forme de graphe d’une procédure composée de trois paquets. Les arcs orientés en pointillés représentent un nouveau type de liaison entre nœuds central permettant de représenter l’ordre temporel des échanges.

La Figure 3.12 illustre l’ajout de dépendance par une flèche pointillée. Cette représentation présente l’avantage d’être aisément interprétable par un lecteur humain tout en rendant explicites les séquences et leur ordre d’exécution. Cependant, cette approche n’apporte pas d’information supplémentaire au modèle, dans la mesure où la structure séquentielle est déjà encodée via les graphes dynamiques continus. Néanmoins, elle conserve un intérêt pour l’analyse humaine et peut ainsi être ajoutée a posteriori de l’inférence afin d’améliorer la lisibilité des résultats.

EGAT [Chen 2021] propose de donner plus d’importance à l’information portée par les arêtes en réalisant une agrégation sur ces dernières au lieu d’une agrégation sur les nœuds comme cela est fait classiquement. Pour ce faire, ils convertissent leur graphe en *line graph* où les nœuds correspondent aux arêtes du graphe original, tandis que les arêtes traduisent les relations entre les nœuds. La Figure 3.13 illustre cette transformation. Néanmoins, dans notre cas d’étude, les graphes considérés sont fortement connectés et comportent un grand nombre d’arêtes. Or, la construction du *line graph* entraîne une augmentation significative de la complexité structurelle, puisque chaque arête du graphe initial devient un nœud supplémentaire. Cette transformation ne passe donc pas à l’échelle dans notre configuration et conduit rapidement à une explosion de la complexité.

Ces différentes approches montrent que plusieurs extensions de la formalisation initiale sont envisageables. Néanmoins, bien qu’elles présentent des avantages évidents, elles soulèvent des problèmes structurels et computationnels qui empêchent




FIGURE 3.13 – Illustration de la transformation d'un graphe classique (à gauche) en *line graph* (à droite). Dans cette représentation, les arêtes du graphe initial deviennent les nœuds du *line graph*, tandis que les relations entre arêtes sont représentées par de nouvelles connexions.

leur intégration à notre formalisation.

3.5 Encodage des paramètres contenus dans les arcs

Comme mentionné dans la section 3.4.4.1 relative à la construction des messages, il est nécessaire d'encoder les informations contenues dans les arcs. Les paquets réseau 5G comportent un très grand nombre de paramètres, ce qui conduit à un espace d'entrée de très grande dimension. Nous verrons dans cette section que cette forte dimensionnalité ne constitue pas nécessairement un problème dans le cadre d'une approche supervisée. En revanche, si l'objectif est de réaliser une détection non supervisée afin d'identifier des attaques *zero-day*, il devient nécessaire de recourir à des techniques d'encodage permettant de réduire la dimension de l'espace d'entrée. À cette fin, nous nous intéressons aux approches issues du Traitement Automatique du Langage Naturel (NLP). Nous analyserons leur utilisation dans l'état de l'art, puis étudierons leur adaptation à notre cas d'usage ainsi que les problématiques qu'elles soulèvent.

3.5.1 Apprentissage supervisé et non supervisé

L'apprentissage supervisé et l'apprentissage non supervisé soulèvent des problématiques différentes en matière d'encodage des paramètres. Nous commençons donc par présenter ces deux approches, avant d'examiner les implications de chacune sur la stratégie d'encodage des paramètres.

3.5.1.1 Apprentissage supervisé

Le principe de l'apprentissage supervisé consiste à entraîner un modèle sur un dataset étiqueté contenant à la fois des exemples bénins et malveillants. L'objectif est d'apprendre à distinguer ces deux classes afin de pouvoir ensuite effectuer cette distinction sans étiquettes. Ce type d'apprentissage se limite aux attaques connues, mais il offre généralement de meilleures performances. Cependant, comme l'ensemble des attaques à détecter est défini à l'avance, il est possible de sélectionner un sous-ensemble de paramètres pertinents et de réduire ainsi la dimension du problème. En considérant un sous-ensemble suffisamment restreint, il devient alors possible d'utiliser de simples techniques de *one-hot encoding* pour encoder les paramètres.

3.5.1.2 Apprentissage non supervisé

L'apprentissage non supervisé consiste à apprendre à un modèle le comportement normal d'un système en l'entraînant uniquement sur des données bénignes. Les anomalies sont alors détectées à partir de leur écart à cette notion de normalité. Ce type d'apprentissage permet de détecter des attaques inconnues, mais il est généralement plus difficile à mettre en œuvre. En effet, puisque l'objectif est notamment de détecter des attaques de type *zero-day*, il n'est pas possible de savoir à l'avance quels paramètres seront pertinents. Il est donc nécessaire de considérer l'ensemble des paramètres potentiellement observables, y compris ceux qui ne sont pas pertinents pour les attaques connues, ce qui introduit un bruit important dans les données.

De plus, la prise en compte de l'ensemble des paramètres potentiellement observables conduit à un espace d'entrée de très grande dimension, susceptible d'entraîner le phénomène de *malédiction de la dimension*, caractérisé par une dégradation des capacités de généralisation lorsque la dimension de l'espace d'entrée devient trop importante. Par conséquent, il est nécessaire de réduire la dimension de cet espace à l'aide de techniques issues du NLP, afin de rendre les données exploitables par les modèles de GNN présentés précédemment.

3.5.2 Tour d'horizon des techniques de NLP

Les approches issues du NLP sont traditionnellement utilisées pour des tâches telles que la traduction automatique, la classification de documents, la détection d'intention ou encore la reconnaissance d'entités nommées. Dans ces applications, les modèles sont entraînés à apprendre une représentation sémantique des données textuelles, sous la forme d'un espace latent structuré dans lequel une proximité géométrique reflète une proximité sémantique. Dans cette thèse, nous cherchons à exploiter directement la structure de l'espace latent afin d'associer à n'importe quel paramètre une représentation vectorielle pertinente.

Pour évaluer la qualité de cette structuration, deux approches complémentaires sont généralement utilisées et reposent sur une interprétation humaine. La première




FIGURE 3.14 – Projection en deux dimensions d’un espace latent représentant un vocabulaire anglais, obtenue par Analyse en Composantes Principales (PCA).

consiste à examiner, au cas par cas, les voisins les plus proches d’un mot donné dans l’espace d’embedding. La seconde consiste à projeter cet espace de haute dimension dans un espace à deux dimensions afin d’en permettre une visualisation globale. Les méthodes les plus couramment utilisées pour cela sont la PCA et le t-SNE, qui représentent respectivement une projection linéaire conservant la structure globale, et une projection stochastique visant à préserver les similarités locales. La figure 3.14 illustre un exemple de projection PCA d’un vocabulaire générique encodé avec FastText [Bojanowski 2017] que nous allons présenter ensuite.

Notre objectif est d’encoder les mots de manière individuelle. L’approche la plus simple consiste à utiliser un encodage one-hot, c’est-à-dire associer chaque mot à une dimension d’un vecteur orthogonal. Le fait d’attribuer des représentations uniques à chaque mot laisse ensuite au GNN la responsabilité d’en apprendre la sémantique. Un inconvénient de cette méthode est qu’elle produit des embeddings sans sémantique qui pourrait pourtant faciliter l’apprentissage du GNN. De plus, comme la construction de vecteurs orthogonaux impose une dimension de l’espace d’embedding égale à la taille du vocabulaire, cette approche n’est pas possible sur des espaces de grande dimension et est donc réservée, dans notre cas, à l’apprentissage supervisé.

Afin de pallier ce problème, des techniques comme le hashing trick projettent les termes dans un espace de dimension fixe à l’aide d’une fonction de hachage. Cette approche permet de contrôler la taille des représentations indépendamment du

vocabulaire, mais introduit des collisions. Ainsi, plusieurs termes distincts peuvent obtenir des encodages identiques, ce qui peut induire des proximités artificielles dans l'espace vectoriel. Le hashing trick et le one-hot encoding ont l'avantage d'être simples et rapides à grande échelle, mais ne capturent pas la dimension sémantique des mots qu'ils encodent.




FIGURE 3.15 – Illustration de l'architecture de Word2Vec à travers les modèles Continuous Bag of Words (CBOW) et Skip-Gram, appliqués au mot cible "lie" dans la phrase "The biggest lie ever told".

Les approches de deep learning permettent justement d'apprendre la sémantique des mots à partir de leur contexte d'utilisation. L'idée principale est qu'un mot peut être compris en observant les mots qui l'entourent dans une phrase ou un corpus. C'est ce que fait Word2Vec [Mikolov 2013] qui propose deux modèles, un CBOW qui vise à prédire un mot à partir de son contexte et un Skip-Gram qui, de façon symétrique, vise à prédire les mots du contexte en connaissant un mot en entrée.

Néanmoins, comme il apprend sur des fenêtres de contexte locales, Word2Vec ne dispose pas d'une vision globale du corpus. Cette limitation est adressée par Global Vectors for Word Representation (GloVe) [Brochier 2019], qui apprend à minimiser la distance entre le produit scalaire de deux vecteurs et le logarithme de leur fréquence de co-occurrence dans le corpus. Cependant, GloVe présente des limites dans le cas de langues à morphologie et vocabulaire riche.

FastText [Bojanowski 2017] est justement une extension de Word2Vec qui cherche à découper un mot en sous-unités morphologiques. Contrairement à Word2vec, FastText ne considère pas un mot comme une entité atomique, mais le représente comme un ensemble de n -grammes de caractères. Cette segmentation permet de partager des informations entre mots présentant des structures similaires. Dans notre cas, cela permet par exemple de décomposer *servingNfId* en plusieurs sous-unités telles que *serving*, *Nf* et *Id*. Chacun de ces segments peut alors porter

une information sémantique propre et être réutilisée pour représenter d'autres paramètres partageant des sous-parties communes. Cependant, une limite importante de cette approche réside dans le caractère statique des embeddings. Ici, chaque mot et n-gramme possède une représentation fixe qui est indépendante du contexte dans lequel il apparaît.

Or, un mot peut être polysémique et donc avoir une sémantique variable en fonction de son contexte d'apparition. Afin de prendre en compte cette ambiguïté sémantique, on a vu l'arrivée de travaux utilisant des architectures de type Transformer, qui permettent d'apprendre des représentations contextuelles dynamiques. Ces modèles, tels que GPT [Radford 2018] et BERT [Devlin 2019], utilisent des mécanismes d'attention pour modéliser les dépendances à long terme dans les séquences de texte, ce qui améliore significativement la qualité des représentations apprises. Le premier est basé sur un décodeur qui va analyser le contexte historique d'un mot pour prédire sa suite tandis que le second va prendre le contexte bidirectionnel et sera plus adapté à des tâches de compréhension du langage. Ces modèles sont la plupart du temps pré-entraînés sur de très grands corpus de texte, mais peuvent être adaptés à des tâches spécifiques par le biais d'une phase de fine-tuning. Cependant, leur complexité et leurs besoins en ressources computationnelles sont considérablement plus élevés que les modèles précédents.

Parmi les approches de NLP proposées, GPT, BERT et leurs variantes respectives figurent parmi les modèles obtenant généralement les meilleures performances. Néanmoins, il convient de souligner que ces architectures ont été conçues pour des données textuelles naturelles et reposent sur des hypothèses implicites liées à la structure du langage humain. Dans le cadre de cette thèse, le contexte considéré est sensiblement différent. Le vocabulaire manipulé est très spécifique, parfois constitué d'identifiants ou de chaînes non lexicalisées, et les paquets qui les contiennent diffèrent fortement de la structure d'une phrase naturelle. Dès lors, l'utilisation de modèles aussi complexes peut s'avérer disproportionnée au regard de la nature des données. Il apparaît donc nécessaire d'évaluer dans quelle mesure ces architectures peuvent être adaptées à notre type de données, et d'identifier les modèles offrant le meilleur compromis entre expressivité, robustesse et coût computationnel dans un contexte aussi spécifique.

3.5.3 Mise en place de l'encodage sémantique

La figure 3.16 illustre le processus d'application du NLP à notre problème afin d'obtenir des encodages associés aux mots. Dans un premier temps, nous exploitons le fichier JSON contenant les données extraites des paquets, que nous transformons en phrases. Pour cela, les chaînes de caractères sont nettoyées en supprimant les caractères spéciaux, tels que les tirets ou les points. Pour chaque couche du paquet, une phrase distincte est construite, et le nom du protocole est explicitement ajouté afin d'enrichir le contexte lexical. Le modèle considère ainsi l'ensemble du paquet comme une unité globale, tout en tirant parti de la séparation entre les phrases pour structurer l'information.




FIGURE 3.16 – Représentation du processus d’encodage fondé sur le NLP. Les paramètres du paquet sont tout d’abord extraits puis transformés en séquences textuelles, lesquelles sont ensuite tokenisées. Ces tokens sont transmis à un modèle de NLP permettant d’obtenir leurs représentations encodées. Ces représentations sont finalement agrégées afin d’obtenir un encodage au niveau du mot.

Ensuite, comme dans un pipeline NLP classique, une étape de tokenisation est appliquée. Celle-ci consiste à identifier des mots connus dans le vocabulaire et, lorsqu’un mot n’est pas reconnu, à le décomposer en sous-unités. Comme illustré sur la figure, le mot *requester* est par exemple segmenté en *request* et *##er*, ce dernier étant marqué comme suffixe par la présence des dièses. De même, le terme *nf*, inconnu du vocabulaire, est décomposé en *n* et *##f*.

Les tokens obtenus sont ensuite convertis en identifiants (token IDs), qui sont fournis au modèle. Celui-ci produit en sortie des vecteurs encodés, représentant chaque token. Comme un mot peut être composé de plusieurs tokens, il est nécessaire d’agréger ces représentations. La méthode la plus simple consiste à effectuer la moyenne des encodages des tokens associés à un même mot. On obtient ainsi, au final, un embedding pour chaque mot.

3.5.4 Avantages et limites

Obtenir une proximité géométrique entre des éléments présentant une similarité sémantique constitue une propriété particulièrement intéressante dans notre contexte. En effet, de nombreux paramètres présentent une forte redondance lexicale ou fonctionnelle, comme *servingNfId* et *nf-id*. Ces paramètres peuvent ainsi être associés à des représentations proches dans l’espace latent, ce qui contribue à réduire la complexité du vocabulaire. De plus, l’utilisation de techniques de NLP pour enrichir la représentation sémantique des vecteurs d’arêtes peut fournir une information de départ supplémentaire au GNN, facilitant ainsi l’apprentissage de relations complexes.

Néanmoins, plusieurs limites apparaissent dans ce cadre. Pour réaliser l’embedding d’éléments textuels par NLP, il est possible soit d’utiliser directement des modèles pré-entraînés, soit de recourir à un fine-tuning afin de les adapter au vocabulaire spécifique du domaine. Dans notre cas, les paramètres à encoder s’appa-

rentent davantage à des noms de variables qu'à des tokens issus du langage naturel. Par exemple, certains termes tels que *address* peuvent être correctement interprétés par les modèles, tandis que des identifiants techniques comme *avType* ou *kausf*, ne correspondent ni à des unités ni à des sous-unités lexicales courantes.

Dans ce contexte, le recours à une phase de fine-tuning apparaît nécessaire. Celle-ci consiste à fournir au modèle des exemples de phrases afin d'apprendre la sémantique des tokens à partir de leur contexte d'occurrence. Toutefois, dans notre cas, les données que l'on extrait des paquets ne sont pas naturellement structurées sous forme de phrases. La solution que nous considérons est donc de représenter chaque paquet comme une phrase en concaténant ses différents paramètres. Cette approche demeure cependant imparfaite, car elle introduit implicitement une notion d'ordre et de position dans la séquence, laquelle n'a pas de signification intrinsèque dans notre problématique.

Que ce soit pour FastText, GPT ou BERT, l'ordre des mots dans une phrase est généralement centrale dans les mécanismes d'apprentissage. Il est donc difficile de prédire dans quelle mesure ces modèles parviendront à capturer efficacement la sémantique de notre vocabulaire lorsque l'on considère un paquet non-ordonné comme une phrase. Nous évaluerons donc empiriquement, dans la section expérimentale présentée au chapitre suivant, les différents impacts des méthodes d'encodage afin d'identifier ceux qui permettent d'améliorer les performances de détection.

3.6 Conclusion

Nous avons vu dans ce chapitre que les besoins en détection d'anomalies dans les réseaux 5G s'éloignent fortement de ceux observés dans les réseaux traditionnels. Les spécificités de la 5G nécessitent de passer d'une analyse par flux à une analyse paquet, comme cela est réalisé dans la majorité des travaux portant sur la détection du domaine. Néanmoins, ces travaux prennent rarement en compte l'ensemble des dimensions temporelles, sémantiques et topologiques que nous avons définies. En combinant les apports de l'état de l'art en 5G et des systèmes distribués, nous proposons un nouveau formalisme de graphe continu dynamique. Ce formalisme constitue l'une de nos principales contributions, car il permet de considérer ces trois dimensions tout en étant hautement interprétable par construction.

Nous avons ensuite présenté de manière détaillée le domaine relativement récent des GNN, ainsi que ses variantes basées sur les graphes dynamiques discrets et continus. Nous avons également montré que les deux types d'apprentissage présentent chacun leurs avantages. L'apprentissage non supervisé permet de détecter des attaques zero-day, mais nécessite l'utilisation de techniques issues du NLP pour gérer la forte dimensionnalité de ses paramètres. L'apprentissage supervisé, quant à lui, en plus d'obtenir généralement de meilleures performances, se concentre sur un sous-ensemble d'attaques connues et permet ainsi de réduire la dimensionnalité des paramètres à considérer, limitant le recours à des techniques de NLP.

Afin de vérifier que le formalisme proposé permet effectivement de détecter

des anomalies et évaluer l'impacte des méthodes de NLP, nous présentons dans le chapitre suivant une analyse empirique. Nous y compareront différentes approches d'apprentissage, modèles de GNN et méthodes d'encodage présentés précédemment.

Evaluation empirique des modèles

Sommaire

4.1	Etat de l'art des datasets	58
4.1.1	Analyse des datasets 5G	58
4.1.2	Limites dans l'évaluation de la qualité des données	59
4.2	Génération d'un dataset	62
4.2.1	Trafic bénin	62
4.2.2	Trafic anormal	65
4.2.3	Méthodologie de génération	69
4.2.4	Environnement et implémentation	71
4.3	Evaluation des caractéristiques du dataset	72
4.3.1	Caractérisation sémantique	72
4.3.2	Caractérisation séquentielle	74
4.3.3	Caractérisation topologique	74
4.3.4	Synthèse	75
4.4	Evaluation des modèles de détection	75
4.4.1	Métriques d'évaluation	76
4.4.2	Approche supervisée	78
4.4.3	Approche non supervisée	79
4.5	Représentation interprétable de la détection	83
4.6	Conclusion	86

Les données constituent un élément central des approches d'apprentissage automatique. Pourtant, dans l'état de l'art appliqué à la 5G, aucun dataset ne semble aujourd'hui s'imposer comme référence commune. La majorité des travaux reposent sur des datasets construits localement par des équipes de recherche, souvent avec des méthodologies différentes et insuffisamment documentées. Cette absence de standardisation rend difficile la comparaison objective des modèles proposés dans la littérature. Dans ce contexte, la création d'un dataset de référence apparaît comme une opportunité importante pour la communauté scientifique. Toutefois, cette démarche soulève plusieurs questions fondamentales autour de la définition de la qualité d'un dataset, un sujet qui demeure aujourd'hui au cœur des discussions de la communauté plus large de l'intelligence artificielle. Nous proposons donc, dans cette thèse, la conception d'un dataset dédié, en portant une attention particulière à la

reproductibilité de son processus de génération ainsi qu'à l'évaluation des données produites.

Au moment de l'écriture de cette thèse, la recherche en apprentissage automatique fait face à une problématique croissante de reproductibilité des résultats. Dans de nombreux travaux, l'obtention de performances élevées sur des métriques de détection ou de classification constitue un critère déterminant pour la publication scientifique. En pratique, l'absence de scores compétitifs tend à éclipser les contributions méthodologiques pourtant pertinentes. Cette pression conduit à la multiplication de travaux présentant des résultats difficilement reproductibles ou insuffisamment documentés. Il devient alors complexe de déterminer si les performances observées traduisent réellement une bonne capacité de généralisation du modèle ou si elles résultent d'un surapprentissage sur des sous-ensembles de données peu représentatifs. Dans cette thèse, une attention particulière sera donc portée à la limitation des biais expérimentaux.

4.1 Etat de l'art des datasets

Dans cette section, nous commencerons par étudier les datasets existants ainsi que leurs limites, avant de présenter les principales recommandations et considérations méthodologiques relatives à la génération de datasets dans le domaine de l'apprentissage automatique.

4.1.1 Analyse des datasets 5G

Pour des raisons de confidentialité et de protection des données, les grands opérateurs de télécommunication partagent rarement les données issues de leurs réseaux opérationnels. À notre connaissance, il n'existe donc pas de dataset public contenant des données provenant d'un réseau commercial. Les travaux disponibles reposent ainsi principalement sur des données synthétiques.

À notre connaissance, seuls trois travaux se positionnent à l'heure actuelle officiellement comme des datasets 5G publics dédiés à la détection d'anomalies. 5G-NIDD [Samarakoon 2022] considère principalement des attaques génériques au niveau réseau, sans prendre en compte les spécificités des réseaux 5G. PFCP Intrusion Detection Dataset [Amponis 2023] propose un large éventail d'attaques ciblant le plan de gestion de session, mais ne détaille pas la génération du trafic légitime. Enfin, 5GAD [Coldwell 2022] introduit plusieurs attaques visant les interfaces orientées services du CN, mais son trafic normal repose essentiellement sur des activités utilisateur telles que le streaming vidéo ou le téléchargement de fichiers. Ce trafic étant chiffré, il diffère fortement du trafic de contrôle utilisé pour les attaques.

En l'absence de dataset public satisfaisant, les travaux sur la détection d'anomalies doivent généralement produire leurs propres données d'entraînement, souvent privées ou insuffisamment documentées. GSAD [Wang 2023] et ADSeq-5GCN [Tian 2023] proposent plusieurs procédures normales, telles que l'enregistrement d'UE ou l'établissement de session des UE mais ne couvrent cependant qu'un

nombre limité d’attaques. PROV5GC [Pacherkar 2024] enrichit la diversité de trafic légitime avec les changements d’état des UE. Néanmoins, parmi les attaques qu’ils proposent, certaines concernent le slicing et le signalement SMS, pour lesquels il n’introduisent pas d’équivalents légitimes avec lesquels faire contraster leurs attaques. Enfin, 5GCGuard [Tan 2025] est le seul travail à notre connaissance fournissant des outils permettant de reproduire la génération des données. Cependant, seule une version prétraitée de leur dataset généré est publiée, sans accès aux captures brutes originales.

Dataset	PCAP	Code	Procédures bénignes				
			Enregistrement d’UE	Gestion de Session	Changement d’Etat	Gestion de NF	Transmission par UPF
5GAD [Coldwell 2022]	✓	✓					
PFCP IDD [Amponis 2023]	✓						
GSAD [Wang 2023]			✓				
AdSeq [Tian 2023]			✓	✓			
PROV5GC [Pacherkar 2024]			✓	✓	✓		
5GCGuard [Tan 2025]		✓	✓	✓			
Notre solution	✓	✓	✓	✓	✓	✓	✓

TABLE 4.1 – Comparaison de différents datasets 5G et de leurs caractéristiques.

Ainsi, le principal problème des travaux récents réside dans le manque important de ressources publiques ainsi que dans l’absence de cohérence entre les attaques à détecter et le trafic normal utilisé pour les contraster. Le tableau 4.1 présente une synthèse comparative des travaux de l’état de l’art proposant des datasets 5G ou générant leurs propres données pour la détection d’anomalies.

4.1.2 Limites dans l’évaluation de la qualité des données

Afin d’évaluer correctement les performances des modèles de détection, il est nécessaire de s’assurer en amont que les données utilisées sont fiables et représentatives. Le machine learning est utilisé depuis longtemps pour les NIDS, ce qui a conduit à la constitution de nombreux datasets. Cependant, plusieurs travaux ont déjà mis en évidence des lacunes importantes dans des datasets pourtant considérés comme étant des références. L’exemple le plus connu est CIC-IDS-2017 [Sharafaldin 2017], qui fait souvent consensus pour des tâches de détection d’anomalies réseau. Néanmoins, des travaux ont mis en lumière des problèmes critiques dans son contenu, notamment des erreurs d’étiquetage ainsi que la duplication de paquets [Lanvin 2022]. Cela montre que la problématique est loin d’être triviale et qu’elle constitue encore un sujet d’actualité.

Dans leur travaux, Gharib et al. [Sarhan 2022] ont proposé un ensemble de lignes directrices permettant d’évaluer les méthodologies de génération de datasets. Ces recommandations soulignent l’importance de la diversité des types de trafic, de l’anonymisation, ainsi que d’une documentation rigoureuse garantissant la reproductibilité. De leur côté, Flood et al. [Flood 2024] apportent des éléments complémentaires en mettant en évidence des biais concrets présents dans des datasets populaires. Ils montrent que ces biais permettent la détection d’anomalies même à

l'aide de modèles extrêmement simples, ce qui remet en question la validité des résultats d'évaluation obtenus sur de telles données. Bien que ces travaux fournissent des recommandations utiles, ils s'appliquent principalement à des systèmes NIDS basés sur l'analyse de flux, plutôt que sur des paquets individuels.

Par conséquent, certaines de ces lignes directrices ne sont pas directement transposables et doivent être réinterprétées dans notre contexte. En compilant les recommandations issues de l'état de l'art et en les adaptant à notre problématique, nous identifions les objectifs suivants comme essentiels à la constitution d'un datasets 5G de qualité.

4.1.2.1 Exhaustivité des surfaces d'attaques

Comme le montre le tableau 4.1, la majorité des travaux se concentrent sur un nombre limité de procédures de fonctionnement du réseau 5G. Les scénarios bénins se limitent généralement aux procédures d'enregistrement de l'UE et de transition d'état, qui génèrent principalement de la signalisation entre l'AN et le CN. Certains travaux incluent également des procédures de gestion de session, permettant de couvrir les échanges de signalisation PFCP entre les fonctions de gestion de session et le plan utilisateur.

En revanche, deux aspects pourtant essentiels au fonctionnement d'un réseau 5G sont largement absents de la littérature. D'une part, aucun des datasets étudiés ne propose de scénario bénin mettant en œuvre l'encapsulation du trafic utilisateur. D'autre part, les mécanismes de gestion dynamique des NF, pourtant au cœur de la flexibilité introduite par la 5G, ne sont que très rarement représentés.

Notre approche vise ainsi à proposer un dataset couvrant non seulement les surfaces les plus couramment utilisées dans les travaux existants, mais également ces deux nouvelles surfaces, que nous considérons indispensables pour obtenir une représentation plus complète du fonctionnement d'un réseau 5G.

4.1.2.2 Définition du périmètre d'utilisation

Les biais peuvent apparaître très facilement dans un dataset et introduire des corrélations artificielles facilitant excessivement la détection. Par exemple, la prise en compte des adresses MAC par un utilisateur pourrait permettre de discriminer très facilement un attaquant. Afin de limiter ces biais autant que possible, il est important de distinguer clairement les surfaces constituant le véritable objectif du dataset de celles qui ne doivent pas être prises en compte lors de l'analyse.

Notre dataset est donc conçu pour être utilisé au niveau paquet sur les protocoles correspondant aux surfaces considérées, à savoir GTP, PFCP et HTTP/2. Tout autre protocole doit être exclu des analyses afin d'éviter l'introduction de biais non souhaités. La seule exception concerne la couche IP, pour laquelle les adresses source et destination doivent être conservées et utilisées comme identifiants des NF afin de permettre la détection des attaques basées sur les interactions.

Un autre point important de notre dataset est l'absence de contrainte de temps réel, qui n'est pas pertinent dans notre cas d'utilisation. En effet seul l'ordre des

paquets dans les séquence importe pour détecter les attaques que l’on considère. Ainsi, l’utilisation de notre dataset suppose de prendre uniquement en compte de l’ordre d’arrivée des paquets, et d’ignorer leurs horodatages exacts.

4.1.2.3 Réalisme des données synthétiques

En l’absence d’accès à du trafic 5G réel, la principale solution pour les travaux de recherche consiste à s’appuyer sur des données synthétiques, générées à partir d’implémentations open-source de réseaux 5G. Bien qu’elles soient synthétiques, les données générées sur ces implémentations ne sont pas pour autant irréalistes. En effet, la 5G est en partie conçue pour des Réseaux Privés Mobiles (MPN) et destinée aux entreprises souhaitant déployer leur propre infrastructures, notamment pour garantir une faible latence ou protéger des données sensibles. Dans ces situations, il est souvent excessif de redévelopper entièrement un cœur 5G, ce qui favorise l’adoption d’implémentations open-source telles que OAI [oai 2026], free5GC [free5GC Project 2026] et Open5GS [open5gs 2026]. On observe également des cas d’acteurs industriels tels que Firecell [firecell 2026], qui proposent des solutions prêtes à l’emploi intégrant des implémentations basées sur OAI [oai 2026]. Ainsi, même si notre dataset a été généré à partir d’une implémentation différente de celles des grands opérateurs de réseaux mobiles, il constitue une représentation réaliste d’un scénario possible de déploiement 5G privé et apparaît donc comme une solution légitime.

4.1.2.4 Trafic légitime de nature adaptée

La détection d’anomalies nécessite de disposer d’exemples représentatifs de trafic légitime servant de référence face aux attaques. Pourtant, peu de travaux proposent un trafic bénin réellement comparable aux attaques qu’ils cherchent à détecter. Pour chaque attaque incluse dans le datasets, il est donc essentiel d’identifier les messages légitimes pouvant servir de référence lors de la détection. Dans notre approche, chaque attaque intégrée au datasets est associée à au moins un type de message bénin auquel elle peut être comparée. Les résultats sont présentés dans le Tableau 4.2.

4.1.2.5 Caractérisation des attaques proposées

Lorsqu’un datasets intègre des attaques, il est essentiel d’identifier précisément les caractéristiques qui les distinguent du trafic bénin. Dans les sections précédentes, nous avons montré que les attaques pouvaient être catégorisées selon trois dimensions : sémantique, temporelle et topologique. Afin d’éviter l’introduction de biais, il est nécessaire de classifier chaque attaque selon ces dimensions et de vérifier qu’elle ne puisse être détectée qu’à travers l’analyse de la ou des dimensions qui la caractérisent. Ainsi, pour chaque attaque incluse dans notre dataset, nous définissons explicitement les dimensions sur lesquelles elle doit être détectée. Ces correspondances sont détaillées dans le Tableau 4.2.

4.1.2.6 Caractéristiques fortement dépendantes

Une caractéristique fortement dépendante correspond à une propriété inattendue sur laquelle un modèle peut surapprendre durant l’entraînement. La définition du périmètre d’utilisation réduit déjà significativement le nombre de caractéristiques fortement dépendantes susceptibles d’apparaître. Toutefois, de telles caractéristiques peuvent encore émerger au sein des couches retenues. Nous définissons donc plusieurs critères visant à limiter leur apparition.

Pour toute attaque ne reposant pas sur une dimension sémantique, la payload doit être strictement identique à celle d’un paquet bénin. Dans le cas des attaques basées sur la répétition, il est nécessaire de randomiser l’ordre d’exécution des procédures et d’insérer du trafic bénin comme bruit de fond durant les attaques. Enfin, pour les attaques basées sur les interactions, l’adresse IP de l’attaquant doit rester cohérente au sein d’une même instance d’attaque sans pour autant demeurer constante à l’échelle de l’ensemble du datasets.

4.2 Génération d’un dataset

Cette section décrit le dataset généré dans le cadre de nos travaux. Nous présentons dans un premier temps les différents types de messages bénins et malveillants retenus. Nous détaillons ensuite les choix méthodologiques mis en œuvre afin de garantir que les données produites respectent les critères de qualité précédemment définis. Enfin, nous décrivons le processus technique de génération du dataset, de manière à en assurer la reproductibilité.

4.2.1 Trafic bénin

Parmi le trafic de contrôle 5G, les échanges entre entités s’organisent sous forme de séquences de messages appelées procédures. Certaines procédures se limitent à quelques messages échangés entre deux acteurs, tandis que d’autres peuvent impliquer de nombreuses interactions entre plusieurs NF. En effet, lorsqu’une NF doit exécuter une action nécessitant des informations ou des ressources externes, elle peut être amenée à solliciter d’autres NFs, conduisant à des procédures complexes comportant parfois plusieurs dizaines de messages. La plupart sont déclenchées à la suite d’une action initiée par un utilisateur. Toutefois, certaines peuvent également être lancées soit par une fonction réseau du CN, soit en réaction à un événement particulier, soit de manière périodique.

Le standard 5G définit un très grand nombre de procédures, souvent décliné en plusieurs variantes et sont décrites dans la spécification 3GPP TS 23.502 [ESTI 2021]. En pratique, il est difficile de reproduire exhaustivement l’ensemble de ces comportements, d’autant plus que les implémentations open-source disponibles ne couvrent qu’une partie des fonctionnalités prévues par les spécifications. Nous nous concentrons donc sur un sous-ensemble de procédures sélectionnées en fonction de leur importance opérationnelle et de leur pertinence vis-à-vis des scénarios

rios d'attaque considérés. L'objectif est de disposer d'un trafic légitime suffisamment diversifié tout en garantissant la présence de procédures pouvant être directement mises en contraste avec les attaques incluses dans le dataset.




FIGURE 4.1 – Procédure générale d'enregistrement tel que proposé dans la TS 23.502 de 3GPP [ESTI 2021].

4.2.1.1 Enregistrement des UEs

Les procédures d'enregistrement des UEs sont celles les plus couramment utilisés dans l'état de l'art pour générer du trafic légitime. Elles produisent une vingtaine de requêtes réparties entre le RAN et le CN. Ces procédures font intervenir plusieurs protocoles, notamment NGAP, NAS et HTTP/2, ainsi que différentes NF telles que l'AMF, le PCF, le SMF, l'AUSF et l'UDM. Dans le cadre de notre étude, leur principal intérêt réside dans la diversité des messages et des interactions qu'elles génèrent. La Figure 4.1, extraite de la spécification 3GPP, illustre une procédure complète d'enregistrement incluant l'ensemble des étapes optionnelles.

4.2.1.2 Changements d'état des UE

Dans la même logique que les procédures d'enregistrement, PROV5GC [Pacherkar 2024] propose un trafic légitime fondé sur les transitions d'état des UEs. Lorsqu'un UE demeure inactif pendant une certaine durée, une procédure de *Libération de contexte* est automatiquement déclenchée. Celle-ci génère une séquence de messages entre le RAN et le CN visant à modifier l'état de l'UE du point de vue du CN et ainsi économiser des ressources précédemment allouées. Dans notre cas, ces procédures sont déclenchées manuellement, en envoyant nous-mêmes le message de libération de contexte. Lorsqu'un UE inactif redevient actif, une procédure de *requête de service* est initiée afin de rétablir son état actif. Elle peut être déclenchée soit par la réception d'un message à destination d'un UE inactif, soit, à l'inverse, par l'envoi d'un message depuis ce dernier. Qu'il s'agisse de la libération de contexte ou de la reprise d'activité, ces procédures correspondent à des comportements courants dans les réseaux opérationnels et contribuent à accroître la diversité des messages présents dans le dataset.

4.2.1.3 Création et libération de session

Plusieurs attaques décrites dans l'état de l'art ciblent l'interface N4 reliant le SMF et l'UPF, responsable de la gestion des sessions. Sur cette interface, les échanges reposent sur le protocole PFCP qui sont notamment utilisés par des messages de création, de modification et de libération de session qui sont incluses dans la procédure d'enregistrement de l'UE et de redémarrage des sessions actives d'UE.

Certaines attaques [Amponis 2022] ciblant spécifiquement les messages PFCP associés à la création ou à la suppression de sessions, il est indispensable d'inclure des exemples légitimes de ces mêmes procédures dans le dataset afin de garantir une couverture réaliste des comportements du réseau.

4.2.1.4 Gestion des NF

L'architecture du cœur 5G étant conçue pour s'adapter dynamiquement aux variations de charge, il est nécessaire d'avoir à disposition des procédures légitimes d'ajout et de suppression de NF, pourtant absentes de l'état de l'art. Ces opérations

se limitent généralement à une unique requête d'API et surviennent naturellement lors du démarrage ou de l'arrêt du réseau. Comme redémarrer le cœur empièterait sur la disponibilité du réseau, nous simulons ces procédures au cours de l'exécution, tout en garantissant la continuité du service. La manipulation de l'architecture du CN étant exploitée par certaines attaques [Coldwell 2022], la présence de trafic légitime associé à ces opérations constitue une référence nécessaire à leur détection.

4.2.1.5 Transfert de données par l'UPF

Enfin, nous introduisons une seconde procédure absente des travaux de l'état de l'art en générant du trafic utilisateur entre l'UE et le RAN. Le contenu transporté dans le plan utilisateur n'est pas spécifique à la 5G et se situe donc en dehors du périmètre de cette étude. En revanche, son acheminement nécessite l'encapsulation des paquets entre le gNB et l'UPF. Cette encapsulation repose sur le protocole GTP, qui constitue une cible fréquente des attaques décrites dans la littérature [TrendMicro 2023, Park 2022]. L'inclusion de trafic utilisateur permet ainsi de générer des exemples légitimes d'utilisation de GTP, indispensables à la détection et à l'évaluation des attaques ciblant ce protocole.

Attaque	Source	Surface	Bénins comparables	Dimensions
Scan applicatif des NFs	5GAD [Coldwell 2022]	CN	Découverte de NF	Sequentiel / Topologique
Fuzzing d'API	Originale	CN	Tout appel d'API	Sequentiel / Sémantique
Man-in-the-Middle dans le CN	Originale	CN	Gestion de NF	Sequentiel / Topologique
Inondation d'établissement de session	Amponis et al.[Amponis 2023]	SM	Création de session	Sequentiel
Inondation de libération de session	Amponis et al.[Amponis 2023]	SM	Libération de session	Sequentiel
DoS des sessions par modification	Amponis et al.[Amponis 2023]	SM	Modification de session	Sequentiel / Sémantique
Fuzzing du SEID	Originale	SM	Modification de session	Sequentiel
PFCP dans GTP-U	Park et al.[Park 2022]	UP	Tout message GTP-U	Sémantique
Usurpation de trafic montant	Trend Micro [TrendMicro 2023]	UP	Tout message GTP-U	Topologique

Note : CN = cœur de réseau ; SM = gestion de session ; UP = plan utilisateur

TABLE 4.2 – Liste des attaques présentes dans le dataset ainsi que leurs caractéristiques.

4.2.2 Trafic anormal

La littérature recense un large éventail d'attaques ciblant les réseaux mobiles et les infrastructures 5G. Comme évoqué dans le chapitre précédent, certaines de ces attaques exploitent des vulnérabilités spécifiques à des implémentations particulières et ne sont pas nécessairement réalistes dans le cas d'une entreprise disposant d'une implémentation robuste et conforme aux spécifications. Néanmoins, le réel enjeu ici est plutôt que les attaques restent distinguables du trafic normal selon des critères bien définis. Ainsi, en apprenant à détecter des anomalies sur une ou plusieurs des trois dimensions définies précédemment, un modèle peut ensuite être rendu utilisable dans un cadre opérationnel plus réaliste en s'entraînant sur des données réelles. Par ailleurs, étant donné que certaines implémentations open-source

sont utilisées dans des réseaux 5G privés, il est également possible que des attaques aussi triviales existent tout de même en pratique. Pour chaque attaque, nous avons identifié de manière explicite dans le Tableau 4.2 ses dimensions de détection, ainsi que les surfaces d’attaque concernées et les procédures bénignes permettant une comparaison pertinente.

4.2.2.1 Scan applicatif des NFs

Dans les réseaux 5G, les NFs peuvent être instanciées et supprimées dynamiquement. Le NRF maintient un registre des instances actives ainsi que des métadonnées décrivant leurs capacités. Lorsqu’une NF nécessite un service particulier, elle interroge le NRF afin d’identifier les fournisseurs disponibles. 5GAD [Coldwell 2022] souligne que, en l’absence de mécanismes d’authentification adéquats, ces requêtes de découverte peuvent être détournées par un attaquant afin de cartographier l’ensemble du CN. Nous implémentons ce scénario en générant une séquence de requêtes de découverte, chacune ciblant aléatoirement un type de NF différent. Ces messages, pris individuellement, sont entièrement bénins. Toutefois, c’est leur enchaînement ainsi que leur origine commune qui peuvent constituer un comportement anormal.

4.2.2.2 Fuzzing d’API

Les réseaux 5G étant conformes aux spécifications 3GPP, les schémas d’API sont publiquement accessibles. Un attaquant peut ainsi disposer d’une connaissance complète des requêtes possibles ainsi que des formats de paramètres d’entrée attendus. Cette accessibilité est renforcée par des travaux récents [Gregorio 2025] ayant automatisé l’extraction de ces spécifications et leur mise à disposition dans des formats facilement exploitables. Dans ce contexte, un attaquant peut automatiquement générer des requêtes syntaxiquement valides mais contenant des paramètres falsifiés, susceptibles de provoquer des comportements anormaux selon l’implémentation du parser d’API. Dans notre code, nous sélectionnons aléatoirement des services au sein de plusieurs NFs et faisons varier systématiquement les paramètres associés. Ces messages peuvent être détectés soit individuellement via l’analyse de valeurs incohérentes, soit de manière séquentielle via l’identification de séquences anormales.

4.2.2.3 Man-in-the-Middle dans le CN

En l’absence de mécanismes d’authentification suffisants, un attaquant ayant accès au cœur de réseau peut enregistrer des NFs malveillantes de tout type. Lorsqu’une fonction malveillante se déclare comme fournisseur d’un service donné, elle apparaît alors dans les résultats de découverte au même titre que les instances légitimes. Dans le cas de free5GC, lorsqu’une fonction réseau doit sélectionner un fournisseur parmi plusieurs candidats, elle privilégie généralement celui ayant été enregistré le plus anciennement. Un attaquant peut exploiter ce comportement en supprimant puis en ré-enregistrant les NFs légitimes, de manière à faire apparaître sa fonction malveillante comme la plus ancienne. Cette manipulation lui permet de

s'interposer dans les échanges et de rediriger le trafic sans interruption de service. On distingue alors deux phases dans ce scénario. La première correspond à la phase d'établissement, qui se caractérise par des séries de procédures anormales. La seconde phase correspond à la redirection du trafic légitime, dans laquelle l'anomalie réside dans les interactions topologiques observées au sein du réseau.

4.2.2.4 Inondation d'établissement de session

Comme proposé par Amponis et al. [Amponis 2023], une attaque possible est de cibler l'UPF et de lui envoyer un grand nombre de requêtes de création de session. L'objectif est de saturer ses ressources de calcul et de mémoire, entraînant un ralentissement des autres requêtes légitimes. Dans notre implémentation, nous générons des séquences de requêtes de création de session avec des valeurs de SEID et de Identifiant de Tunnel (TEID) aléatoires. Dans ce contexte, les messages produits sont sémantiquement identiques aux messages légitimes et seule leur séquence permet de les distinguer du trafic normal.

4.2.2.5 Inondation de libération de session

Dans cette attaque, Amponis et al. [Amponis 2023] proposent de rompre les sessions établies entre l'UE et le réseau de données en envoyant des requêtes de libération. L'attaquant peut cibler un UE spécifique s'il connaît son SEID, ou bien effectuer une attaque par saturation en variant les identifiants afin de déconnecter un grand nombre d'UE. Dans notre implémentation, nous adoptons une stratégie similaire à celle de l'inondation d'établissement de session, en variant systématiquement les SEIDs. Cette attaque présente de fortes similarités avec la précédente et est donc également détectable principalement sur la dimension séquentielle.

4.2.2.6 DoS des sessions par modification

Amponis et al. [Amponis 2023] décrivent également des attaques reposant sur la modification des Forwarding Action Rule (FAR) afin de perturber discrètement l'accès au plan de données. Une première variante consiste à remplacer l'action de transfert (*forward*) par une action de suppression (*drop*), conduisant l'UPF à éliminer silencieusement les paquets associés à une session ciblée, sans qu'aucune notification ne soit transmise à l'UE. Une seconde variante repose sur la modification de la FAR afin de dupliquer les paquets au lieu de simplement les transférer. Cette duplication peut être utilisée à des fins d'écoute passive ou pour amplifier du DoS. Ces attaques peuvent être détectées à la fois par leur fréquence anormale et par leur contenu, qui comporte des champs ou des configurations inhabituels, absents des requêtes légitimes de modification de session.

4.2.2.7 Fuzzing de SEID

Les attaques de libération et de DoS de sessions supposent l'existence d'une session valide dont le SEID est connu. En l'absence de connaissance d'un SEID valide, un attaquant peut tenter d'exécuter son attaque en testant successivement différents SEID jusqu'à obtenir un résultat concluant. Toutefois, dans le cas des DoS par modification, cette approche peut être détectée à la fois sur les dimensions sémantique et séquentielle. Dans le cas d'attaques par libération de session, dès qu'un SEID valide est identifié, la session associée est supprimée, ce qui empêche toute réutilisation ultérieure de cet identifiant. Afin de discrètement identifier des SEID actifs, un attaquant peut exploiter le comportement des requêtes de modification de session, qui produisent une réponse positive lorsque le SEID existe et une réponse négative dans le cas contraire, même lorsque la requête n'entraîne aucune modification effective de l'état de la session (par exemple lorsque les paramètres demandés correspondent déjà à l'état courant). L'attaquant peut ainsi envoyer un grand nombre de requêtes de modification bénignes, sémantiquement correctes et sans effet, et observer les réponses obtenues. De cette manière, il est possible d'extraire une liste de SEID actifs tout en restant détectable uniquement via la dimension séquentielle.

4.2.2.8 PFCP dans GTP-U

Park et al. [Park 2022] présentent une vulnérabilité liée au processus de décapsulation de l'UPF. Lorsqu'un utilisateur envoie des données vers le réseau de données, celles-ci sont encapsulées dans un paquet GTP-U traversant l'UPF. Celui-ci décapsule le paquet et le redirige vers sa destination. Toutefois, certaines implémentations, telles que free5GC, ne vérifient pas la nature du protocole encapsulé et le traitent de manière transparente. Il devient alors possible d'injecter des messages PFCP dans un tunnel GTP-U. Dans notre cas, nous encapsulons un unique message de suppression de session PFCP dans un paquet GTP-U. Ce type d'encapsulation n'est pas prévu par les spécifications, ce qui rend l'anomalie détectable sur la dimension sémantique.

4.2.2.9 Usurpation d'utilisateur

TrendMicro [TrendMicro 2023] met en évidence une vulnérabilité de type réflexion de paquets dans le protocole GTP-U. En l'absence de validation appropriée, un attaquant ayant accès à l'UPF peut envoyer depuis ce dernier un paquet GTP-U encapsulant un paquet IP falsifié contenant l'adresse d'un UE légitime. Une fois désencapsulé, ce paquet est relayé vers l'Internet, permettant à l'attaquant d'usurper l'identité de l'UE. Celui-ci peut alors émettre des requêtes en se faisant passer pour l'utilisateur légitime et réaliser des actions en son nom. Par exemple, un comportement malveillant répété pourrait conduire certains services à bloquer l'adresse IP associée à cet utilisateur, sans que celui-ci en soit responsable. Son identification repose principalement sur l'analyse de la dimension topologique, en mettant en évidence des incohérences dans les interactions observées entre les différentes entités

du réseau.

4.2.3 Méthodologie de génération

Afin de limiter les biais, nous présentons dans cette section les choix méthodologiques ainsi que les mesures mises en œuvre afin de garantir la qualité, la représentativité et la cohérence du dataset généré.

4.2.3.1 Longueur des attaques par répétition

Dans le trafic anormal, certaines attaques reposent sur l'émission d'un unique message malveillant, tandis que d'autres nécessitent la transmission d'un grand nombre de paquets successifs. Pour ces dernières, le nombre de répétitions a été fixé à 100 messages. En pratique, un attaquant pourrait facilement transmettre un nombre bien plus important de paquets lors d'une attaque par inondation. Toutefois, limiter chaque instance d'attaque à 100 messages permet d'éviter que les scénarios d'inondation ne dominent de manière disproportionnée le dataset, tout en conservant les caractéristiques essentielles de ce type d'attaque.

Cette valeur est considérée comme suffisamment élevée, car dans des conditions normales d'utilisation d'un réseau 5G, des séquences de plus de trois ou quatre messages quasi identiques consécutifs sont très rares. Ainsi, un modèle capable de détecter le comportement anormal généré par 100 messages malveillants consécutifs devrait naturellement être en mesure de se généraliser à des attaques par inondation de plus grande ampleur. Enfin, puisque ces traces d'attaque sont utilisées exclusivement pour l'évaluation, le fait de fixer ce nombre de répétitions ne peut pas introduire de biais dans l'apprentissage.

4.2.3.2 Préservation du contexte temporel

La plupart des datasets 5G existants séparent le trafic bénin et le trafic malveillant en les plaçant dans des intervalles temporels distincts. Cette approche est explicitement critiquée par Flood et al. [Flood 2024], car elle empêche la conservation d'un contexte séquentiel pertinent et favorise l'apparition d'un sur-apprentissage basé sur les périodes plutôt que sur le contenu des échanges. Afin de reproduire des séquences plus réalistes, nous adoptons une approche similaire à celle proposée par 5GCGuard [Tan 2025], consistant à entrelacer le trafic malveillant avec une activité bénigne de fond pendant l'exécution des attaques. Pour ce faire, nous exécutons en parallèle un script générant des procédures bénignes et un autre dédié aux procédures malveillantes. Dans chaque cas, les procédures sont sélectionnées aléatoirement parmi l'ensemble de celles que nous avons implémentées.

4.2.3.3 Préservation du contexte d'identité

Une autre approche couramment utilisée pour distinguer le trafic bénin du trafic malveillant consiste à s'appuyer sur des identités, telles que l'adresse IP. Cette

pratique est fréquente dans les datasets d'IDS, les adresses étant généralement anonymisées a posteriori afin de préserver la confidentialité des utilisateurs. Dans notre cas, le dataset étant entièrement synthétique, il n'est pas soumis à ces contraintes. Nous conservons donc les adresses IP, qui sont essentielles pour la détection des anomalies de nature topologique.

Toutefois, l'utilisation d'une adresse IP fixe pour l'attaquant peut conduire un modèle à sur-apprendre cette caractéristique et à identifier un attaquant uniquement à partir de son adresse. Afin d'éviter ce biais, nous faisons en sorte que l'adresse source associée aux messages d'attaque corresponde à celle d'une NF légitime choisie aléatoirement au sein du CN. Cette configuration peut par exemple simuler la compromission d'une fonction réseau légitime. Afin de conserver un contexte topologique cohérent, nous garantissons toutefois que l'ensemble des messages appartenant à une même procédure d'attaque partagent la même adresse de fonction réseau d'origine.




FIGURE 4.2 – Processus de labellisation préservant les contextes temporels et topologiques grâce à l'utilisation de marqueurs.

4.2.3.4 Labelisation du dataset

Afin d'attribuer une adresse IP cohérente à l'ensemble des paquets appartenant à une même procédure, il est nécessaire d'identifier, pour chaque paquet, à quelle procédure il appartient. Dans cette optique, les attaques sont initialement générées à partir d'une même machine source. Au lancement de chaque procédure, qu'elle soit bénigne ou malveillante, des marqueurs sont injectés sous la forme de paquets UDP temporaires contenant le nom de la procédure.

Ces marqueurs permettent de délimiter automatiquement les frontières temporelles de chaque procédure et de restreindre la modification des adresses source aux seuls paquets situés entre ces bornes. Il est ainsi possible de modifier a posteriori l'ensemble des adresses IP comprises entre deux marqueurs de manière cohérente. Par ailleurs, cette approche permet de générer, en parallèle, une table de correspondance reliant les identifiants des paquets aux noms des procédures associées. Ce processus est illustré sur la figure 4.2.

Bénin			Attaque		
Nom	Procédures	Paquets	Nom	Procédures	Paquets
Enregistrement d'UE	591	467,638	Fuzzing d'API	107	33,308
Redémarrage de session	562	379,181	MITM dans le CN	123	22,587
Trafic utilisateur	317	159,228	Fuzzing de SEID	116	23,858
Libération de contexte	288	67,124	Inondation d'établissement	113	23,949
Réveil par envoi	137	55,599	Inondation de libération	98	20,446
Deregister UE	276	50,279	Scan applicatif	81	4,997
Réveil par reception	279	21,884	Modification : Duplication	119	345
Ajout de NF	261	18,232	Modification : Suppression	100	292
Suppression de NF	253	16,336	Usurpation d'utilisateur	102	102
			PFCP dans GTP-U	101	101
Total	2 265	1 235 501	Total	1 060	129 985

TABLE 4.3 – Nombre de procédures et de paquets pour les scénarios bénins et d'attaque, classés par volume de paquets.

4.2.4 Environnement et implémentation

Les implémentations commerciales de la 5G n'étant pas librement accessibles, nous nous appuyons sur des projets open-source afin de simuler des déploiements réalistes. Plus précisément, nous utilisons *free5GC* [free5GC Project 2026] pour émuler le CN, ainsi que *UERANSIM* [ueransim 2026] pour simuler les UEs et les gNBs du réseau d'accès. Ces outils ont été retenus en raison de leur large adoption au sein de la communauté scientifique et de leur utilisation fréquente dans les travaux de génération de données 5G.

Bien que *free5GC* et *UERANSIM* puissent être exécutés directement sous forme de binaires, nous avons choisi de les déployer via Docker, au moyen du projet *free5gc-compose* [free5GC compose 2025]. L'utilisation de la conteneurisation permet de disposer d'environnements préconfigurés pour l'ensemble des composants, ce qui simplifie le déploiement et améliore la reproductibilité des expériences.

Nous avons également apporté plusieurs modifications à cette architecture basée sur Docker. Tout d'abord, les adresses IP des fonctions réseau ont été fixées, la configuration par défaut reposant sur une attribution dynamique à chaque déploiement. De plus, un nouveau conteneur nommé *NF_EVIL* a été ajouté afin d'exécuter les scénarios d'attaque. Par ailleurs, nous avons modifié le Dockerfile de *UERANSIM* afin d'utiliser notre propre fork, la version originale présentant une défaillance affectant le mécanisme de libération du contexte UE, la rendant inutilisable pour nos expérimentations. La version corrigée est disponible dans notre dépôt GitHub [Hoger 2025].

Le dataset d'apprentissage est constitué exclusivement de trafic bénin, généré sur une période de 15 heures, correspondant à environ 10 000 procédures individuelles. Le dataset d'évaluation, quant à lui, a été produit en exécutant simultanément

du trafic bénin et des scénarios d'attaque pendant 4 heures. Les volumes de trafic générés sont indiqués dans le tableau 4.3.

Les volumes de trafic associés aux attaques présentent une forte hétérogénéité. Celle-ci reflète la distinction entre les attaques fondées sur la répétition de messages, qui génèrent un trafic conséquent, et les attaques sémantiques, dont l'exécution repose généralement sur un nombre restreint de requêtes, voire sur une seule interaction.

4.3 Evaluation des caractéristiques du dataset

Nous avons présenté dans les sections précédentes les différents objectifs de qualité retenus pour la conception de notre dataset, ainsi que la méthodologie mise en œuvre pour les satisfaire. Les procédures bénignes associées à chaque attaque ont été présentées dans le Tableau 4.2. L'objectif de cette section est de vérifier que les attaques incluses dans le dataset ne peuvent être distinguées du trafic légitime associé qu'à travers les dimensions pour lesquelles elles ont été conçues.




FIGURE 4.3 – Proportion de messages bénins sémantiquement identiques à des messages d'attaque de même nature.

4.3.1 Caractérisation sémantique

Afin d'évaluer si les attaques sémantiques sont les seules susceptibles d'être détectées sur cette dimension, nous utilisons la distance de Jaccard. La distance de Jaccard est une métrique permettant de mesurer la similarité entre deux ensembles de caractéristiques. Elle est notamment utilisée dans l'analyse de similarité de contenus textuels, par exemple pour comparer des courriels de phishing [Betts 2024]. Dans notre cas, nous l'utilisons afin d'évaluer si les attaques sémantiques sont les seules susceptibles d'être détectées sur cette dimension. Les champs protocolaires présents dans chaque paquet d'attaque sont représentés sous forme d'un ensemble

de caractéristiques, puis comparés aux ensembles extraits des paquets bénins de nature comparable. Une distance nulle indique que les deux messages partagent exactement les mêmes champs protocolaires et sont donc considérés comme sémantiquement équivalents.

Néanmoins, un même type de message bénin peut présenter plusieurs variations sémantiques. Par exemple, une requête légitime de découverte peut contenir plus ou moins d’informations selon le contexte dans lequel elle est émise. Ainsi, une attaque n’a pas nécessairement besoin d’être identique à l’ensemble du trafic bénin pour être considérée comme potentiellement connue par le modèle. Il suffit en effet qu’au moins un message bénin équivalent présente une distance de Jaccard nulle avec le message d’attaque pour que celui-ci ait pu être observé lors de l’apprentissage. Dans ce cas, il ne devrait pas être détecté sur la seule dimension sémantique.

Nous mesurons donc, pour chaque message généré par une procédure d’attaque, la proportion de messages bénins présentant une distance de Jaccard nulle avec celui-ci. La Figure 4.3 présente les résultats obtenus. Nous observons que seules les attaques considérées comme sémantiques, à savoir l’injection de messages PFCP dans GTP-U et la modification de session, ne disposent d’aucun équivalent bénin strictement identique.

L’attaque par fuzzing d’API constitue un cas particulier et n’est pas incluse dans cette analyse globale. En effet, elle génère des messages sémantiquement différents selon les endpoints sollicités, ce qui nécessite une étude spécifique de leurs caractéristiques. En calculant la distance de Jaccard pour chaque type d’appel d’API indépendamment, nous constatons que 93% des messages générés par cette attaque ne possèdent aucun équivalent sémantiquement identique dans le trafic bénin. Les 7% restants correspondent à des requêtes plausibles, dont la détection repose alors davantage sur leur contexte temporel ou comportemental que sur leur seule structure sémantique.




FIGURE 4.4 – Distribution des messages issues de procédures d’attaques et bénignes en fonction du temps.

4.3.2 Caractérisation séquentielle

Nous avons vu dans les sections précédentes que nous cherchions à limiter les biais temporels en introduisant du bruit de fond durant les phases d'attaque et en randomisant l'ordre d'exécution des événements. La Figure 4.4 met en évidence que, lors de l'exécution d'une attaque, du trafic bénin est systématiquement présent en parallèle, ce qui empêche toute isolation temporelle simple de l'attaque. Cette figure illustre également les différences de longueurs de séquences selon les types d'attaques. Les attaques non fondées sur la répétition apparaissent en très faible quantité, car elles reposent généralement sur un nombre réduit de paquets.

Il existe néanmoins quelques cas particuliers qu'il convient de détailler ici. Bien que les attaques de type scan applicatif soient généralement détectables sur la dimension temporelle, elles génèrent un volume relativement faible sur les graphiques observés. Cela s'explique par le fait que, bien qu'elles reposent sur un principe de répétition, elles n'ont pas besoin de produire un grand nombre de requêtes pour être efficaces.

À l'inverse, l'attaque de type MITM génère un nombre important de paquets bien qu'elle ne soit pas fondée sur la répétition. En effet, si sa phase d'initialisation nécessite un faible nombre de messages, l'ensemble des paquets relayés par la suite est systématiquement annoté comme anomalie. Le fait de considérer les paquets redirigés comme appartenant à la procédure MITM conduit ainsi à une augmentation artificielle du volume de messages associés à cette attaque. Toutefois, comme il s'agit essentiellement d'une redirection de trafic légitime, les séquences restent structurellement similaires à du trafic bénin et ne peuvent être discriminées qu'en analysant les identités et la topologie des échanges. La longueur des séquences associées au MITM est par ailleurs fortement variable, car elle dépend à la fois de la fonction usurpée et de l'intensité avec laquelle celle-ci est sollicitée par le trafic bénin durant la prise de contrôle.

Le dernier cas particulier concerne le fuzzing applicatif. Celui-ci constitue une attaque reposant sur la répétition, générant typiquement de l'ordre d'une centaine de messages par exécution. Cependant, la figure montre que ces messages présentent moins de pics temporels marqués que les autres attaques séquentielles et sont, au contraire, davantage dispersés dans le temps. Ce comportement s'explique par le fait que certaines exécutions de fuzzing peuvent être relativement longues et s'étendre sur plusieurs minutes, en fonction du temps de réponse des NF.

4.3.3 Caractérisation topologique

La dernière dimension d'attaques que l'on veut vérifier est la dimension topologique. L'objectif ici est de vérifier que les motifs théoriques caractérisant ces attaques apparaissent effectivement dans le dataset. Ces motifs sont illustrés sur la Figure 4.5 et ne peuvent pas se produire dans un trafic normal d'un réseau respectant la spécification 3GPP. Afin de dénombrer ces occurrences, nous avons transformé les paquets du dataset en graphes, puis recherché dans ces graphes les




FIGURE 4.5 – Schéma d'interactions : (a) MITM dans le CN (b) Usurpation d'utilisateur.

motifs suivants.

Dans le cas du MITM, nous avons identifié un motif de redirection durant sa phase opérationnelle, dans lequel le récepteur d'une requête API redirige la même requête vers un autre NF. Le nombre d'occurrences de ce motif dépend directement du volume de trafic bénin sollicitant le MITM. Étant donné que ce trafic est généralement important, nous observons ainsi de l'ordre de 4500 occurrences de ce motif, ce qui dépasse largement le nombre d'exécutions distinctes de la procédure MITM.

Pour l'attaque d'usurpation d'utilisateur, nous avons recherché une requête GTP-U dont l'adresse IP source dans l'en-tête IP externe diffère de l'adresse IP de destination de la réponse correspondante. Afin de garantir qu'il s'agit bien d'une réponse, nous vérifions également la cohérence des adresses IP internes. La recherche de ce motif ne permet d'identifier que 72 occurrences, soit 20 de moins que le nombre d'exécutions de la procédure de spoofing. Cet écart est attendu, dans la mesure où des pertes de paquets peuvent être observées lors des requêtes adressées au service web sollicité.

4.3.4 Synthèse

Nous avons vérifié dans cette section que, pour chacune des attaques de notre dataset, la discriminabilité n'est possible qu'au regard des dimensions que nous avons définies. Nous obtenons ainsi un dataset dans lequel le risque de biais a été réduit autant que possible et que nous pourrions utiliser pendant l'entraînement et l'évaluation de nos modèles, dont les expérimentations sont détaillées dans la section suivante.

4.4 Evaluation des modèles de détection

La contribution principale de cette thèse est de proposer un formalisme permettant de représenter de manière explicite les interactions au sein d'un réseau 5G et de détecter les nouvelles anomalies liées à sa nature fortement logiciel. La conception de nouveaux modèles de GNN constitue un domaine de recherche à part

entière et ne relève pas de l’objectif de cette thèse. Nous nous appuyons donc sur des modèles existants de l’état de l’art afin d’évaluer la pertinence du formalisme proposé et de vérifier qu’il permet d’obtenir des résultats encourageants.

Afin de comparer ces modèles de manière rigoureuse, il est nécessaire de les évaluer dans un cadre expérimental unifié, de manière à éviter les biais pouvant être introduits par des différences d’implémentation ou de protocole expérimental. Pour cette raison, nous nous appuyons sur DyGLib, la bibliothèque proposée par Yu et al. [Yu 2023], qui fournit un environnement unifié et bien établi regroupant plusieurs des modèles de l’état de l’art présenté dans la section 3.4.2.2. Parmi ceux retenus figurent CAWN, DyGFormer, TCL et GraphMixer, qui couvrent différentes approches légères d’encodage temporel, ainsi que les modèles DyRep, JODIE et TGN qui représentent les approches plus complexes de voisinage temporel avec un module de mémoire.

Comme présenté dans la section 3.4.5, notre problématique se distingue des scénarios classiquement considérés dans la littérature. Afin de mieux répondre à nos besoins, plusieurs adaptations ont été apportées à la bibliothèque. Ces modifications concernent notamment la prise en compte des informations temporelles associées aux événements ainsi que la gestion des parcours multi-sauts. Ces changements ont été implémentés sous la forme d’un fork de DyGLib, disponible à l’adresse indiquée dans [Hoger 2026a].

L’utilisation de DyGLib nous permet ainsi non seulement de comparer la performance de notre formalisme dans différents modèles dans un cadre homogène, mais également d’évaluer leurs performances des méthodes supervisées et non supervisées. Nous étudierons également l’impact des différentes variantes de NLP présentées précédemment. Les résultats de ces expérimentations sont présentés dans les sections suivantes.

4.4.1 Métriques d’évaluation

Afin d’évaluer les performances des modèles de détection, nous utilisons des métriques standards de machine learning, permettant de quantifier la capacité des modèles à distinguer les comportements normaux des anomalies.

4.4.1.1 Métriques pour la classification binaires

Dans le cas des modèles qui produisent une probabilité comprise entre 0 (bénin) et 1 (anomalie), la décision est relativement simple car il suffit de fixer un seuil (généralement à 0.5) pour déterminer si une observation est considérée comme bénigne ou comme une anomalie. Cette approche est naturelle, car le modèle est entraîné à optimiser ses prédictions par rapport à ce seuil implicite. Une fois les prédictions comparées aux étiquettes réelles, il est alors possible de déterminer les cas où le modèle se trompe ou réussit, puis de calculer différentes métriques de classification.

Le **taux de vrais positifs** (TVP) mesure la proportion d’anomalies correcte-

ment détectées parmi l'ensemble des instances d'attaques :

$$\text{TVP} = \frac{VraisPositifs}{VraisPositifs + FauxNégatifs}$$

Le **taux de faux positifs** (TFP) quantifie la proportion de bénins incorrectement classés comme anormaux :

$$\text{TFP} = \frac{FauxPositifs}{FauxPositifs + VraisNégatifs}$$

Ces métriques sont directement liées à leurs contreparties, le **taux de faux négatifs** (TFN) qui correspond aux attaques non détectées et le **taux de vrais négatifs** (TVN) qui mesure la proportion de bénins correctement classés. On observe ainsi les relations complémentaires suivantes :

$$\text{TVP} = 1 - \text{TFN} \quad \text{et} \quad \text{TVN} = 1 - \text{TFP}$$

Dans notre cas, l'objectif est de maximiser le TVP et de minimiser le TFP. Les autres métriques (TFN et TVN) étant complémentaires, elles ne sont pas utilisées directement dans l'analyse, puisque leurs valeurs peuvent être déduites respectivement à partir du TVP et du TFP.

4.4.1.2 Métriques pour la reconstruction

Dans le cas des modèles de type autoencodeur, l'évaluation est plus délicate. En effet, le modèle ne produit pas directement une probabilité d'appartenance à une classe, mais une erreur de reconstruction. Cette erreur n'est pas bornée entre 0 et 1 et dépend notamment des données et de l'architecture du modèle. Il n'est donc pas possible de choisir un seuil de décision universel de manière arbitraire.

Pour évaluer ce type de modèle, on utilise une courbe Receiver Operating Characteristic (ROC). Le principe consiste à faire varier progressivement le seuil appliqué à l'erreur de reconstruction. Pour chaque valeur de ce seuil, on calcule le TVP et le TFP, puis on représente le TVP en fonction du TFP. La figure 4.6 présente un exemple de courbe ROC.

Une courbe ROC idéale monte rapidement vers le coin supérieur gauche du graphique. Cela signifie que le modèle est capable de détecter une grande proportion des anomalies (TVP élevé) tout en générant peu de fausses alertes (TFP faible). À l'inverse, une courbe proche de la diagonale reliant le coin inférieur gauche au coin supérieur droit indique que le modèle ne discrimine pas mieux les classes qu'un tirage aléatoire.

Afin de résumer les performances d'un modèle par une seule valeur, on calcule généralement l'aire sous la courbe ROC, Area Under the Curve (AUC). Une AUC égale à 0,5 correspond à un classifieur aléatoire, tandis qu'une AUC de 1 indique une séparation parfaite entre les observations normales et les anomalies. En pratique, plus l'AUC est élevée, meilleures sont les capacités de discrimination du modèle.




FIGURE 4.6 – Exemple de courbe ROC.

4.4.2 Approche supervisée




FIGURE 4.7 – Représentation du processus d'apprentissage supervisé.

Parmi les différentes familles d'apprentissage considérées dans cette étude figurent l'apprentissage supervisé et l'apprentissage non supervisé. La première approche étudiée est l'apprentissage supervisé, dont l'objectif est d'entraîner un modèle à partir d'un ensemble de données d'apprentissage contenant des exemples annotés, c'est-à-dire associés à une classe connue. Le modèle apprend ainsi à estimer la probabilité d'existence des arcs dans le graphe à partir des caractéristiques des nœuds et des interactions observées durant la phase d'apprentissage. Une représentation du processus d'apprentissage supervisé est présentée sur la figure 4.7.

Comme présenté dans la section 3.5.1, la principale limite de cette approche est qu'elle permet principalement de détecter des attaques déjà observées ou des variantes proches de celles présentes dans les données d'entraînement. Cependant, dans notre cas, la connaissance préalable des paramètres à analyser permet de sélectionner un sous-ensemble pertinent de caractéristiques et de les encoder à l'aide d'un one-hot encoder. Cette réduction de l'espace de représentation permet de diminuer la complexité du problème et d'obtenir de meilleures performances.

Par ailleurs, la détection d'attaques connues reste une tâche pertinente dans un contexte opérationnel. Grâce au formalisme proposé, les décisions du modèle restent interprétables, ce qui facilite l'analyse des alertes générées. De plus, ce type de modèle peut être réentraîné régulièrement afin d'intégrer de nouveaux comportements

malveillants ou des évolutions de l'infrastructure.

Métrique	JODIE	DyRep	CAWN	DyGFormer	TCL	GraphMixer	TGN
TVP	0.1955	0.3568	0.1548	0.4879	0.5404	0.4906	<u>0.8730</u>
TFP	0.0309	0.0415	0.0026	0.0169	0.0271	0.0215	<u>0.0186</u>
Paquets/s	90.63	41.20	138.43	<u>855.73</u>	151.64	76.23	22.79

TABLE 4.4 – Taux de vrais positifs, taux de faux positifs et temps d'exécution par paquet pour les différents modèles étudiés.

Le tableau 4.4 présente les résultats obtenus par les différents modèles. Parmi les approches évaluées, TGN obtient les meilleures performances avec un taux de vrais positifs de 87,3% et un taux de faux positifs de 1,9%. Ces métriques sont relativement bonnes mais doivent être interprétées avec précaution dans un contexte de détection d'attaques. En effet, sur un volume important de données, un faible taux de faux positifs peut tout de même générer un nombre conséquent d'alertes nécessitant une analyse humaine. De la même manière, le fait de ne pas détecter tous les vrais positifs représente un risque important puisqu'ils correspondent à des attaques non détectées pouvant avoir un impact sur l'infrastructure. Néanmoins, même si les performances actuelles ne sont pas encore suffisantes pour une utilisation opérationnelle directe, ces résultats montrent que le formalisme proposé et son exploitation par des modèles d'apprentissage supervisé sont pertinents.

On observe également que TGN, le modèle le plus performant, est aussi celui présentant le temps d'exécution le plus élevé, avec environ 23 paquets par seconde, soit environ 40 fois moins que le modèle le plus rapide. Cependant, sur notre jeu de données de test, composé de 523 000 paquets générés en environ 5 heures, le flux moyen est d'environ 29 paquets par seconde. Dans ce contexte, TGN n'est donc pas encore capable de traiter le flux en temps réel, mais l'écart reste relativement limité. De plus, la principale cause de cette lenteur semble liée à l'implémentation, qui n'est pas optimisée. Il serait donc possible d'améliorer significativement le temps d'exécution, soit en optimisant le code, soit en simplifiant le modèle.

Pour résumer, les résultats de TGN sont très encourageants et pourront être améliorés dans le futur, tant au niveau de la vitesse d'exécution que des performances, par exemple via l'ajustement des hyperparamètres, des modifications d'architecture ou des optimisations d'implémentation.

4.4.3 Approche non supervisée

Cette section s'intéresse aux approches non supervisées, dont l'objectif est de permettre au modèle d'exploiter des informations issues de l'ensemble des paramètres des paquets en entrée, sans recourir à des étiquettes préalablement définies.

Comme présenté en section 3.4.2.3, deux principales familles de méthodes non supervisées sont considérées dans la littérature. La première repose sur la prédiction de liens, analogue à certaines approches supervisées, dans laquelle le modèle est exposé à un ensemble d'arcs considérés comme valides ainsi qu'à des arcs négatifs,




FIGURE 4.8 – Représentation du processus d'apprentissage non supervisé. La première ligne correspond à une tâche de prédiction de lien avec des arcs négatifs artificiels, tandis que la seconde ligne correspond à une tâche de reconstruction.

qu'il doit apprendre à distinguer. Néanmoins, en l'absence d'exemples d'attaques dans les datasets d'entraînement, des liens artificiellement négatifs sont générés. Ceux-ci sont construits en reliant des attributs initialement non connectés, tout en respectant la structure bipartite du graphe. La seconde approche repose sur des méthodes de reconstruction, dans lesquelles un graphe est fourni en entrée et le modèle est entraîné à en reconstruire la structure ou les attributs associés. Ces deux différentes approches sont représentées sur la figure 4.8.

4.4.3.1 Comparaison des méthodes d'encodage

Quelque soit l'approche, une étape d'encodage est nécessaire afin de transformer les différents paramètres disponibles en représentations vectorielles de dimension finie, en s'appuyant sur des techniques issues du NLP. Parmi les architectures étudiées dans la section 3.5.1, nous retenons les méthodes FastText et BERT qui permettent de capturer des informations contextuelles au sein des séquences textuelles. FastText offre une solution plus légère et rapide, tandis que BERT est généralement plus expressif et performant, au prix d'une complexité computationnelle plus élevée.

Cependant, l'un des objectifs de cette étude est de proposer une méthode de détection utilisable dans des temps compatibles avec un contexte opérationnel. Il est donc nécessaire d'évaluer le surcoût induit par les différentes méthodes d'encodage.

Pour cela, nous avons réalisé une étude expérimentale consistant à mesurer le temps nécessaire à l'encodage d'un paquet de notre dataset. L'attention est principalement portée sur les modèles de la famille BERT, dont le coût d'inférence est susceptible d'être le plus élevé. Plusieurs variantes légères de cette architecture sont ainsi comparées afin de déterminer si certaines offrent un compromis satisfaisant entre qualité de représentation et temps d'encodage. Les performances de ces modèles sont ensuite comparées à celles de FastText, qui constitue la solution de référence en termes de rapidité. Les résultats sont présentés sur le tableau 4.5.

On observe que les temps d'exécution associés aux méthodes basées sur BERT

Méthode d'encodage	Temps d'encodage (s/paquet)
One-hot	4.5×10^{-4}
FastText	5.1×10^{-4}
DistilBERT	1.2
ALBERT	2.4
BERT	4.2

TABLE 4.5 – Comparaison des surcoûts temporels induits par les différentes méthodes d'encodage considérées.

sont de l'ordre de plusieurs secondes par paquet, tandis que les approches FastText et *one-hot* restent inférieures à la milliseconde. Les performances mesurées pour BERT sont en partie liées à l'implémentation utilisée et pourraient potentiellement être optimisés. Néanmoins, le coût computationnel reste significativement plus élevé que celui des autres méthodes évaluées.

Compte tenu de ce surcoût temporel important, les approches basées sur BERT ont été écartées pour la suite de cette étude. Nous avons ainsi choisi de nous concentrer sur FastText, qui offre un compromis plus adapté entre richesse des représentations et temps d'exécution.

4.4.3.2 Prédiction de lien

Pour la prédiction de lien, l'approche suivie est similaire à celle utilisée dans le cadre non supervisé. Cependant, contrairement à l'apprentissage supervisé où le modèle est entraîné sur des données bénignes et des attaques explicitement labélisées, l'apprentissage repose uniquement sur des données bénignes ainsi que sur des arcs négatifs artificiellement générés. Lors de la phase d'évaluation, le modèle est ensuite confronté à la fois à des interactions bénignes et à des interactions issues d'attaques afin d'évaluer sa capacité à identifier des comportements malveillants à partir des écarts par rapport aux interactions normales apprises.

Métrique	JODIE	DyRep	CAWN	DyGFormer	TCL	GraphMixer	TGN
TVP	0.9591	0.9590	0.9993	1.0000	0.9997	0.9974	0.9970
TFP	0.9225	0.9253	0.9974	1.0000	0.9990	0.9938	0.9988
Paquets/s	17.31	2.60	47.87	368.44	60.17	32.32	2.37

TABLE 4.6 – Taux de vrais positifs, taux de faux positifs et débit d'exécution pour les différents modèles étudiés.

Le tableau 4.6 présente les résultats obtenus par les différents modèles. On constate que, quel que soit le modèle considéré, les valeurs de TVP et de TFP sont proches de 1. Ces résultats indiquent que le modèle prédit presque systématiquement la classe bénigne, aussi bien pour les interactions normales que pour les interactions malveillantes. Par conséquent, les performances obtenues sont insuffisantes car le modèle ne parvient pas à discriminer efficacement les comportements anormaux.

Contrairement à l'apprentissage supervisé, le modèle bénéficie ici de beaucoup moins d'informations lors de la phase d'entraînement. Il est ainsi davantage exposé aux biais introduits par la construction des arcs négatifs, dont la sélection peut fortement influencer les performances. De plus, l'utilisation d'un encodage basé sur des techniques de NLP constitue une source d'incertitude supplémentaire, notamment si les représentations obtenues ne capturent pas correctement la sémantique des interactions étudiées.

4.4.3.3 Reconstruction

Pour l'approche par reconstruction, la sortie du modèle est modifiée afin d'obtenir un vecteur de même dimension que celui fourni en entrée. Il devient alors possible de comparer directement le vecteur reconstruit au vecteur original et de calculer une erreur de reconstruction. Cette erreur est ensuite utilisée comme score d'anomalie et les observations présentant une erreur élevée sont considérées comme potentiellement anormales.

Dans notre cas, nous utilisons l'erreur quadratique moyenne Mean Squared Error (MSE) comme métrique de reconstruction. Elle correspond à la moyenne des écarts quadratiques entre chaque dimension du vecteur d'entrée et sa reconstruction :

$$MSE(x, x') = \frac{1}{n} \sum_{i=1}^n (x_i - x'_i)^2$$

où (x) représente le vecteur d'entrée, (x') sa reconstruction par l'autoencodeur et (n) la dimension du vecteur. Cette métrique pénalise fortement les grandes erreurs de reconstruction, ce qui la rend adaptée pour identifier des observations dont la représentation diffère significativement de celles utilisées lors de l'apprentissage.

Les performances obtenues pour les différents modèles sont présentées sous forme de courbes ROC sur la figure 4.9.

Les résultats obtenus sont cependant peu satisfaisants, avec des modèles présentant des valeurs d'AUC faibles, généralement proches voire inférieures à 0,5. Ces performances indiquent que l'erreur de reconstruction ne permet pas de distinguer efficacement les observations normales des anomalies dans notre configuration.

Plusieurs hypothèses peuvent expliquer ces résultats. Premièrement, l'autoencodeur peut avoir appris une représentation trop générale des données, lui permettant de reconstruire correctement aussi bien les observations normales que les anomalies. Dans ce cas, l'erreur de reconstruction ne constitue plus un indicateur discriminant. Deuxièmement, la représentation vectorielle obtenues avec fasttext peut ne pas contenir suffisamment d'informations pertinentes pour permettre au modèle de différencier les deux classes. Enfin, le choix de l'architecture, des paramètres d'apprentissage ou de la fonction de coût peut également limiter la capacité du modèle à apprendre une représentation spécifique aux données normales.




FIGURE 4.9 – Performances des différents modèles représentés sous forme de courbes ROC.

4.5 Représentation interprétable de la détection

L'un des principaux avantages du formalisme proposé réside dans son caractère visuel ainsi que dans son niveau élevé de granularité, qui en font une représentation particulièrement interprétable. Qu'il soit utilisé dans un cadre d'apprentissage supervisé ou non supervisé, le modèle associe à chaque arc du graphe une probabilité reflétant son degré de légitimité. Ces probabilités peuvent ensuite être directement projetées sur la structure du graphe afin de mettre en évidence les éléments ayant contribué à la décision du modèle.

La figure 4.10 présente différents exemples d'anomalies sémantiques, temporelles et topologiques, ainsi que les probabilités d'existence associées prédites par le modèle. Dans le cas d'une anomalie sémantique, le modèle identifie l'arc asso-




FIGURE 4.10 – Représentation des coefficients d’anomalies pour les dimensions (a) sémantique, (b) séquentielle, et (c) topologique. Les nœuds rouges représentent des paquets d’attaque tandis que les verts représentent des paquets bénins.

cié à l’attribut *nf_type*, qui présente un comportement inhabituel, comme étant fortement anormal. Cependant, en raison de l’utilisation de convolutions sur les graphes, les représentations des arcs intègrent une partie de l’information issue de leur voisinage. Ainsi, l’arc associé à l’attribut *path*, bien qu’il ne soit pas directement à l’origine de l’anomalie, peut également être considéré comme partiellement anormal par le modèle.

Pour l’anomalie temporelle, trois paquets successifs sont observés. Leur ordre d’apparition introduit progressivement un comportement atypique, ce qui conduit le modèle à attribuer des scores d’anomalie croissants au fur et à mesure de la séquence. Enfin, dans le cas d’une anomalie topologique, le problème provient d’une redirection inhabituelle. Le modèle doit identifier que l’anomalie est liée au fait que l’adresse IP source et l’attribut *path* du second paquet correspondent à ceux observés dans le premier paquet. Comme précédemment, les arcs adjacents peuvent également hériter d’une partie du caractère anormal en raison de la propagation de l’information au sein du voisinage du graphe.

Cette représentation visuelle peut ainsi compléter un mécanisme de détection

automatisée fondé sur un seuil d'anomalie. Dans un contexte opérationnel, les opérateurs pourraient définir un niveau de sensibilité à partir duquel une alerte est déclenchée. Lorsqu'un paquet ou une interaction dépasse ce seuil, le modèle fournit alors non seulement une indication de l'anomalie détectée, mais également une représentation visuelle détaillée de son contexte, permettant d'identifier les caractéristiques ayant influencé cette décision. La Figure 4.11 présente un exemple réel, plus complet, et donc plus représentatif des scénarios susceptibles d'être observés dans un environnement opérationnel.




FIGURE 4.11 – Représentation de la prédiction d'anomalie sur un graph représentant un ensemble de paquets observés. Les arcs rouges signalent des anomalies très probables tandis que les arcs verts signalent une faible probabilité d'anomalie. Les paquets bénins sont représentés comme des nœuds de couleur bleu et les paquets d'attaques comme des nœuds de couleur rouge.

Sur cette figure, des paquets légitimes issus de procédures de redémarrage de session (nœuds bleus) ainsi que des paquets associés à des attaques de type DoS de sessions et Fuzzing de SEID (nœuds rouges) sont représentés simultanément au sein d'un même graph. On observe notamment que les arcs liés aux attaques ne sont pas tous directement classés comme fortement anormaux. Dans le cas des attaques

Fuzzing de SEID, les premiers paquets sont représentés en orange, traduisant une sémantique initiale peu suspicieuse. Les paquets d'attaques suivants constituent de surcroît une anomalie temporelle et renforcent la confiance du modèle quant à la présence d'une anomalie. À l'inverse, les paquets issus des attaques de DoS de session sont immédiatement identifiés comme fortement anormaux. Cette distinction s'explique par le fait que ces paquets en particuliers doivent présenter des caractéristiques structurelles et sémantiques directement anormales.

La principale limitation de cette représentation réside dans le fait qu'elle ne capture pas explicitement la dimension temporelle des échanges. Néanmoins, dans un contexte opérationnel, ce formalisme pourrait être étendu sous la forme d'une visualisation dynamique dans laquelle les paquets et les interactions apparaîtraient progressivement au cours du temps. Une telle approche permettrait de combiner l'interprétabilité structurelle du graphe avec une analyse temporelle plus fine des comportements observés.

4.6 Conclusion

Dans ce chapitre, nous avons mis en évidence le manque de datasets publics adaptés à l'évaluation et à la comparaison des approches proposées. Les quelques ensembles de données existants présentent soit une couverture insuffisante des cas d'usage considérés, soit des lacunes en termes de reproductibilité, notamment en raison de l'absence de procédures, d'outils ou de ressources permettant leur réutilisation.

Face à ce constat, un effort conséquent a été consacré à la conception et à la génération d'un nouveau dataset. Cette tâche s'est révélée particulièrement complexe, la définition même de la qualité d'un dataset demeurant un sujet de recherche actif pour lequel aucun consensus définitif n'a encore émergé. Dans ce contexte, une attention particulière a été portée à la réduction des biais potentiels, à la diversité des scénarios représentés ainsi qu'à la couverture des différentes dimensions et surfaces d'attaque considérées. La qualité du dataset a par ailleurs été évaluée a posteriori à l'aide des critères définis au cours de cette étude.

Ce dataset a ensuite servi de base à l'entraînement et à l'évaluation de plusieurs modèles reposant sur différentes architectures et paradigmes d'apprentissage. Bien que les résultats obtenus avec l'apprentissage non supervisé soient limités, ceux obtenus avec les approches supervisées montrent qu'il est possible d'atteindre des performances satisfaisantes pour la détection des comportements anormaux étudiés dans notre formalisme. Au-delà des métriques de performance, l'utilisation d'une représentation graphique fondée sur les graphes permet également de fournir une interprétation fine des décisions prises par les modèles. Cette capacité d'explicabilité constitue un atout majeur dans un contexte opérationnel, où les systèmes de détection doivent non seulement identifier les anomalies, mais également fournir aux opérateurs humains les éléments nécessaires à leur compréhension et à leur analyse.

Conclusion

Sommaire

5.1 Contributions	88
5.2 Limites et perspectives	88
5.2.1 Optimisation de l'implémentation et utilisation de BERT . .	88
5.2.2 Mise en place d'un modèle spécialisé	89
5.2.3 Extension du dataset CTD5G	89
5.2.4 Intégration d'informations système	89
5.3 Synthèse	90

Au cours de cette thèse, nous avons tâché d'étudier les évolutions introduites par la 5G, tant du point de vue des nouvelles surfaces d'attaque que de la nature des menaces auxquelles ces réseaux sont exposés. Cette analyse nous a permis de mettre en évidence que la notion d'attaque 5G demeure encore insuffisamment unifiée dans la littérature. Les travaux existants adoptent des définitions et des niveaux de réalisme très hétérogènes, rendant difficile la comparaison des approches proposées. Afin de répondre à cette limite, nous avons proposé une classification des attaques visant à fournir un cadre commun pour l'étude et l'évaluation des mécanismes de détection.

Nous avons également montré que les spécificités des réseaux 5G nécessitent une analyse approfondie des paquets échangés, en prenant simultanément en compte trois dimensions : sémantique, séquentielle et topologique. Nous avons ainsi proposé un nouveau formalisme reposant sur les graphes dynamiques continus, capable de représenter conjointement ces trois aspects tout en offrant un niveau d'interprétabilité élevé, indispensable dans le contexte de la cybersécurité.

Par ailleurs, nos travaux ont mis en évidence le manque cruel de datasets publics, complets et reproductibles dans l'état de l'art pour évaluer les approches de détection dans des environnements 5G. Afin de pallier cette limitation, nous avons conçu notre propre dataset couvrant un ensemble étendu de procédures bénignes et de scénarios d'attaque, tout en veillant à garantir sa qualité et sa reproductibilité afin de faciliter la comparaison de futurs travaux.

Enfin, nous avons évalué plusieurs architectures de réseaux de neurones sur graphes dynamiques afin d'étudier leur capacité à exploiter le formalisme proposé. Les résultats obtenus montrent que cette représentation est adaptée à la détection d'anomalies dans les réseaux 5G, en particulier dans un cadre supervisé, où les meilleurs modèles atteignent une accuracy d'environ 94%. Ces résultats confirment

l'intérêt des graphes dynamiques pour représenter les interactions complexes observées dans les infrastructures 5G et ouvrent la voie à de futurs travaux visant à améliorer encore leurs performances ainsi que leur capacité de généralisation à des environnements opérationnels.

5.1 Contributions

Les principales contributions de cette thèse peuvent être résumées comme suit :

- **Analyse critique des attaques 5G et des cadres de catégorisation existants.** Nous mettons en évidence les limites des cadres de catégorisation existants et proposons une classification permettant de structurer les différentes familles d'attaques selon les surfaces du réseau 5G qu'elles ciblent.
- **Proposition d'un formalisme de graphes dynamiques continus.** Nous introduisons une représentation permettant de capturer simultanément les dimensions sémantique, temporelle et topologique des échanges au sein d'un réseau 5G, tout en conservant un haut niveau d'interprétabilité.
- **Conception d'un dataset de trafic de contrôle 5G.** Nous proposons un nouveau dataset couvrant un ensemble étendu de procédures bénignes et de scénarios d'attaque, afin de pallier le manque de datasets publics représentatifs des environnements 5G.
- **Evaluation comparative de modèles de détection d'anomalies** Nous comparons plusieurs architectures de l'état de l'art, dans des contextes supervisés et non supervisés, afin d'évaluer leur aptitude à exploiter le formalisme proposé pour la détection d'anomalies dans les réseaux 5G.

5.2 Limites et perspectives

Bien que les principaux objectifs de cette thèse aient été atteints, plusieurs pistes d'amélioration et d'extension n'ont pas pu être explorées pleinement et pourront faire l'objet de travaux futurs.

5.2.1 Optimisation de l'implémentation et utilisation de BERT

Une perspective concerne l'optimisation de l'implémentation utilisée pour l'évaluation des modèles. Nous avons initialement prévu d'intégrer des modèles d'encodage plus complexes, tel que BERT, afin d'étudier leur impact sur les performances. Cependant, l'implémentation actuelle de DyGLib présente plusieurs limitations en termes d'efficacité computationnelle, rendant l'entraînement de modèles plus coûteux difficilement envisageable.

En particulier, la gestion mémoire adoptée par la librairie n'est pas totalement adaptée aux contraintes des graphes dynamiques. L'espace mémoire est réservé pour des nœuds futurs avant leur apparition, et aucun mécanisme efficace de suppression des nœuds trop anciens n'est proposé. Cela conduit progressivement à une augmentation importante de la taille du graphe et ralentit fortement les entraînements.

Ces contraintes nous ont conduits à ne pas intégrer BERT dans les expérimentations finales, malgré son potentiel pour améliorer la représentation sémantique des paramètres réseau. Une optimisation de l'implémentation permettrait ainsi d'explorer ces modèles plus complexes dans de futurs travaux.

5.2.2 Mise en place d'un modèle spécialisé

Dans cette étude, nous avons principalement utilisé des modèles issus de l'état de l'art afin d'évaluer notre formalisme, avec seulement quelques adaptations mineures. Toutefois, ces architectures ne sont pas nécessairement optimisées pour répondre aux spécificités de notre problématique.

Une perspective d'amélioration serait donc de concevoir une architecture dédiée, comme cela est fréquemment réalisé dans les travaux existants. Dans notre cas, une telle architecture pourrait notamment exploiter les particularités de notre représentation sous forme de graphe biparti, ainsi que le fait que l'information pertinente soit portée par les arcs plutôt que par les nœuds. Un modèle mieux adapté à la structure des données et aux objectifs de détection considérés permettrait ainsi d'améliorer les performances globales.

5.2.3 Extension du dataset CTD5G

Le dataset CTD5G couvre de manière satisfaisante les surfaces d'attaque définies dans le périmètre de cette étude et permet de détecter les attaques qui leur sont associées. Néanmoins, certaines surfaces n'ont pas pu être prises en compte.

C'est notamment le cas de l'AN, pour lequel le dataset contient du trafic légitime mais aucun scénario d'attaque. Les procédures de *handover* constituent également une piste d'extension, puisqu'elles mettent en jeu une pile protocolaire spécifique ainsi que des scénarios impliquant le changement de gNB par un UE au cours de son déplacement.

Le *slicing* représente une autre perspective intéressante. Plusieurs attaques ciblant ce mécanisme ont déjà été proposées dans la littérature [Kumar 2023, Enea 2021]. Toutefois, les implémentations open-source actuelles offrent un support encore limité de cette fonctionnalité. En pratique, l'identifiant de slice est principalement utilisé comme un simple critère de filtrage, plutôt que comme un véritable mécanisme d'isolation logique entre les différentes tranches du réseau.

Bien que la couverture actuelle du dataset soit suffisante pour les surfaces d'attaque considérées dans le périmètre de cette étude, l'intégration de ces nouvelles surfaces permettrait d'améliorer davantage sa représentativité en regard des fonctionnalités avancées des réseaux 5G.

5.2.4 Intégration d'informations système

Les logs systèmes sont fréquemment utilisés pour la détection d'anomalies dans le domaine des systèmes distribués [Bogatinovski 2021]. Dans notre approche, nous

avons choisi de ne pas les intégrer, car ils constituent une représentation indirecte et partielle des événements réseau.

Toutefois, plutôt que de s'appuyer sur la surcouche que constituent les logs, une approche alternative consisterait à surveiller directement les appels systèmes effectués par les machines hôtes afin d'intégrer des informations issues de l'environnement d'exécution. Ces données pourraient permettre d'identifier des comportements complémentaires, comme les phases d'une intrusion ainsi que les conséquences système des attaques réseau, telles que les surcharges ou les pertes de connectivité.

Le travail de Raulin et al. [Raulin 2023] propose notamment une modélisation des appels systèmes sous forme de graphes, ce qui ouvre la possibilité d'adapter ce formalisme à notre représentation et de combiner les informations réseau et système. Une telle approche nécessiterait néanmoins une étape de sélection des événements pertinents afin d'écarter les comportements systèmes non liés à la détection d'attaques réseau, ce qui représente un défi supplémentaire mais constitue une perspective intéressante.

5.3 Synthèse

Au cours de cette thèse, nous avons étudié les approches existantes en détection d'anomalies dans les réseaux 5G et mis en évidence plusieurs limites de l'état de l'art, notamment concernant les attaques considérées, les datasets disponibles et les méthodes de détection proposées.

La principale contribution de ce travail est la proposition d'un nouveau formalisme permettant de répondre à ces limites. Celui-ci permet de détecter des attaques couvrant les trois dimensions étudiées, tout en conservant une forte capacité d'explicabilité. Cette propriété le rend particulièrement adapté aux environnements nécessitant une validation humaine, comme les SOC.

Les résultats obtenus sont encourageants, avec des performances atteignant jusqu'à 94% d'accuracy. Ces performances pourraient encore être améliorées par des modèles plus spécialisés ou des étapes de *fine-tuning*.

Ainsi, cette thèse ouvre de nouvelles perspectives pour l'amélioration des méthodes et outils existants, tout en proposant de nouvelles opportunités grâce au formalisme développé et à l'exploitation de modèles de graphes continus dynamiques.

Bibliographie

- [Amponis 2022] George Amponis, Panagiotis Radoglou-Grammatikis, Thomas Lagkas, Wissam Mallouli, Ana Cavalli, Dimitris Klonidis, Evangelos Markakis et Panagiotis Sarigiannidis. *Threatening the 5G core via PFCP DoS attacks : the case of blocking UAV communications*. EURASIP Journal on Wireless Communications and Networking, no. 1, page 124, 2022. (Cité en pages 10, 17, 19, 20 et 64.)
- [Amponis 2023] George Amponis, Panagiotis Radoglou-Grammatikis, George Nakas, Sotirios Goudos, Vasileios Argyriou, Thomas Lagkas et Panagiotis Sarigiannidis. *5G core PFCP intrusion detection dataset*. Dans 2023 12th International Conference on Modern Circuits and Systems Technologies (MOCAST), pages 1–4. IEEE, 2023. (Cité en pages 6, 58, 59, 65 et 67.)
- [Ariu 2011] Davide Ariu, Roberto Tronci et Giorgio Giacinto. *HMMPayl : An intrusion detection system based on Hidden Markov Models*. Computers & Security, vol. 30, no. 4, pages 221–241, juin 2011. (Cité en page 28.)
- [Bandyopadhyay 2020] Sambaran Bandyopadhyay, Lokesh N, Saley Vishal Vivek et M. N. Murty. *Outlier Resistant Unsupervised Deep Architectures for Attributed Network Embedding*. Dans Proceedings of the 13th International Conference on Web Search and Data Mining, WSDM '20, pages 25–33, New York, NY, USA, janvier 2020. Association for Computing Machinery. (Cité en page 42.)
- [Betts 2024] Lucas Betts, Robert Biddle, Danielle Lottridge et Giovanni Russello. *Exploring Content Concealment in Email*. Dans 2024 APWG Symposium on Electronic Crime Research (eCrime), pages 58–75, septembre 2024. ISSN : 2159-1245. (Cité en page 72.)
- [Bogatinovski 2021] Jasmin Bogatinovski et Sasho Nedelkoski. *Multi-Source Anomaly Detection in Distributed IT Systems*, janvier 2021. (Cité en pages 32 et 89.)
- [Bojanowski 2017] Piotr Bojanowski, Edouard Grave, Armand Joulin et Tomas Mikolov. *Enriching Word Vectors with Subword Information*, juin 2017. (Cité en pages 50 et 52.)
- [Brochier 2019] Robin Brochier, Adrien Guille et Julien Velcin. *Global Vectors for Node Representations*. Dans The World Wide Web Conference, pages 2587–2593, mai 2019. (Cité en page 52.)
- [Chen 2021] Jun Chen et Haopeng Chen. *Edge-Featured Graph Attention Network*, janvier 2021. (Cité en page 47.)
- [Chlosta 2021] Merlin Chlosta, David Rupperecht, Christina Pöpper et Thorsten Holz. *5G SUCI-catchers : still catching them all ?* Dans Proceedings of

- the 14th ACM Conference on Security and Privacy in Wireless and Mobile Networks, WiSec '21, pages 359–364, New York, NY, USA, juin 2021. Association for Computing Machinery. (Cité en pages 18 et 19.)
- [Coldwell 2022] Cooper Coldwell, Denver Conger, Edward Goodell, Brendan Jacobson, Bryton Petersen, Damon Spencer, Matthew Anderson et Matthew Sgambati. *Machine Learning 5G Attack Detection in Programmable Logic*. Dans 2022 IEEE Globecom Workshops (GC Wkshps), pages 1365–1370, décembre 2022. (Cité en pages 10, 17, 19, 58, 59, 65 et 66.)
- [Cong 2023] Weilin Cong, Si Zhang, Jian Kang, Baichuan Yuan, Hao Wu, Xin Zhou, Hanghang Tong et Mehrdad Mahdavi. *Do We Really Need Complicated Model Architectures For Temporal Networks ?*, février 2023. (Cité en pages 40 et 41.)
- [Devlin 2019] Jacob Devlin, Ming-Wei Chang, Kenton Lee et Kristina Toutanova. *BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding*, mai 2019. (Cité en page 52.)
- [Doll 2025] John Doll, Carson McCarthy, Hannah McDougall et Suman Bhunia. *Unraveling Log4Shell : Analyzing the Impact and Response to the Log4j Vulnerabil*, janvier 2025. (Cité en page 8.)
- [Enea 2021] Enea. *A Slice in Time : Slicing Security in 5G Core Networks*, mars 2021. (Cité en pages 8 et 89.)
- [ESTI 2021] ESTI. *TS 123 502 - V16.7.0 - 5G ; Procedures for the 5G System (5GS) (3GPP TS 23.502 version 16.7.0 Release 16)*, 2021. (Cité en pages 62 et 63.)
- [ETSI 2024] ETSI. *Network Functions Virtualisation (NFV) ; Release 4 ; Management and Orchestration ; Architectural Framework Specification*, mai 2024. (Cité en page 8.)
- [Ettiane 2021] Raja Ettiane, Abdelaali Chaoub et Rachid Elkouch. *Toward securing the control plane of 5G mobile networks against DoS threats : Attack scenarios and promising solutions*. Journal of Information Security and Applications, vol. 61, page 102943, 2021. (Cité en pages 6 et 9.)
- [Fan 2025] Wei Fan, Bingnan Shi et Cheng Peng. *A Novel 5G Key Reinstallation Attack and Defensive Strategies*. Dans 2025 IEEE Wireless Communications and Networking Conference (WCNC), pages 1–6, mars 2025. ISSN : 1558-2612. (Cité en pages 18 et 19.)
- [Feng 2024] ZhengZhao Feng, Rui Wang, TianXing Wang, Mingli Song, Sai Wu et Shuibing He. *A Comprehensive Survey of Dynamic Graph Neural Networks : Models, Frameworks, Benchmarks, Experiments and Challenges*, 2024. (Cité en page 41.)
- [FIGHT 2026] FIGHT. *FiGHT Matrix / MITRE FiGHT™*, 2026. (Cité en page 20.)
- [firecell 2026] firecell. *Firecell <https://firecell.io/fr/>*, 2026. (Cité en pages 7 et 61.)
- [Flood 2024] Robert Flood, Gints Engelen, David Aspinall et Lieven Desmet. *Bad Design Smells in Benchmark NIDS Datasets*. Dans 2024 IEEE 9th European

- Symposium on Security and Privacy (EuroS&P), pages 658–675, juillet 2024. (Cité en pages 59 et 69.)
- [free5GC compose 2025] free5GC compose. *free5gc/free5gc-compose*, 2025. (Cité en page 71.)
- [free5GC Project 2026] free5GC Project. *free5GC : 5G Core Network*, 2026. Accessed : 2026-03-31. (Cité en pages 14, 61 et 71.)
- [Ganesh 2017] Meenu Ganesh, Priyanka Pednekar, Pooja Prabhuswamy, Divyashri Sreedharan Nair, Younghee Park et Hyeran Jeon. *CNN-Based Android Malware Detection*, juillet 2017. (Cité en page 28.)
- [Gilmer 2017] Justin Gilmer, Samuel S. Schoenholz, Patrick F. Riley, Oriol Vinyals et George E. Dahl. *Neural Message Passing for Quantum Chemistry*, juin 2017. (Cité en page 39.)
- [Gregorio 2025] Jesus de Gregorio. *jdegre/5GC_APIs*, 2025. (Cité en page 66.)
- [Gupta 2015] A. Gupta et R. K. Jha. *A Survey of 5G Network : Architecture and Emerging Technologies*. IEEE Access, vol. 3, pages 1206–1232, 2015. (Cité en page 5.)
- [Hamilton 2018] William L. Hamilton, Rex Ying et Jure Leskovec. *Inductive Representation Learning on Large Graphs*, 2018. (Cité en pages 32 et 39.)
- [Han 2022] Kai Han, Yunhe Wang, Jianyuan Guo, Yehui Tang et Enhua Wu. *Vision GNN : An Image is Worth Graph of Nodes*. NeurIPS, 2022. (Cité en page 37.)
- [Hoger 2025] Thomas Hoger. *thomas-hoger/free5gc-compose*, 2025. (Cité en page 71.)
- [Hoger 2026a] Thomas Hoger. *thomas-hoger/DyGLib*, mai 2026. original-date : 2026-02-24T15 :15 :48Z. (Cité en page 76.)
- [Hoger 2026b] Thomas Hoger, Philippe Owezarski et Guilhem Durand-Nauze. *Control Traffic Dataset and Generation Framework for 5G Networks*, 2026. (Cité en pages 6, 17 et 19.)
- [Hou 2022] Zhenyu Hou, Xiao Liu, Yukuo Cen, Yuxiao Dong, Hongxia Yang, Chunjie Wang et Jie Tang. *GraphMAE : Self-Supervised Masked Graph Autoencoders*, juillet 2022. (Cité en page 42.)
- [Hussain 2019] Syed Rafiul Hussain, Mitziu Echeverria, Imtiaz Karim, Omar Chowdhury et Elisa Bertino. *5GReasoner : A Property-Directed Security and Privacy Analysis Framework for 5G Cellular Network Protocol*. Dans Proceedings of the 2019 ACM SIGSAC Conference on Computer and Communications Security, pages 669–684, London United Kingdom, novembre 2019. ACM. (Cité en pages 18 et 19.)
- [Jiao 2024] Pengfe Jiao, Xinxun Zhang, Mengzhou Gao, Tianpeng Li et Zhidong Zhao. *Informative Subgraphs Aware Masked Auto-Encoder in Dynamic Graphs*, sep 2024. (Cité en page 42.)

- [Kale 2023] Rahul Kale, Kar Wai Fok et Vrizzlynn L. L. Thing. *Payload-based 5G Attack Detection*. Dans 2023 9th International Conference on Computer and Communications (ICCC), pages 1262–1266, décembre 2023. (Cité en pages 28 et 31.)
- [Kipf 2017] Thomas N. Kipf et Max Welling. *Semi-Supervised Classification with Graph Convolutional Networks*, 2017. (Cité en page 39.)
- [Koc 2012] Levent Koc, Thomas A. Mazzuchi et Shahram Sarkani. *A network intrusion detection system based on a Hidden Naïve Bayes multiclass classifier*. Expert Systems with Applications, vol. 39, no. 18, pages 13492–13500, décembre 2012. (Cité en page 27.)
- [Kula 2018] Raula Gaikovina Kula, Daniel M. German, Ali Ouni, Takashi Ishio et Katsuro Inoue. *Do Developers Update Their Library Dependencies ? An Empirical Study on the Impact of Security Advisories on Library Migration*. Empirical Software Engineering, vol. 23, no. 1, pages 384–417, 2018. (Cité en page 8.)
- [Kumar 2019] Srijan Kumar, Xikun Zhang et Jure Leskovec. *Predicting Dynamic Embedding Trajectory in Temporal Interaction Networks*, août 2019. (Cité en pages 41 et 46.)
- [Kumar 2023] Ayush Kumar et Vrizzlynn L.L. Thing. *Malicious Lateral Movement in 5G Core With Network Slicing And Its Detection*. Dans 2023 33rd International Telecommunication Networks and Applications Conference, pages 110–117, novembre 2023. (Cité en pages 8 et 89.)
- [Lam 2020] Jordan Lam et Robert Abbas. *Machine Learning based Anomaly Detection for 5G Networks*, mars 2020. (Cité en pages 28 et 31.)
- [Lanvin 2022] Maxime Lanvin, Pierre-François Gimenez, Yufei Han, Frédéric Majorczyk, Ludovic Mé et Éric Totel. *Errors in the CICIDS2017 Dataset and the Significant Differences in Detection Performances It Makes*. Dans Risks and Security of Internet and Systems : 17th International Conference, CRiSIS 2022, Sousse, Tunisia, December 7-9, 2022, Revised Selected Papers, pages 18–33, Berlin, Heidelberg, décembre 2022. Springer-Verlag. (Cité en page 59.)
- [Liu 2010] Yan Liu, Ning Cao, Wei Pan et Guangwei Qiao. *System anomaly detection in distributed systems through MapReduce-Based log analysis*. Dans 2010 3rd International Conference on Advanced Computer Theory and Engineering (ICACTE), volume 6, pages V6–410–V6–413, août 2010. (Cité en page 32.)
- [Liu 2023] Yixin Liu, Shirui Pan, Yu Guang Wang, Fei Xiong, Liang Wang, Qingfeng Chen et Vincent CS Lee. *Anomaly Detection in Dynamic Graphs via Transformer*. IEEE Transactions on Knowledge and Data Engineering, vol. 35, no. 12, pages 12081–12094, décembre 2023. (Cité en page 32.)
- [Madi 2021] Taous Madi, Hyame Assem Alameddine, Makan Pourzandi, Amine Boukhtouta, Moataz Shoukry et Chadi Assi. *AutoGuard : A Dual Intelli-*

- gence *Proactive Anomaly Detection at Application-Layer in 5G Networks*. Dans Elisa Bertino, Haya Shulman et Michael Waidner, éditeurs, *Computer Security – ESORICS 2021*, pages 715–735, Cham, 2021. Springer International Publishing. (Cité en pages 29 et 31.)
- [Mahyoub 2024] Mohammed Mahyoub, AbdulAziz AbdulGhaffar, Emmanuel Alalade, Ezekiel Ndubisi et Ashraf Matrawy. *Security Analysis of Critical 5G Interfaces*. *IEEE Communications Surveys & Tutorials*, vol. 26, no. 4, pages 2382–2410, 2024. (Cité en page 9.)
- [Mikolov 2013] Tomas Mikolov, Kai Chen, Greg Corrado et Jeffrey Dean. *Efficient Estimation of Word Representations in Vector Space*, septembre 2013. (Cité en page 51.)
- [Moon 2017] Daesung Moon, Hyungjin Im, Ikkyun Kim et Jong Park. *DTB-IDS : an intrusion detection system based on decision tree using behavior analysis for preventing APT attacks*. *The Journal of Supercomputing*, vol. 73, juillet 2017. (Cité en page 27.)
- [Münz 2007] Gerhard Münz, Sa Li et G. Carle. *Traffic Anomaly Detection Using K-Means Clustering*. 2007. (Cité en page 28.)
- [Nguyen 2019] Thien Duc Nguyen, Samuel Marchal, Markus Miettinen, Hossein Fereidooni, N. Asokan et Ahmad-Reza Sadeghi. *D²IoT : A Federated Self-learning Anomaly Detection System for IoT*, mai 2019. (Cité en page 31.)
- [oai 2026] oai. *OpenAirInterface* <https://openairinterface.org/>, 2026. (Cité en pages 7, 14 et 61.)
- [open5gs 2026] open5gs. *Open5GS*, 2026. (Cité en pages 14 et 61.)
- [Pacherkar 2024] Harsh Sanjay Pacherkar et Guanhua Yan. *PROV5GC : Hardening 5G Core Network Security with Attack Detection and Attribution Based on Provenance Graphs*. Dans *Proceedings of the 17th ACM Conference on Security and Privacy in Wireless and Mobile Networks, WiSec '24*, pages 254–264, New York, NY, USA, mai 2024. Association for Computing Machinery. (Cité en pages 29, 30, 31, 59 et 64.)
- [Pareja 2019] Aldo Pareja, Giacomo Domeniconi, Jie Chen, Tengfei Ma, Toyotaro Suzumura, Hiroki Kanezashi, Tim Kaler, Tao B. Schardl et Charles E. Leiserson. *EvolveGCN : Evolving Graph Convolutional Networks for Dynamic Graphs*, 2019. (Cité en page 39.)
- [Park 2022] Seongmin Park, Sungmoon Kwon, Youngkwon Park, Dowon Kim et Ilsun You. *Session Management for Security Systems in 5G Standalone Network*. *IEEE Access*, vol. 10, pages 73421–73436, 2022. (Cité en pages 6, 9, 18, 19, 65 et 68.)
- [Pazho 2024] Armin Danesh Pazho, Ghazal Alinezhad Noghre, Arnab A Purkayastha, Jagannadh Vempati, Otto Martin et Hamed Tabkhi. *A Survey of Graph-Based Deep Learning for Anomaly Detection in Distributed Systems*. *IEEE Transactions on Knowledge and Data Engineering*, vol. 36, no. 1, pages 1–20, janvier 2024. (Cité en page 32.)

- [Protogerou 2021] Aikaterini Protogerou, Stavros Papadopoulos, Anastasios Drosou, Dimitrios Tzovaras et Ioannis Refanidis. *A graph neural network method for distributed anomaly detection in IoT*. Evolving Systems, vol. 12, mars 2021. (Cité en page 32.)
- [Radford 2018] Alec Radford, Karthik Narasimhan, Tim Salimans et Ilya Sutskever. *Improving Language Understanding by Generative Pre-Training*. 2018. (Cité en page 52.)
- [Raulin 2023] Vincent Raulin, Pierre-François Gimenez, Yufei Han et Valérie Viet Triem Tong. *BAGUETTE : Hunting for Evidence of Malicious Behavior in Dynamic Analysis Reports*. 20th International Conference on Security and Cryptography, janvier 2023. Pages : 424. (Cité en page 90.)
- [Rossi 2020] Emanuele Rossi, Ben Chamberlain, Fabrizio Frasca, Davide Eynard, Federico Monti et Michael Bronstein. *Temporal Graph Networks for Deep Learning on Dynamic Graphs*, 2020. (Cité en pages 41, 43, 44 et 45.)
- [Salazar 2021] Zujany Salazar, Huu Nghia Nguyen, Wissam Mallouli, Ana R. Cavalli et Edgardo Montes de Oca. *5Greplay : a 5G Network Traffic Fuzzer – Application to Attack Injection*. Dans Proceedings of the 16th International Conference on Availability, Reliability and Security, pages 1–8, août 2021. arXiv :2304.05719 [cs]. (Cité en pages 18 et 19.)
- [Salazar 2023] Zujany Salazar, Fatiha Zaïdi, Huu-Nghia Nguyen, Wissam Mallouli, Ana Rosa Cavalli et Edgardo Montes De Oca. *A Network Traffic Mutation based Ontology, and its application to 5G networks*. IEEE Access, vol. 11, pages 43925–43944, 2023. (Cité en page 6.)
- [Samarakoon 2022] Sehan Samarakoon Samarakoon, Yushan Siriwardhana Siriwardhana, Pawani Porambage Porambage, Madhusanka Liyanage Liyanage, Sang-Yoon Chang Chang, Jinoh Kim Kim, Jonghyun Kim Kim et Mika Ylianttila Ylianttila. *5G-NIDD : A Comprehensive Network Intrusion Detection Dataset Generated over 5G Wireless Network*, 2022. (Cité en page 58.)
- [Sammak 2023] Rami Sammak, Anna Lena Rotthaler, Harshini Sri Ramulu, Dominik Wermke et Yasemin Acar. *Developers’ Approaches to Software Supply Chain Security : An Interview Study*. Dans Proceedings of the 2024 Workshop on Software Supply Chain Offensive Research and Ecosystem Defenses, pages 56–66, 2023. (Cité en page 8.)
- [Sankar 2019] Aravind Sankar, Yanhong Wu, Liang Gou, Wei Zhang et Hao Yang. *Dynamic Graph Representation Learning via Self-Attention Networks*, juin 2019. (Cité en page 39.)
- [Sarhan 2022] Mohanad Sarhan, Siamak Layeghy et Marius Portmann. *Evaluating Standard Feature Sets Towards Increased Generalisability and Explainability of ML-Based Network Intrusion Detection*. Big Data Research, vol. 30, page 100359, novembre 2022. (Cité en page 59.)

- [Scarselli 2009] Franco Scarselli, Marco Gori, Ah Chung Tsoi, Markus Hagenbuchner et Gabriele Monfardini. *The Graph Neural Network Model*. IEEE Transactions on Neural Networks, vol. 20, no. 1, pages 61–80, 2009. (Cité en page 39.)
- [Sexton 2019] Conor Sexton, Nicola Marchetti et Luiz A. DaSilva. *Customization and Trade-offs in 5G RAN Slicing*. IEEE Communications Magazine, vol. 57, no. 4, pages 116–122, 2019. (Cité en page 7.)
- [Sharafaldin 2017] Sharafaldin. *Network Intrusion dataset(CIC-IDS- 2017)*, 2017. (Cité en page 59.)
- [Snort 2026] Snort. *Snort - Network Intrusion Detection & Prevention System*, 2026. (Cité en page 27.)
- [srsRAN 2026] srsRAN. *srsRAN Project* <https://www.srsran.com/>, 2026. (Cité en page 14.)
- [Suricata 2026] Suricata. *Home*, 2026. (Cité en page 27.)
- [Tan 2023] Yawen Tan, Jiadai Wang, Jiajia Liu et Yuanhao Li. *Deep Learning-Based Log Anomaly Detection for 5G Core Network*. Dans 2023 IEEE/CIC International Conference on Communications in China (ICCC), pages 1–6, août 2023. (Cité en page 32.)
- [Tan 2025] Yawen Tan, Jiajia Liu, Yuanhao Li et Jiadai Wang. *Deep Learning Based Proactive Anomaly Detection for 5G Core Control Plane Network Function Interactions*. IEEE Transactions on Cognitive Communications and Networking, pages 1–1, 2025. (Cité en pages 29, 31, 59 et 69.)
- [Tian 2023] Zixu Tian, Rajendra Patil, Mohan Gurusamy et Joshua McCloud. *ADSeq-5GCN : Anomaly Detection from Network Traffic Sequences in 5G Core Network Control Plane*. Dans 2023 IEEE 24th International Conference on High Performance Switching and Routing (HPSR), pages 75–82, juin 2023. (Cité en pages 29, 31, 58 et 59.)
- [TR 33.811 2018] TR 33.811. *Study on security aspects of 5G network slicing management (Release 15)*, June 2018. 3GPP Technical Specification Group Services and System Aspects. (Cité en page 7.)
- [TR 33.813 2020] TR 33.813. *Study on security aspects of network slicing enhancements (Release 16)*, June 2020. 3GPP Technical Specification Group Services and System Aspects. (Cité en page 7.)
- [TrendMicro 2019] TrendMicro. *CVE-2019-5736 : RunC Container Escape Vulnerability Provides Root Access to the Target Machine | Trend Micro (BE)*, 2019. (Cité en page 6.)
- [TrendMicro 2023] TrendMicro. *A Deep Dive into the Packet Reflection Vulnerability Allowing Attackers to Plague Private 5G Networks | Trend Micro (US)*, 2023. (Cité en pages 6, 9, 17, 19, 65 et 68.)
- [Trivedi 2018] Rakshit Trivedi, Mehrdad Farajtabar, Prasenjeet Biswal et Hongyuan Zha. *Representation Learning over Dynamic Graphs*. International Conference on Learning Representations (ICLR), 2018. (Cité en page 41.)

- [TS 23.501 2026] TS 23.501. *Specification # 23.501*, 2026. (Cité en page 16.)
- [TS 29.244 2026] TS 29.244. *Specification # 29.244*, 2026. (Cité en page 15.)
- [TS 29.281 2026] TS 29.281. *Specification # 29.281*, 2026. (Cité en page 18.)
- [TS 29.510 2026] TS 29.510. *Specification # 29.510*, 2026. (Cité en page 16.)
- [TS 33.501 2026] TS 33.501. *Specification # 33.501*, 2026. (Cité en pages 14, 16, 18 et 19.)
- [ueransim 2026] ueransim. *UERANSIM*, 2026. (Cité en pages 14 et 71.)
- [Veličković 2018] Petar Veličković, Guillem Cucurull, Arantxa Casanova, Adriana Romero, Pietro Liò et Yoshua Bengio. *Graph Attention Networks*, 2018. (Cité en pages 39 et 40.)
- [Vijayanand 2018] R. Vijayanand, D. Devaraj et B. Kannapiran. *Intrusion detection system for wireless mesh network using multiple support vector machine classifiers with genetic-algorithm-based feature selection*. *Computers & Security*, vol. 77, pages 304–314, août 2018. (Cité en page 27.)
- [Wang 2022] Yanbang Wang, Yen-Yu Chang, Yunyu Liu, Jure Leskovec et Pan Li. *Inductive Representation Learning in Temporal Networks via Causal Anonymous Walks*, octobre 2022. (Cité en pages 40 et 41.)
- [Wang 2023] Min Wang, Peng Li, Zhang Cheng, Wenmao Liu, Lei Nie, Haizhou Bao, Qin Liu et Kai Zhang. *Unsupervised Graph-Sequence Anomaly Detection for 5G Core Network Control Plane Traffic*. Dans 2023 IEEE 29th International Conference on Parallel and Distributed Systems (ICPADS), pages 1645–1652, décembre 2023. (Cité en pages 30, 31, 43, 58 et 59.)
- [Wei 2024] Kang Wei, Jun Li, Chuan Ma, Ming Ding, Sha Wei, Fan Wu, Guihai Chen et Thilina Ranbaduge. *Vertical Federated Learning : Challenges, Methodologies and Experiments*, août 2024. (Cité en pages 31 et 32.)
- [Wen 2022] Miaowen Wen, Qiang Li, Kyeong Jin Kim, David López-Pérez, Octavia A. Dobre, H. Vincent Poor, Petar Popovski et Theodoros A. Tsiftsis. *Private 5G Networks : Concepts, Architectures, and Research Landscape*. *IEEE Journal of Selected Topics in Signal Processing*, vol. 16, no. 1, pages 7–25, 2022. (Cité en page 7.)
- [Williams 2025] Laurie Williams, Giacomo Benedetti, Sivana Hamer, Ranindya Paramitha, Imranur Rahman, Mahzabin Tamanna, Greg Tystahl, Nusrat Zahan, Patrick Morrison, Yasemin Acaret *al.* *Research directions in software supply chain security*. *ACM Transactions on Software Engineering and Methodology*, vol. 34, no. 5, pages 1–38, 2025. (Cité en page 8.)
- [Xu 2019] Keyulu Xu, Weihua Hu, Jure Leskovec et Stefanie Jegelka. *How Powerful are Graph Neural Networks ?*, 2019. (Cité en page 39.)
- [Xu 2020] Da Xu, Chuanwei Ruan, Evren Korpeoglu, Sushant Kumar et Kannan Achan. *INDUCTIVE REPRESENTATION LEARNING ON TEMPORAL GRAPHS*. *International Conference on Learning Representations*, 2020. (Cité en pages 40 et 41.)

- [Yasrab 2023] Robail Yasrab. *Mitigating Docker Security Issues*, 2023. (Cité en page 6.)
- [Yu 2023] Le Yu, Leilei Sun, Bowen Du et Weifeng Lv. *Towards Better Dynamic Graph Learning : New Architecture and Unified Library*, mars 2023. (Cité en pages 40, 41 et 76.)
- [Zaame 2020] I. Zaame, Tomader Mazri et A. Elrhayour. *5G : Architecture Overview and Deployments Scenarios*. ISPRS - International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences, vol. XLIV-4/W3-2020, pages 435–440, 11 2020. (Cité en page 5.)
- [Zeek 2026] Zeek. *The Zeek Network Security Monitor*, 2026. (Cité en page 27.)
- [Zhang 2019] Wang Zhang et Yin Yiu. *Graph Masked Autoencoder for Spatio-Temporal Graph Learning*, 2019. (Cité en page 42.)
- [Zhao 2020] Ling Zhao, Yujiao Song, Chao Zhang, Yu Liu, Pu Wang, Tao Lin, Min Deng et Haifeng Li. *T-GCN : A Temporal Graph Convolutional Network for Traffic Prediction*. IEEE Transactions on Intelligent Transportation Systems, vol. 21, no. 9, pages 3848–3858, 2020. (Cité en page 39.)
- [Zimmermann 2019] Markus Zimmermann, Cristian-Alexandru Staicu, TU Darmstadt, Cam Tenny, Michael Pradel et TU Darmstadt. *Small World with High Risks : A Study of Security Threats in the npm Ecosystem*. 28th USENIX Conference on Security Symposium, 2019. (Cité en page 8.)